

# 1 Wielowskażnikowe modele regresji liniowej

$G$ -równaniowy ekonometryczny model regresji wielorakiej - postać uogólniona.

## 1.1 $G$ -równaniowy model regresji wielorakiej (bez restrykcji zerowych):

$$\begin{aligned} t_{t1} &= \gamma_{12}t_{t2} + \dots + \gamma_{1G}y_{tG} + \beta_{10} + \beta_{11}x_{t1} + \beta_{12}x_{t2} + \dots + \beta_{1k}x_{tk} + \varepsilon_{t1} \\ t_{t1} &= \gamma_{21}t_{t1} + \gamma_{23}t_{t3} + \dots + \gamma_{2G}y_{tG} + \beta_{20} + \beta_{21}x_{t1} + \beta_{22}x_{t2} + \dots + \beta_{2k}x_{tk} + \varepsilon_{t2} \\ &\vdots \\ t_{tG} &= \gamma_{G1}t_{t1} + \gamma_{G2}t_{t2} + \dots + \beta_{G0} + \beta_{G1}x_{t1} + \beta_{G2}x_{t2} + \dots + \beta_{Gk}x_{tk} + \varepsilon_{tG} \end{aligned}$$

### 1.1.1 SYNTETYCZNY ZAPIS MACIERZOWY MODELU

$$y_t \cdot \Gamma + x_t \cdot B = \varepsilon_t$$

gdzie:

$y_t = \begin{bmatrix} y_{t1} & y_{t2} & \dots & y_{tG} \end{bmatrix}$  - wektor zmiennych endogenicznych modelu

$\Gamma = \begin{bmatrix} \gamma_{G \times G} \end{bmatrix}$  - macierz parametrów strukturalnych zmiennych endogenicznych

$x_t = \begin{bmatrix} 1 & x_{t1} & x_{t2} & \dots & x_{tk} \end{bmatrix}$  - wektor zmiennych egzogenicznych modelu

$B = \begin{bmatrix} \beta_{(k+1) \times G} \end{bmatrix}$  - macierz parametrów strukturalnych zmiennych egzogenicznych

$\varepsilon_t = \begin{bmatrix} \varepsilon_{t1} & \varepsilon_{t2} & \dots & \varepsilon_{tG} \end{bmatrix}$  - wektor składników zakłócających modelu

$$Y \cdot \Gamma + X \cdot B = E$$

$$Y = \begin{bmatrix} y_{11} & y_{12} & \dots & y_{1G} \\ y_{21} & y_{22} & \dots & y_{2G} \\ \vdots & \vdots & \ddots & \vdots \\ y_{n1} & y_{n2} & \dots & y_{nG} \end{bmatrix} = Y_{n \times G} \text{ - macierz obserwacji endogenicznych modelu}$$

$$X = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1k} \\ 1 & x_{21} & x_{22} & \dots & x_{2k} \\ 1 & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{nk} \end{bmatrix} = X_{n \times (k+1)} \text{ - macierz obserwacji zmiennych egzogenicznych modelu}$$

$$E = \begin{bmatrix} \varepsilon_{11} & \varepsilon_{12} & \dots & \varepsilon_{1G} \\ \varepsilon_{21} & \varepsilon_{22} & \dots & \varepsilon_{2G} \\ \vdots & \vdots & \ddots & \vdots \\ \varepsilon_{n1} & \varepsilon_{n2} & \dots & \varepsilon_{nG} \end{bmatrix} = E_{n \times G} - \text{macierz składników zakłócających} \\ G\text{-równaniowego modelu}$$

## 1.2 Wstępne założenia dotyczące struktury stochastycznej modelu wielorównaniowego.

$$\begin{aligned} \mathbb{E}\varepsilon_{tj} &= 0 & t &= 1, 2, \dots, n & j &= 1, 2, \dots, G \\ \mathbb{E}\varepsilon &= 0 \end{aligned}$$

co oznacza, że składnik zakłócający jest zmienną losową o wartości oczekiwanej równe 0, w każdym okresie  $t$  i w każdym równaniu  $j$ -tym.

$$\mathbb{E}\varepsilon_{tj}^2 = \sigma_{\varepsilon j}^2 = \text{const.} \quad j = 1, 2, \dots, G$$

co oznacza, że w każdym równaniu  $j$ -tym wariancja składnika losowego jest stała i niezależna od okresu obserwacji.

$$\mathbb{E}\varepsilon_{tj}\varepsilon_{(t-s)j} = 0 \quad , (s \neq 0)$$

co oznacza, że kowariancja między składnikami losowymi w poszczególnych równaniach dla różnych okresów jest równa 0. Klasyfikacja modeli z punktu widzenia powiązań pomiędzy zmiennymi endogenicznymi.

### 1.2.1 MODEL PROSTY

Model prosty jest to model, w którym nieopóźnione zmienne endogeniczne nie oddziałują na siebie. Z uwagi na brak powiązań pomiędzy nieopóźnionymi zmiennymi endogenicznymi macierz  $\Gamma$  jest macierz diagonalną, będąc macierzą jednostkową.

Przykład trójrównaniowego modelu prostego:

$$\begin{aligned} y_{t1} &= \beta_{10} + \beta_{11}x_{t1} + \beta_{12}x_{t2} - \varepsilon_{t1} \\ y_{t2} &= \beta_{20} + \beta_{21}x_{t2} + \beta_{23}x_{t3} - \varepsilon_{t2} \\ y_{t3} &= \beta_{30} + \beta_{32}x_{t1} + \beta_{33}x_{t3} - \varepsilon_{t3} \end{aligned}$$

Zapis w postaci macierzowej

$$Y \cdot \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} + X \cdot \begin{bmatrix} -\beta_{10} & -\beta_{20} & -\beta_{30} \\ -\beta_{11} & -\beta_{21} & 0 \\ -\beta_{12} & 0 & -\beta_{32} \\ 0 & -\beta_{23} & -\beta_{33} \end{bmatrix} = E$$

Wstępne założenia stochastyczne dla modelu prostego:  
Zakładając nielosowość zmiennych z góry ustalonych (egzogenicznych) musimy uznać, że zmienne egzogeniczne są niezależne od składników losowych, tzn.

$$\mathbb{E}(X'_j \cdot \varepsilon_j) = (\mathbb{E}X'_j) \cdot (\mathbb{E}\varepsilon_j) = X'_j \cdot 0 = 0$$

### 1.2.2 MODEL REKURENCYJNY

Model rekurencyjny jest to model, w którym występują jednokierunkowe powiązania pomiędzy zmiennymi endogenicznymi nieopóźnionymi w czasie. Oznacza to, że macierz  $\Gamma$  - parametrów występujących przy zmiennych endogenicznych - jest macierzą trójkątną.

Przykład trójrównaniowego modelu rekurencyjnego:

$$Y \cdot \begin{bmatrix} 1 & 0 & 0 \\ -y_{12} & 1 & 0 \\ -y_{13} & -y_{23} & 1 \end{bmatrix} + X \cdot \begin{bmatrix} -\beta_{10} & -\beta_{20} & -\beta_{30} \\ -\beta_{11} & -\beta_{21} & 0 \\ -\beta_{12} & 0 & -\beta_{32} \\ 0 & -\beta_{23} & -\beta_{33} \end{bmatrix} = E$$

### Wniosek

W modelach rekurencyjnych istnieje zawsze takie równanie, w którym występują jedynie zmienne z góry ustalone (egzogeniczne).

W przypadku pozostałych równań musimy uznać, że w zbiorze zmiennych objaśniających występują zmienne losowe, którymi są zmienne endogeniczne występujące w charakterze zmiennych objaśniających. Zmienne endogeniczne występujące w charakterze zmiennych objaśniających mogą być uznane za:

- nieskorelowane ze składnikiem zakłócającym danego równania, jeśli konstrukcja modelu nie wymusza odrzucenia takiego założenia
- skorelowane ze składnikiem zakłócającym danego równania, jeśli wynika to z założeń tkwiących u podstaw konstrukcji modelu.

## 1.3 Model o równaniach współzależnych

Model o równaniach współzależnych jest to model, w którym występują nieopóźnione w czasie sprzężenia zwrotne pomiędzy zmiennymi endogenicznymi. Oznacza to, że macierz  $\Gamma$  nie jest macierzą ani diagonalną, ani trójkątną.

Przykład trójrównaniowego modelu regresji wielorakiej:

$$\begin{aligned} y_{t1} &= \gamma_{12}y_{t2} + \gamma_{13}y_{t3} + \beta_{10} + \beta_{11}x_{t1} + \beta_{12}x_{t2} + \varepsilon_{t1} \\ y_{t2} &= \gamma_{23}y_{t3} + \beta_{20} + \beta_{21}x_{t1} + \beta_{23}x_{t3} + \varepsilon_{t2} \\ y_{t3} &= \gamma_{31}y_{t1} + \beta_{30} + \beta_{33}x_{t3} + \varepsilon_{t3} \end{aligned}$$

$$Y \cdot \begin{bmatrix} 1 & 0 & 0 \\ -y_{12} & 1 & 0 \\ -y_{13} & -y_{23} & 1 \end{bmatrix} + X \cdot \begin{bmatrix} -\beta_{10} & -\beta_{20} & -\beta_{30} \\ -\beta_{11} & -\beta_{21} & 0 \\ -\beta_{12} & 0 & -\beta_{32} \\ 0 & -\beta_{23} & -\beta_{33} \end{bmatrix} = E$$

Uporządkowany całościowy zapis modelu z restrykcjami zerowymi

$$y_{t1} - \gamma_{12}$$

$$\begin{bmatrix} y_1 & y_2 & y_3 \end{bmatrix} \cdot \begin{bmatrix} 1 & 0 & -\gamma_{31} \\ -y_{12} & 1 & 0 \\ -y_{13} & -y_{23} & 1 \end{bmatrix} + \\ + \begin{bmatrix} 1 & x_1 & x_2 & x_3 \end{bmatrix} \cdot \begin{bmatrix} -\beta_{10} & -\beta_{20} & -\beta_{30} \\ -\beta_{11} & -\beta_{21} & 0 \\ -\beta_{12} & 0 & 0 \\ 0 & -\beta_{23} & -\beta_{33} \end{bmatrix} = \begin{bmatrix} \varepsilon_1 & \varepsilon_2 & \varepsilon_3 \end{bmatrix}$$

Z uwagi na to, że macierz  $\Gamma$  nie jest ani diagonalna, ani trójkątna, model uznajemy za model o równaniach współzależnych. Oznacza to, że między zmiennymi endogenicznymi nieopóźnionymi w czasie występują sprzężenia zwrotne.

Zauważmy, że zmienne endogeniczne, będąc między innymi funkcjami zmiennych losowych ( $\varepsilon$ ), jednocześnie nawzajem się wyjaśniają. Tym samym musimy uznać, że zmienne te - występując w poszczególnych równaniach w charakterze zmiennych objaśniających - są skorelowane ze składnikami losowymi tychże równań.

### 1.3.1 REDUKCJA MODELI O RÓWNANIACH WSPÓŁZALEŻNYCH

Procedura sprowadzania modelu o równaniach współzależnych do wielorównaniowego modelu prostego nazywamy redukcją. Przykładowa procedura redukcji naszego modelu

$$y_t \cdot \Gamma + x_t \cdot \beta = \varepsilon_t$$

Przekształcona postać modelu

$$y_t \cdot \Gamma = x_t \cdot (-\beta) + \varepsilon_t$$

Zapis macierz w postaci zredukowanej

$$y_t = x_t \cdot \pi + v_t$$

gdzie

$$\pi = -B\Gamma = \begin{bmatrix} \pi_{10} & \pi_{20} & \pi_{30} \\ \pi_{11} & \pi_{21} & \pi_{31} \\ \pi_{12} & \pi_{22} & \pi_{32} \\ \pi_{13} & \pi_{23} & \pi_{33} \end{bmatrix}$$

$\pi$ - macierz parametrów strukturalnych postaci zredukowanej o wymiarach  $(k+1) \times G$  (gdzie  $k+1=4$ ,  $G=3$ )

Wektor składników zakłócających postaci zredukowanej o wymiarach  $G \times G$ ,  $G=3$

$$v_t = \varepsilon_t \Gamma^{-1} =$$

Tym samym model w postaci macierzowej zapiszemy następująco

$$\begin{bmatrix} v_{t1} & v_{t2} & v_{t3} \end{bmatrix} = \begin{bmatrix} 1 & x_{t1} & x_{t2} & x_{t3} \end{bmatrix} \cdot \begin{bmatrix} \pi_{10} & \pi_{20} & \pi_{30} \\ \pi_{11} & \pi_{21} & \pi_{31} \\ \pi_{12} & \pi_{22} & \pi_{32} \\ \pi_{13} & \pi_{23} & \pi_{33} \end{bmatrix} + \begin{bmatrix} v_{t1} & v_{t2} & v_{t3} \end{bmatrix}$$

Co po rozpisaniu przybierze następującą postać

$$\begin{aligned} y_{t1} &= \pi_{10} + x_{t1}\pi_{11} + x_{t2}\pi_{12} + x_{t3}\pi_{13} + v_{t1} \\ y_{t2} &= \pi_{20} + x_{t1}\pi_{21} + x_{t2}\pi_{22} + x_{t3}\pi_{23} + v_{t2} \\ y_{t3} &= \pi_{30} + x_{t1}\pi_{31} + x_{t2}\pi_{32} + x_{t3}\pi_{33} + v_{t3} \end{aligned}$$

Rozpisany zapis macierzowy modelu dla  $n$  obserwacji przedstawia się następująco

$$Y = X\Pi + V$$

Zauważmy, że w każdym z równań postaci zredukowanej występują jedynie zmienne z góry ustalone (egzogeniczne) modelu. Jeśli uznamy, że są one nielosowe, mamy prawo wykluczyć ich ewentualną zależność ze składnikami losowymi poszczególnych równań. Wynika z tego, że każde z równań możemy oszacować stosując metodę najmniejszych kwadratów.

### 1.3.2 IDENTYFIKACJA

Identyfikacja jest ot proces rozpoznawania (identyfikowania) parametrów strukturalnych modelu (elementów macierzy  $\Gamma$  i  $B$ ) na podstawie parametrów

postaci zredukowanej, a więc na podstawie elementów macierzy  $\Pi$ . Ze zdefiniowania macierzy  $\Pi$  wynikają następujące konsekwencje

$$\Pi = -B\Gamma^{-1} \Leftrightarrow \Pi\Gamma = -B$$

Wykorzystując badany model oraz jego postać zredukowaną i odpowiednio zdefiniowane dla tych modeli macierze  $\pi, \Gamma$  oraz  $B$  drugi człon powyższego wyrażenia zapiszemy następująco

dużo rozpisanych macierzy

Powiemy, że  $j$ -ty układ równań:

1. Zawiera więcej parametrów  $\gamma$  i  $\beta$  aniżeli równań, to równanie  $M_j$ -te postaci strukturalnej uznajemy za **nieidentyfikowalne**.
2. Zawiera taką samą ilość parametrów  $\gamma$  i  $\beta$  aniżeli równań, to równanie  $M_j$ -te postaci strukturalnej uznajemy za **jednoznacznie identyfikowalne**.
3. Zawiera mniej parametrów  $\gamma$  i  $\beta$  aniżeli równań, to równanie  $M_j$ -te postaci strukturalnej uznajemy za **niejednoznacznie identyfikowalne**.

W rozpatrywanym przypadku otrzymujemy następujące trzy układy równań. Pierwszy układ równań (a) dla  $j = 1$  równania postaci strukturalnej modelu

$$\begin{aligned}\pi_{10} - \pi_{20}\gamma_{12} - \pi_{30}\gamma_{13} &= \beta_{10} \\ \pi_{11} - \pi_{21}\gamma_{12} - \pi_{31}\gamma_{13} &= \beta_{11} \\ \pi_{12} - \pi_{22}\gamma_{12} - \pi_{32}\gamma_{13} &= \beta_{12} \\ \pi_{13} - \pi_{23}\gamma_{12} - \pi_{33}\gamma_{13} &= 0\end{aligned}$$

Z uwagi na fakt, iż liczba poszukiwanych parametrów  $\gamma$  i  $\beta$  wynosi 5 (2 parametry  $\gamma$  oraz 3 parametry  $\beta$ ) jest większa od liczby równań, powyższy układ nie ma rozwiązania. Tym samym powiemy, że równanie pierwsze postaci strukturalnej jest nieidentyfikowalne.

Drugi układ równań (b) dla  $j = 2$  równania postaci strukturalnej modelu

$$\begin{aligned}\pi_{20} - \pi_{30}\gamma_{23} &= \beta_{20} \\ \pi_{21} - \pi_{31}\gamma_{23} &= \beta_{21} \\ \pi_{22} - \pi_{32}\gamma_{23} &= 0 \\ \pi_{23} - \pi_{33}\gamma_{23} &= \beta_{23}\end{aligned}$$

Z uwagi na fakt, iż liczba poszukiwanych parametrów  $\gamma$  i  $\beta$  wynosi 4 (1 parametr  $\gamma$  i 3 parametry  $\beta$ ) jest równa liczbie równań, powyższy układ ma

jednoznaczne rozwiązanie. Tym samym powiemy, że równanie drugie postaci strukturalnej jest jednoznacznie identyfikowalne. Zauważmy, że z równania trzeciego tego układu równań wynika, że

$$\pi_{22} - \gamma_{23}\pi_{32} = 0 \Rightarrow \gamma_{23} = \left( \frac{\pi_{21}}{\pi_{32}} \right)$$

Trzeci układ równań (c) dla  $j = 3$  równania postaci strukturalnej modelu

$$\pi_{30} - \pi_{10}\gamma_{31} = \beta_{30}$$

$$\pi_{31} - \pi_{11}\gamma_{31} = 0$$

$$\pi_{32} - \pi_{12}\gamma_{31} = 0$$

$$\pi_{33} - \pi_{13}\gamma_{31} = \beta_{33}$$

Z uwagi na fakt, iż liczba poszukiwanych parametrów  $\gamma$  i  $\beta$  wynosi 3 (1 parametr  $\gamma$  i 2 parametry  $\beta$ ) jest mniejsza od liczby równań, powyższy układ nie ma jednoznacznego rozwiązania. Tym samym powiemy, że równanie trzecie postaci strukturalnej jest niejednoznacznie identyfikowalne.

Aby sformułować użyteczne twierdzenia dotyczące identyfikacji modelu o równaniach współzależnych przyjmujemy następujący system oznaczeń:

- $k_j$  - liczba zmiennych z góry ustalonych występujących w  $j$ -tym równaniu modelu łącznie z wyrazem wolnym
- $K$  - liczba zmiennych z góry ustalonych występujących w całym modelu łącznie z wyrazem wolnym
- $G_j$  - liczba zmiennych łącznie współzależnych (endogenicznych) występujących w  $j$ -tym równaniu
- $G_{j-1}$  - liczba zmiennych łącznie współzależnych (endogenicznych) występujących w  $j$ -tym równaniu w charakterze zmiennych objaśniających (bez zmiennej objaśnianej w tym równaniu)
- $G$  - liczba zmiennych łącznie współzależnych zależnych (endogenicznych) występujących w całym modelu (równa liczbie równań modelu)

$$K_j^* = K - k_j$$

$$G_j^* = G - G_j$$

**Twierdzenie 1**

Warunkiem koniecznym na to, aby równanie  $j$ -te było identyfikowalne, jest aby liczba zmiennych z góry ustalonych oraz łącznie współzależnych występujących w równaniu  $j$ -tym w charakterze zmiennych objaśniających była mniejsza od liczby zmiennych z góry ustalonych występujących w całym modelu

$$K \geq K_j + G_j - 1$$

Równanie możemy przekształcić w następujący sposób

$$K - k_j \geq G_j - 1$$

Wprowadzając do siebie wyrażenia otrzymujemy

$$K - k_j \geq G - G_j^* - 1$$

a stąd ostatecznie otrzymujemy

$$K_j^* + G_j^* \geq G - 1$$

Wykorzystując powyższe wyrażenie formułujemy następujące twierdzenia

**Twierdzenie 2**

Warunkiem koniecznym na to, aby równanie  $j$ -te postaci strukturalnej modelu było **identyfikowalne**, jest by liczba zmiennych nie występujących w  $j$ -tym równaniu była nie mniejsza od liczby równań modelu pomniejszonej o jeden.

**Twierdzenie 3**

Warunkiem koniecznym na to, aby równanie  $j$ -te postaci strukturalnej modelu było **jednoznacznie identyfikowalne**, jest by liczba zmiennych nie występujących w  $j$ -tym równaniu była równa liczbie równań modelu pomniejszonej o jeden.

**Twierdzenie 4**

Warunkiem koniecznym na to, aby równanie  $j$ -te postaci strukturalnej modelu było **niejednoznacznie identyfikowalne**, jest by liczba zmiennych nie występujących w  $j$ -tym równaniu była większa od liczby równań modelu pomniejszonej o jeden.

**Twierdzenie 5**

Warunkiem dostatecznym na to, aby równanie  $j$ -te postaci strukturalnej modelu było **nieidentyfikowalne**, jest by liczba zmiennych nie występujących w  $j$ -tym równaniu była mniejsza od liczby równań modelu pomniejszonej o jeden.



### Zadanie

Rozpatrz następujący model o równaniach współzależnych

$$\begin{aligned}Y_t &= q_0 + q_1 L_t + a_2 k_t + a_3 H_t + a_4 ER_t + e_{t1} \\L_t &= b_0 + b_1 Y_t + b_2 K_t + b_3 W_t e_{t2} \\K_t &= c_0 + c_1 Y_t + c_2 R_t + e_{t3}\end{aligned}$$

#### 1.3.3 METODA ZMIENNYCH INSTRUMENTALNYCH

W dotychczas przedstawianych modelach przyjmowaliśmy założenie o braku korelacji między zmiennymi uwzględnionymi w specyfikacji modelu a składnikiem losowym. Jednak w wielu ważnych z punktu widzenia teorii ekonomicznej zastosowaniach takie założenie nie jest spełnione. W takim przypadku nie można udowodnić zgodności estymatora MNK.

W modelu  $Y = X\beta + \varepsilon$

- zmiennymi egzogenicznymi nazywamy zmienne, które nie są skorelowane ze składnikami losowymi
- zmiennymi endogenicznymi nazywamy zmienne, które są skorelowane ze składnikami losowymi

## 2 Równoczesność

O problemie równoczesności mówimy, gdy występuje niezerowa korelacja pomiędzy zmienną objaśniającą  $x_i$  a równoczesnym błędem losowym  $\varepsilon_j$ . Gdy  $\mathbb{E}(\varepsilon|X) \neq 0$  to

$$\begin{aligned}\mathbb{E}(b) &= \mathbb{E}\left((X'X)^{-1} X'y|X\right) \\ \mathbb{E}(b) &= \beta + (X'X)^{-1} X'\mathbb{E}(\varepsilon|X) \neq \beta\end{aligned}$$

Więc estymator wektora parametrów jest obciążony.

### 2.1 Przykłady

Model Keynesowski gospodarki zakłada, że

$$PKB = \text{konsumpcja} + \text{inwestycje} + \text{export netto}$$

Z drugiej strony Keynesowska funkcja konsumpcji zakłada, że  $C_t = f(Y_t)$ . Szacując jej parametry

$$C_t = \beta_0 + \beta_1 Y_t + \varepsilon_t$$

nie są spełnione założenia modelu, gdyż  $\text{cov}(X_t, \varepsilon_t) \neq 0$   
Szacujemy model autoregresji postaci

$$y_t = f(y_{t-1}, y_{t-2}, \dots) + \varepsilon_t$$

ale

$$y_{t+1} = f(y_{t-2}, y_{t-3}, \dots) + \varepsilon_{t+1}$$

zatem  $\text{cov}(y_{t-1}, \varepsilon_{t-1}) \neq 0$ . Wobec tego w modelu (1) zmienne objaśniające są skorelowane z błędem losowym. Zazwyczaj w zbiorach danych mikroekonomicznych brakuje informacji o zdolnościach respondentów. Mimo wszystko szacuje się równanie płacy typu Mincera

$$\ln(placa) = \beta_0 + \beta_1 plec + \beta_2 wiek + \beta_3 wiek^2 + \beta_4 wyksz + u$$

Ponieważ w modelu pominięto zmienną niezależną zdolności to składnik losowy ma postać

$$u = \gamma_0 + \gamma_1 zdolnosci + \phi$$

Z drugiej strony poziom wykształcenia jest determinowany przez zdolności respondenta. Zatem

$$\begin{aligned} \text{cov}(u, wyksz) &= \text{cov}(zdolnosci + \phi, wyksz) = \\ &= \text{cov}(zdolnosci, wyksz) + \text{cov}(\phi, wyksz) \neq 0 \end{aligned}$$

Ponieważ zmienna pominięta jest dodatnio skorelowana z uzyskanym wykształceniem i wpływa dodatnio na zmienną zależną to parametr przy zmiennej będzie dodatnio obciążony.

Metoda zmiennych instrumentalnych pozwala na uzyskanie zgodnych estymatorów w przypadku występowania korelacji między zmiennymi objaśniającymi a składnikiem losowym. Pozwala również uzyskać zgodne oszacowania parametrów w przypadku występowania problemu równoczesności. Polega ona na zastępowaniu oryginalnych zmiennych instrumentalami. Instrumenty powinny być skorelowane ze zmiennymi objaśniającymi, ale nie powinny być skorelowane z błędem losowym. Znalezienie właściwych instrumentów jest najciekawszym, ale również najtrudniejszym etapem badania.

Oznaczmy przez  $Z$  macierz zmiennych instrumentalnych ( $n$  instrumentów). Estymator MZI jest zgodny, gdy spełnione są następujące warunki

$$\begin{aligned} \text{plim} \left( \frac{1}{n} Z' \varepsilon \right) &= \text{plim} \left( \frac{1}{n} \sum_i z'_i \varepsilon_i \right) = \mathbb{E}(z'_i \varepsilon_i) = 0 \\ \text{plim} \left( \frac{1}{n} Z' X \right) &= \text{plim} \left( \frac{1}{n} \sum_i z'_i x_i \right) = \mathbb{E}(z'_i x_i) \neq 0 \end{aligned}$$

Dodatkowo  $r(\mathbb{E}(z'_i x_i)) = k$

$$plim\left(\frac{1}{n}Z'Z\right) = plim\left(\frac{1}{n}\sum_i z'_i z_i\right) = \mathbb{E}(z'_i z_i) \neq 0$$

Metoda polega na zastępowaniu oryginalnych wartości zmiennych objaśniających wartościami dopasowanymi uzyskanymi z regresji pomocniczej wykorzystującej zmienne instrumentalne.

- macierz instrumentów  $Z$  musi zawierać co najmniej tyle zmiennych, ile oryginalna macierz  $X$
- Ale nie w każdym przypadku konieczne jest posiadanie  $k$  nowych zmiennych
- Zmienne z macierzy  $X$ , które są nieskorelowane ze składnikiem losowym mogą same dla siebie stanowić instrumenty
- W rezultacie potrzeba co najmniej tylu dodatkowych zmiennych instrumentalnych ile jest zmiennych skorelowanych ze składnikiem losowym.

Macierz instrumentów uzyskujemy poprzez rzutowanie wektora  $X$  na przestrzeń rozpiętą przez kolumny macierzy instrumentów  $Z$

$$\hat{X} = Z \underbrace{(Z'Z)^{-1} Z'X}_{\beta} = Z\beta = \hat{P}_Z X$$

Dysponując macierzą instrumentów  $\hat{X}$  budujemy estymator

$$\begin{aligned}\beta_{MZI} &= (\hat{X}'X)^{-1} \hat{X}'y = (X'P_Z X)^{-1} X'P_Z y = \\ &= (X'Z(Z'Z)^{-1}Z')^{-1} X'Z(Z'Z)^{-1}Z'y\end{aligned}$$

jeżeli  $r(2) = r(X)$ , czyli tyle nowych zmiennych, ile zmiennych w macierzy  $X$  skorelowanych ze składnikiem.

Estymator MZI jest również nazywany estymatorem dwustopniowej metody najmniejszych kwadratów.

- W pierwszym kroku przeprowadzana jest regresja zmiennych endogenicznych na zmienne instrumentalne
- W drugim, oryginalne wartości zmiennych są zastępowane przez zwartości dopasowane z pierwszego kroku i oblicze są oszacowania poszczególnych parametrów

- W kolejnym kroku pokażemy, że przy warunkach zdefiniowanych wcześniej estymator MZI jest zgodny

Estymator MZI jest dany wzorem

$$\beta_{MZI} = \left( X'Z (Z'Z)^{-1} Z' \right)^{-1} X'Z (Z'Z)^{-1} Z'y$$

więc

$$plim \beta_{MZI} = plim \left( X'Z (Z'Z)^{-1} Z' \right)^{-1} X'Z (Z'Z)^{-1} Z'y$$

## Wnioski

- Estymator MZI jest zgodny nawet, gdy w modelu występują zmienne endogeniczne
- Ale, gdy nie ma takich zmiennych, a spełnione są założenia MNK to estymator MZI nie jest efektywny
- MZI można traktować jako uogólnienie MNK
- Wobec tego wszystkie testy stosowane przy MNK mogą być stosowane przy MZI
- Testy specyficzne dla MZI weryfikują założenie o egzogeniczności zmiennych oraz poprawności wykorzystanych instrumentów.

## 2.2 Test Hausmana

Przy estymacji MZI test Hausmana jest testem na egzogeniczność zmiennych. Estymator MZI jest estymatorem zawsze zgodnym.

Przy prawdziwej  $H_0$  o egzogeniczności zmiennych  $X$  oba estymatory są zgodne, ale estymator MZI ma większą wariancję niż estymator MNK.

Przy fałszywej  $H_0$  estymator MZI jest zgodny i efektywny, a estymator MNK nie jest zgodny.

Statystyka testowa jest dana przez formę kwadratową

$$(\beta_{MZI} - \beta_{MNK})' \Sigma_{\beta_{MZI} - \beta_{MNK}}^{-1} (\beta_{MZI} - \beta_{MNK}) \xrightarrow{D} \chi^2(r(\Sigma))$$

Gdy różnica jest duża sugeruje to wykorzystanie MNK.

## 2.3 Test Surgana

- Test Surgana weryfikuje poprawność instrumentów
- Zauważmy, że reszty modelu są równe

$$e = \left( I - X (X' P_Z X)^{-1} X' P_Z \right) \varepsilon$$

- Oczywiście  $M_Z$  jest macierzą idempotentną, rzędu  $p - k$
- Przy prawdziwości  $H_0$  jest brak korelacji instrumentów z błędami losowymi

$$\frac{e P_Z e}{\sigma^2} \sim \chi_{p-k}^2$$

- Niestety przeprowadzenie testu jest wyłącznie możliwe, gdy liczba instrumentów przekracza liczbę zmiennych objaśniających