

Rozdział 1

28 września 2015

Procesy stochastyczne - teoria służąca do opisu analizy (wnioskowań) zjawisk losowych ewoluujących w czasie. Wywodzą się z rachunku prawdopodobieństwa. Modelowanie rzeczywistości obarczonej niepewnością (losowością). Przeciwnieństwo równań różniczkowych.

$$\begin{aligned}y' &= f(y, t) \\ y(t) &= g(t, y_0)\end{aligned}$$

Równania różniczkowe dostarczają modeli deterministycznych. Idealizuje, możliwe w warunkach laboratoryjnych. Bardzo dużo praktycznych zagadnień nie ma charakteru deterministycznego (a jak już ma to będzie to determinizm chaotyczny). Chaos to nie to samo, co losowość. Losowość tkwi w głębi natury. Dla przykładu mechanika kwantowa.

Podstawowe elementy (pojęcia) procesów stochastycznych:

Przestrzeń probabilistyczna (Ω, \mathcal{F}, P)

Ω - zbiór zdarzeń elementarnych	} pojęcia pierwotne
$\omega \in \Omega$ - zdarzenie elementarne	
\mathcal{F} - σ -ciało podzbioru Ω	

Definicja 1 (σ -ciało)

Mówimy, że rodzina \mathcal{F} podzbiorów Ω jest σ -ciałem, jeśli spełnia:

1.

$$\emptyset \in \mathcal{F}, \quad \Omega \in \mathcal{F},$$

2.

$$\forall A \in \Omega [A \in \mathcal{F} \Rightarrow A^c = \Omega \setminus A \in \mathcal{F}],$$

3.

$$\forall A_1, A_2, \dots \in \Omega \left[\forall_n A_n \in \mathcal{F} \Rightarrow \bigcup_{n=1}^{\infty} A_n \in \mathcal{F} \right],$$

Definicja 2

Mówimy, że funkcja zbioru P określona na (Ω, \mathcal{F}) jest σ -addytywnym prawdopodobieństwem (miarą probabilistyczną σ -addytywną), jeżeli spełnia:

1.

$$P : \mathcal{F} \rightarrow [0, 1],$$

2.

$$P(\emptyset) = 0,$$

3.

$$P(\Omega) = 1,$$

4. warunek σ -addytywności

$$\forall A_1, A_2, \dots \in \mathcal{F} \left[\forall_{i \neq j} A_i \cap A_j = \emptyset \Rightarrow P \left(\bigcup_{n=1}^{\infty} A_n \right) = \sum_{n=1}^{\infty} P(A_n) \right]$$

Definicja 3 (Proces stochastyczny)

Procesem stochastycznym na przestrzeni probabilistycznej (Ω, \mathcal{F}, P) nazywamy rodzinę zmiennych losowych $\{X_t\}_{t \in T}$ określonych na (Ω, \mathcal{F}, P) .

T - zbiór indeksów (czasowych, gdy T interpretujemy jako czas)

Definicja 4 (Zmienna losowa)

Zmienna losowa X_t .

$$\forall t \in T \forall B \in \mathfrak{B}_{\mathbb{R}} X_t^{-1}(B) \in \mathcal{F}$$

X_t jest \mathcal{F} mierzalne; X_t jest $\sigma(\mathcal{F}, \mathfrak{B}_{\mathbb{R}})$ mierzalna

- $\mathfrak{B}_{\mathbb{R}}$ - σ -ciało zbiorów borelowskich w \mathbb{R}
- $\mathfrak{B}_{\mathbb{R}} = \sigma(\{(\alpha, \beta) : \alpha < \beta\})$

Uwaga!

$$\text{card}(\mathfrak{B}_{\mathbb{R}}) = \mathfrak{c} < 2^{\mathfrak{c}} = \text{card}(\mathcal{L}_{\mathbb{R}})$$

Definicja 5

Niech Ω będzie ustalonym zbiorem. Mówimy, że rodzina \mathcal{C} podzbiorów Ω tworzy ciało, jeżeli spełnia:

1.

$$\emptyset, \Omega \in \mathcal{C}$$

2.

$$\forall A \subseteq \Omega [A \in \mathcal{C} \Rightarrow A^c \in \mathcal{C}]$$

3.

$$\begin{aligned} & \forall A, B \in \mathcal{C} [A < B \Rightarrow A \cup B \in \mathcal{C}] \equiv \\ & \equiv \left[A_1, A_2, \dots, A_n \in \mathcal{C}, \quad n \in \mathbb{N} \Rightarrow \bigcup_{j=1}^n A_j \in \mathcal{C} \right] \end{aligned}$$

Definicja 6

Mówimy, że funkcja zbioru μ określona na (Ω, \mathcal{C}) jest miarą probabilistyczną σ -addytywną, jeśli spełnia:

1.

$$\begin{aligned} \mu(\emptyset) &= 0 \\ \mu(\Omega) &= 1 \\ \forall A \in \mathcal{C} \quad 0 &\leq \mu(A) \leq 1 \end{aligned}$$

2.

$$\forall A_1, A_2, \dots \in \mathcal{C} \left[\forall i \neq j A_i \cap A_j = \emptyset \wedge \bigcup_{n=1}^{\infty} A_n \in \mathcal{C} \Rightarrow \mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(A_n) \right]$$

Rozdział 2

5 Października 2015

Twierdzenie 1

Niech \mathcal{C} będzie ciałem podzbiorów Ω oraz $\mu : \mathcal{C} \rightarrow [0, 1]$ będzie miarą skończenie addytywną na (Ω, \mathcal{C}) nieujemną i unormowaną, czyli

$$\mu(\Omega) = 1, \forall a \in \mathcal{C} \quad 0 \leq \mu(A) \leq 1.$$

Wówczas następujące warunki są równoważne:

(A) μ jest σ -addytywna na (Ω, \mathcal{C})

(B) Ciągłość od dołu

$$\forall B_j \in \mathcal{C} \forall B_1 \subseteq B_2 \subseteq \dots \bigcup_{j=1}^{\infty} B_j \in \mathcal{C} \Rightarrow \mu \left(\bigcup_{j=1}^{\infty} B_j \right) = \lim_{n \rightarrow \infty} \mu(B_n)$$

(C) Ciągłość od góry

$$\forall C_j \in \mathcal{C} \forall C_1 \supseteq C_2 \supseteq \dots \bigcap_{j=1}^{\infty} C_j = \emptyset \Rightarrow \lim_{n \rightarrow \infty} \mu(C_n) = 0$$

Dowód. (A) \Rightarrow (B)

$$A_1 = B_1$$

$$A_2 = B_2 \setminus B_1$$

\vdots

$$A_n = B_n \setminus B_{n-1}$$

\vdots

$$\bigcup_{j=1}^{\infty} B_j = \bigcup_{j=1}^{\infty} A_j$$

$$\begin{aligned}
\mu\left(\bigcup_{j=1}^{\infty} B_j\right) &= \mu\left(\bigcup_{j=1}^{\infty} A_j\right) = \\
&= \sum_{j=1}^{\infty} \mu(A_j) = \lim_{n \rightarrow \infty} \sum_{j=1}^n \mu(A_j) = \\
&= \lim_{n \rightarrow \infty} \mu\left(\bigcup_{j=1}^n A_j\right) = \\
&= \lim_{n \rightarrow \infty} \mu(B_n)
\end{aligned}$$

(B) \Rightarrow (C)

$$C_1 \supseteq C_2 \supseteq \dots$$

$$\bigcap_{n=1}^{\infty} C_n = \emptyset$$

$$B_n = C_n^c = \Omega \setminus C_n$$

$$\bigcup_{n=1}^{\infty} B_n = (\bigcap_{n=1}^{\infty} C_n)^c = \emptyset^c = \Omega$$

$$\begin{aligned}
1 &= \mu(\Omega) = \\
&= \mu\left(\bigcup_{n=1}^{\infty} B_n\right) = \\
&= \lim_{n \rightarrow \infty} \mu(B_n) = \\
&= \lim_{n \rightarrow \infty} (\mu(\Omega) - \mu(C_n)) = \\
&= \lim_{n \rightarrow \infty} (\mu(\Omega) - \mu(C_n)) = \\
&= \mu(\Omega) - \lim_{n \rightarrow \infty} \mu(C_n) \Rightarrow \lim_{n \rightarrow \infty} \mu(C_n) = 0
\end{aligned}$$

(C) \Rightarrow (A)

$$\bigcup_{j=1}^{\infty} A_j \in \mathcal{C}$$

$$\bigcup_{j=1}^{n-1} A_j \in \mathcal{C}$$

$$C_n = \bigcup_{j=n}^{\infty} A_j = \bigcup_{j=1}^{\infty} A_j \setminus \bigcup_{j=1}^{n-1} A_j \in \mathcal{C}$$

$$C_1 \supseteq C_2 \supseteq \dots$$

$$\bigcap_{j=1}^{\infty} C_n = \emptyset.$$

$$\text{Z (C)} \lim_{n \rightarrow \infty} \mu(C_n) = 0$$

$$\begin{aligned} \mu(C_n) &= \\ &= \mu \left(\bigcup_{j=n}^{\infty} A_j \right) = \\ &= \mu \left(\bigcup_{j=1}^{\infty} A_j \setminus \bigcup_{j=1}^{n-1} A_j \right) = \\ &= \mu \left(\bigcup_{j=1}^{\infty} A_j \right) - \mu \left(\bigcup_{j=1}^{n-1} A_j \right) = \\ &= \mu \left(\bigcup_{j=1}^{\infty} A_j \right) - \sum_{j=1}^{n-1} \mu(A_j) \rightarrow 0 \end{aligned}$$

$$\begin{aligned} \lim_{n \rightarrow \infty} \mu \left(\bigcup_{j=1}^{n-1} A_j \right) &= \mu \left(\bigcup_{j=1}^{\infty} A_j \right) \\ \lim_{n \rightarrow \infty} \sum_{j=1}^{n-1} \mu(A_j) &= \mu \left(\bigcup_{j=1}^{\infty} A_j \right) \end{aligned}$$

Ostatecznie

$$\mu \left(\bigcup_{j=1}^{\infty} A_j \right) = \sum_{j=1}^{\infty} \mu(A_j)$$

□

Uwaga!

Warunek (C) jest bardzo wygodny do sprawdzenia.

Twierdzenie 2

Jeżeli μ jest prawdopodobieństwem σ -addytywnym na ciele \mathcal{C} podzbiorów Ω , to istnieje dokładnie jedno rozszerzenie μ do miary probabilistycznej $\tilde{\mu}$ na $\sigma(\mathcal{C})$ $\{\tilde{\mu}|_{\mathcal{C}} = \mu\}$

$$(\Omega, \mathcal{C}, \mu) \rightsquigarrow (\Omega, \sigma(\mathcal{C}), \tilde{\mu})$$

Tradycyjnie $\tilde{\mu}$ piszemy μ .

Dygresja

$\Omega = \mathbb{N}, A \subseteq \mathbb{N}, \nu(A) = \lim_{n \rightarrow \infty} \frac{\mu(A \cap \{1, 2, \dots, n\})}{n}$ gęstość zbioru A . Dobra miara

"grubości" podzbiorów \mathbb{N} . Nie wszystkie podzbiory mają gęstość. Z całą pewnością ν nie jest σ -addytywna, bo $\nu(k) = 0$, $\text{card}(k) < \infty$

$$1 = \nu(\mathbb{N}) \neq \lim_{n \rightarrow \infty} \nu(\{1, 2, \dots, n\}) = 0$$

Przykład 1

$$\Omega = (0, 1]$$

$$\mathcal{C}_{\text{przed.}} = \left\{ \bigcup_{j=1}^{\infty} (\alpha_j, \beta_j] : n = 0, 1, \dots; 0 < \alpha_1 < \beta_1 < \alpha_2 < \beta_2 < \dots < \alpha_n < \beta_n \right\}$$

$F : [0, 1] \rightarrow \mathbb{R}$, F niemalejąca, prawostronnie ciągła.

$$\mu_F \left(\bigcup_{j=1}^{\infty} (\alpha_j, \beta_j] \right) \stackrel{\text{df}}{=} \sum_{j=1}^n (F(\beta_j) - F(\alpha_j)) \geq 0$$

μ_F jest skończenie addytywna na $((0, 1], \text{przed.})$, co widać z konstrukcji. Nieco trudniej dowodzi się, że μ_F jest σ -addytywna na ciele $\mathcal{C}_{\text{przed.}}$. Zatem każda funkcja niemalejąca, prawostronnie ciągła $F : [0, 1]$ definiuje miarę σ -addytywną na $((0, 1], \sigma(\mathcal{C}_{\text{przed.}}))$

FUNKCJE TWORZĄCE

(p.g.f. probability geometry function)

Niech $X : (\Omega, \mathcal{F}, P) \rightarrow \mathbb{N}_0 = \{0, 1, 2, \dots\}$ będzie zmienną losową ($y \in X^{-1}(B) \in \mathcal{F}, \subseteq \mathbb{N}$ - dowolny podzbiór). Nową charakterystyką takich zmiennych losowych jest funkcja charakterystyczna.

Definicja 7 (Funkcja tworząca)

Funkcją tworzącą zmiennej losowej X o wartościach w \mathbb{N}_0 nazywamy

$$\Upsilon_X(s) = \mathbb{E}s^X \left(= \sum_{j=0}^{\infty} s^j P(X = j) = \sum_{j=0}^{\infty} s^j p_j \right)$$

Pytanie: $\text{Dom}(r_X) = ?$

r_X określona szeregiem potęgowym; pewnie analityczna. $r_X(z), z \in K(0, R)$

Twierdzenie 3

Niech $X, \tau, X^{(1)}, X^{(2)}, \dots$ będą zmiennymi losowymi o wartościach w \mathbb{N}_0 i oznaczmy $P(X = k) = p_k$, $P(X^{(n)} = k) = p_k^{(n)}$, $k = 0, 1, 2, \dots$. Wówczas:

1. $\text{dom}(\Upsilon_X) \supseteq [-1, 1]$ (W przypadku dziedziny zespolonej $\overline{K}(0, 1)$)
 Υ_X jest niemalejąca i wypukła na $[0, 1]$ oraz klasy C^∞ na $(-1, 1)$

2. $\Upsilon_X(1) = 1$

3.

$$\begin{aligned}\Upsilon'_X(0) &= P(X = 1) = p_1 \\ \Upsilon''_X(0) &= 2 \cdot P(X = 2) = 2p_2 \\ &\vdots \\ \Upsilon_X^{(k)}(0) &= k! \cdot P(X = k) = k!p_k\end{aligned}$$

4. Dla X

$$\mathbb{E}X^n < \infty \Leftrightarrow \lim_{n \rightarrow 1^-} \Upsilon_X^{(n)}(s) = \Upsilon_X^{(n)}(1^-) < \infty$$

Co więcej

$$\Upsilon_X^{(n)}(1^-) = \mathbb{E}X(X-1)\cdots(X-n+1)$$

n-ty moment faktorialny

W szczególności

$$\begin{aligned}\mathbb{E}X &= \Upsilon'_X(1^-) \\ \mathbb{E}X^2 &= \mathbb{E}X(X-1) + \mathbb{E}X = \Upsilon''_X(1^-) + \Upsilon'_X(1^-)\end{aligned}$$

5. Jeżeli x i Y są niezależne o wartościach w \mathbb{N}_0 , to $\Upsilon_{X+Y}(s) = \Upsilon_X(s)\Upsilon_Y(s)$

6. Jeżeli $X^{(1)}, X^{(2)}, \dots$ są niezależnymi zmiennymi losowymi o tym samym rozkładzie i o wartościach w \mathbb{N}_0 i podobnie τ i dodatkowo ciąg $X^{(1)}, X^{(2)}, \dots$ i τ są niezależne, to dla

$$U = \sum_{j=1}^{\tau} X^{(j)}$$

mamy

$$\Upsilon_U(s) = \Upsilon_{\tau}(\Upsilon_{X^{(1)}}(s))$$

7. Dla dowolnego ciągu zmiennych losowych (niekoniecznie niezależnych) $X^{(1)}, X^{(2)}, \dots$ i zmiennej losowej X o wartościach w \mathbb{N}_0 następujące warunki są równoważne:

$$(a) \quad \forall_{k \in \mathbb{N}_0} \lim_{n \rightarrow \infty} P(X^{(n)} = k) = P(X = k)$$

(b) $X_n \xrightarrow{\mathcal{D}} X$ (zbieżność słaba)

(c) $\forall_{s \in [0,1]} \lim_{n \rightarrow \infty} \Upsilon_{X^{(n)}}(s) = \Upsilon_X(s)$

Dowód.

$$2. \Upsilon_X(1) = \mathbb{E}1^X = \mathbb{E}1 = 1$$

1.

$$\Upsilon_X(s) = \sum_{k=0}^{\infty} s^X p_k = \sum_{k=0}^{\infty} p_k s^k$$

ten szereg potęgowy jest zbieżny dla $s = 1$ nawet bezwzględnie.

$$\left(\sum_{k=0}^{\infty} |p_k| |s|^k \right)_{s=1}$$

$$\sum_{k=0}^{\infty} |a_k| |z^k| < \infty$$

$\Upsilon_X(z)$ jest dobrze określone na $|z| \leq 1$.

Υ_X jest funkcją analityczną (co najmniej) na $\{z : |z| < 1\}$, a stąd wynika, że

Υ_X jest ciągła na $[-1, 1]$ i ma ciągłe pochodne na $(-1, 1)$.

$\Upsilon_X(s) = \sum_{k=0}^{\infty} p_k s^k \geq 0$ na $[0, 1]$

$\Upsilon'_X(s) = \sum_{k=0}^{\infty} k \cdot p_k s^{k-1} \geq 0$ - niemalejąca na $[0, 1]$

$\Upsilon''_X(s) = \sum_{k=0}^{\infty} k(k-1)p_k s^{k-2} \geq 0$ dla $s \in [0, 1]$

Reasumując Υ_X jest nieujemna, niemalejąca, wypukła na $[0, 1]$.

$$P(\{X+0\} \cup \{X=1\}) = 1$$

$$P(X \geq 2) > 0$$

$$\Upsilon_X(s) = p_0 + p_1 \cdot s$$

Υ_X ściśle wypukła

3.

$$\Upsilon_X^{(k)}(s) = \frac{d^k}{ds^k} \left(\sum_{j=0}^{\infty} p_j s^j \right) =$$

$$= \sum_{j=0}^{\infty} j(j-1) \cdots (j-k+1) p_j s^{j-k} = \sum_{j=k}^{\infty} j(j-1) \cdots (j-k+1) p_j s^{j-k}$$

$$\Upsilon_X^{(k)}(0) = k(k-1) \cdots (k-k+1) p_k = k! p_k \Rightarrow p_k = P(X=k) = \frac{\Upsilon_X}{k!}$$

4.

$$\begin{aligned}
\mathbb{E}X &= \\
&= \sum_{k=0}^{\infty} k \cdot P(X = k) = \\
&= \sum_{k=0}^{\infty} k \cdot p_k \cdot 1^k = \\
&= \left(\sum_{k=0}^{\infty} k \cdot p_k \cdot s^k \right)_{s=1} = \\
&= \lim_{n \rightarrow 1^-} \left(\sum_{k=0}^{\infty} k \cdot p_k \cdot s^k \right) = \\
&= \lim_{n \rightarrow 1^-} \Upsilon'_X(s)
\end{aligned}$$

Analogicznie

$$\begin{aligned}
&\mathbb{E}X(X+1) \cdots (X-n+1) = \\
&= \sum_{k=n}^{\infty} k(k-1) \cdots (k-n+1) p_k \cdot 1^{k-n+1} = \\
&= \lim_{n \rightarrow 1^-} \Upsilon_X^{(n)}(s)
\end{aligned}$$

Uwaga!

$$\mathbb{E}X^n < \infty \Leftrightarrow \mathbb{E}(X(X-1) \cdots (X-n+1)) < \infty$$

5. X, Y niezależne zmienne losowe o wartościach w \mathbb{N}_0

$$\Upsilon_{X+Y}(s) = \mathbb{E}s^{X+Y} = \mathbb{E}s^X \cdot s^Y = \mathbb{E}s^X \cdot \mathbb{E}s^Y = \Upsilon_X^{(s)} \Upsilon_Y^{(s)}$$

6. $V = \sum_{j=1}^{\tau} X^{(j)}$, ustalmy $\sum_{j=1}^0 \dots = 0$

$$\begin{aligned}
\Upsilon_V(s) &= \mathbb{E} s^V = \int_{\Omega} s^V dP = \\
&= \sum_{n=0}^{\infty} \int_{\{\tau=n\}} s^{\sum_{j=1}^{\tau} x^{(j)}} dP = \\
&= \int_{\{\tau=0\}} s^{\sum_{j=1}^0 x^{(j)}} dP + \sum_{n=1}^{\infty} \int_{\{\tau=n\}} s^{\sum_{j=1}^{\tau} x^{(j)}} dP = \\
&= 1 \cdot P(\tau=0) + \sum_{n=1}^{\infty} \int_{\Omega} \mathbb{1}_{\{\tau=n\}} dP \int_{\Omega} s^{\sum_{j=1}^{\tau} x^{(j)}} dP = \\
&= 1^0 \cdot P(\tau=0) + \sum_{n=1}^{\infty} P(\tau=n) \Upsilon_{\sum_{j=1}^{\tau} x^{(j)}}(s) = \\
&= P(\tau=0) \cdot s^0 + \sum_{n=1}^{\infty} P(\tau=n) [\Upsilon_{X^{(1)}}(s)]^n = \\
&= P(\tau=0) \cdot \left(\Upsilon_X^{(1)}(s)\right)^0 + \sum_{n=1}^{\infty} P(\tau=n) [\Upsilon_{X^{(1)}}(s)]^n = \\
&= \Upsilon_{\tau}(\Upsilon_{X^{(1)}}(s)) = \Upsilon_{\tau} \circ \Upsilon_{X^{(1)}}(s)
\end{aligned}$$

□

Rozdział 3

12 października 2015

Dowód. 7. (a) \Rightarrow (b)

$$P(X^{(n)} \leq t) \xrightarrow{n \rightarrow \infty} P(X \leq t)$$

w każdym punkcie t , w którym F_X jest ciągła; dla $t < 0$ jasne, bo $0 \xrightarrow{n \rightarrow \infty} 0$

$$\begin{aligned} P(X^{(n)} \leq t) &= \\ &= P(X^{(n)} \leq \lfloor t \rfloor) = \\ &= \sum_{k=0}^{\lfloor t \rfloor} P(X^{(n)} = k) \xrightarrow{n \rightarrow \infty} \sum_{k=0}^{\lfloor t \rfloor} P(X \leq \lfloor t \rfloor) = \\ &= P(X \leq t) \end{aligned}$$

(b) \Rightarrow (c)

$$\Upsilon_{X^{(n)}}(s) = \mathbb{E}s^{X^{(n)}}$$

$$g_s(t) = \begin{cases} 1 & \text{dla } t \leq 0 \\ s^t & \text{dla } t > 0 \end{cases} \quad \text{dla } 1 \geq s > 0$$
$$g_0(t) = 1 - 2t$$

$\forall_{s \in [0,1]} g_s$ jest funkcją ciągłą i ograniczoną

$$X \xrightarrow{\mathcal{D}} X \Leftrightarrow \forall_{g: \mathbb{R} \rightarrow \mathbb{R}} \mathbb{E}g(X^{(n)}) \xrightarrow{n \rightarrow \infty} \mathbb{E}g(X)$$

Dla każdego $s \in [0, 1]$ g jest funkcją ciągłą i ograniczoną.

$$\mathbb{E}g_s(X^{(n)}) = \mathbb{E}s^{X^{(n)}} = \Upsilon_{X^{(n)}}(s)$$

$$\mathbb{E}g_s(X) = \Upsilon_X(s)$$

$$\begin{aligned}\mathbb{E}g_0(X^{(n)}) &= 1 \cdot P(X^{(n)} = 0) + \sum_{k=1}^{\infty} 0 \cdot P(X^{(n)} = k) = \\ &= \Upsilon_{X^{(n)}}(0) \xrightarrow{n \rightarrow \infty} \mathbb{E}g_0(X) = \dots = \Upsilon_X(0)\end{aligned}$$

(c) \Rightarrow (a)

Mamy $\Upsilon_{X^{(n)}}(s) \rightarrow \Upsilon_X(s)$ dla $s \in [0, 1]$

Podstawmy $s = 0$

$$\begin{aligned}\sum_{k=0}^{\infty} s^k \cdot P(X^{(n)} = k) \Big|_{s=0} &= P(X^{(n)} = 0) \xrightarrow[n \rightarrow \infty]{c)} \Upsilon_X(0) \\ P_0^{(n)} &\rightarrow P_0\end{aligned}$$

Szkic

$$p_1^{(n)} = P(X^{(n)} = 1) \xrightarrow{n \rightarrow \infty} P(X = 0)?$$

$$\Upsilon_{X^{(n)}}(s) = P(X^{(n)} = 0) + P(X^{(n)} = 1)s + P(X^{(n)} = 2)s^2 + \dots$$

$$\Upsilon_X(s) = P(X = 0) + P(X = 1)s + P(X = 2)s^2 + \dots$$

$$\forall_{s \in [0,1]} \sum_{k=1}^{\infty} P(X^{(n)} = k) s^k \xrightarrow{n \rightarrow \infty} \sum_{k=1}^{\infty} P(X = k) s^k$$

$$\forall_{s \in [0,1]} s \sum_{k=1}^{\infty} P(X^{(n)} = k) s^{k-1} \xrightarrow{n \rightarrow \infty} s \sum_{k=1}^{\infty} P(X = k) s^{k-1}$$

o, ile $0 \leq s \leq 1$, to uprościmy

$$\begin{aligned}&\forall_{s \in [0,1]} \sum_{k=1}^{\infty} P(X^{(n)} = k) s^{k-1} = \\ &= P(X^{(n)} = 1) + P(X^{(n)} = 2)s + \dots + P(X^{(n)} = k) s^{k-1} + \dots \xrightarrow{n \rightarrow \infty} \\ &\xrightarrow{n \rightarrow \infty} P(X = 1) + P(X = 2)s + \dots + P(X = k) s^{k-1} + \dots\end{aligned}$$

mogą być dowolnie małe biorąc małe $s \in (0, 1]$. W takim razie, gdy $n \rightarrow \infty$ mamy

$$P(X^{(n)} = 0) \xrightarrow{n \rightarrow \infty} P(X = 0)$$

$$P(X^{(n)} = 1) \xrightarrow{n \rightarrow \infty} P(X = 1)$$

dalej indukcyjnie

$$\forall_{k \in \mathbb{N}_0} P(X^{(n)} = k) \xrightarrow{n \rightarrow \infty} P(X = k)$$

□

3.1 Funkcja generująca momenty (Moment generating function)

Definicja 8

Niech X będzie zmienną losową określoną na przestrzeni probabilistycznej (Ω, \mathcal{F}, P) . Funkcją generującą momenty nazywamy funkcję

$$M_X(s) = \mathbb{E}e^{sX} = \int_{-\infty}^{+\infty} e^{sx} dF_X(x)$$

Wtrącenie

$$\int_{-\infty}^{+\infty} e^{sx} f_X(x) dx, \text{ gdy } X \text{ ma gęstość } f_X$$

$$\sum_{k=1}^{\infty} e^{sx_k} P(X = x_k), \text{ gdy } X \text{ jest typu dyskretnego}$$

Wadą jest fakt, że $\text{Dom}(M_X)$ może być mała lub trudna do określenia. Np. może się zdarzyć, że $\text{Dom}(M_X) = \{0\}$, ale zawsze $0 \in \text{Dom}(M_X)$

Fakt

$$M_X(0) = \mathbb{E}e^{0 \cdot X} = \mathbb{E}e^0 = \mathbb{E}1 = 1$$

Chcielibyśmy, aby $(-\varepsilon, \varepsilon) \subseteq \text{Dom}(M_X)$

Twierdzenie 4

Niech zmienna losowa $X : (\Omega, \mathcal{F}, P) \rightarrow \mathbb{R}$ ma własność $\text{Dom}(M_X) \supseteq (-\varepsilon, \varepsilon)$ dla $\varepsilon > 0$. Wówczas

$$M'_X(0) = \mathbb{E}X$$

$$M''_X(0) = \mathbb{E}X^2 \text{ itd.}$$

Dowód.

$$\begin{aligned} M'_X(x) &= \\ &= \lim_{h \rightarrow 0} \frac{M_X(x+h) - M_X(x)}{h} = \\ &= \lim_{h \rightarrow 0} \frac{\mathbb{E}e^{(x+h)X} - \mathbb{E}e^{xX}}{h} = \\ &= \lim_{h \rightarrow 0} \mathbb{E} \frac{e^{(x+h)X} - e^{xX}}{h} = \\ &= \mathbb{E} \lim_{h \rightarrow 0} \frac{e^{(x+h)X} - e^{xX}}{h} = \\ &= \mathbb{E}X e^{xX} \end{aligned}$$

$$M'_X(0) = \left(M'_X(x) \right)_{x=0} = \mathbb{E} X e^{0X} = \mathbb{E} X$$

Indukcyjnie dla wyższych momentów. □

Twierdzenie 5

Jeżeli zmienne losowe X, Y są niezależne to

$$M_{X+Y}(x) = M_X(x) \cdot M_Y(x)$$

Dowód.

$$\begin{aligned} M_{X+Y}(x) &= \\ &= \mathbb{E} e^{x(X+Y)} = \\ &= \mathbb{E} e^{xX+xY} = \\ &= \mathbb{E} \underbrace{e^{xX} e^{xY}}_{\text{niezależne}} = \\ &= \mathbb{E} e^{xX} \cdot \mathbb{E} e^{xY} = \\ &= M_X(x) M_Y(x) \end{aligned}$$

□

Wniosek

Jeżeli X_1, \dots, X_k to niezależne zmienne losowe o tym samym rozkładzie, to

$$M_{\sum_{j=1}^k X_j}(x) = [M_{X_1}(x)]^k$$

Uwaga!

Jeżeli X i Y mają ten sam rozkład, to oczywiście

$$M_X = M_Y$$

Przykład 2

Wyznacz M_X , gdy $X \sim \text{Pois}(\lambda)$

$$\begin{aligned} M_X(x) &= \\ &= \mathbb{E} e^{xX} = \\ &= \sum_{k=0}^{\infty} e^{xk} \frac{\lambda^k}{k!} e^{-\lambda} = \\ &= \sum_{k=0}^{\infty} \frac{(e^x \lambda)^k}{k!} e^{-\lambda} = \\ &= e^{e^x \lambda} \cdot e^{-\lambda} = \\ &= e^{\lambda(e^x - 1)} \end{aligned}$$

$$\text{Dom}(M_{\text{Pois}}) = \mathbb{R}$$

$$\mathbb{E} = M'_X(0)$$

$$M'_X(x) = \left(e^{\lambda(e^x-1)} \right)' = e^{\lambda(e^x-1)} \cdot (\lambda \cdot e^x)$$

$$M''_X(x) = \left(e^{\lambda(e^x-1)} \cdot (\lambda \cdot e^x) \right)' = \lambda \left(e^{\lambda(e^x-1)} \cdot \lambda e^x \cdot e^x + e^{\lambda(e^x-1)} \cdot e^x \right)$$

$$M''_X(0) = \lambda(\lambda + 1) = \lambda^2 + \lambda = \mathbb{E}X^2$$

$$\text{Var}(X) = \mathbb{E}X^2 - (\mathbb{E}X)^2 = \lambda^2 + \lambda - \lambda^2 = \lambda$$

Przykład 3

$$X \sim \text{Exp}(\alpha)$$

$$M_X(x) = \mathbb{E}e^{xX} = \int_0^{+\infty} e^{xt} \alpha e^{-\alpha t} dt = \alpha \int_0^{\infty} e^{(x-\alpha)t} dt =$$

$$= \frac{\alpha}{x-\alpha} e^{(x-\alpha)t} \Big|_0^{\infty} = \frac{-\alpha}{x-\alpha} = \frac{\alpha}{\alpha-x}$$

$$\text{Dom}M_{\text{Exp}(\alpha)} = (-\infty, \alpha)$$

$$M'_X(x) = \frac{\alpha}{(x-\alpha)^2} \qquad M'_X(0) = \mathbb{E}X = \frac{\alpha}{\alpha^2} = \frac{1}{\alpha}$$

$$M''_X(x) = \frac{2\alpha}{(\alpha-x)^3} \qquad M''_X(0) = \mathbb{E}X^2 = \frac{2\alpha}{\alpha^3} = \frac{2}{\alpha^2}$$

itd.

3.2 Uwagi o teorii niezawodności

Niech czas pracy bezawaryjnej urządzenia opisany będzie zmienną losową $X : (\Omega, \mathcal{F}, P) \rightarrow [0, \infty)$

Definicja 9 (Funkcja niezawodności)

Funkcją niezawodności urządzenia nazywamy

$$R_X(t) = \overline{F}(t) = P(X > t) \text{ dla } t \in [0, \infty]$$

Uwaga!

$P(X = 0) = 0$ to nasze upraszczające założenie.

Definicja 10

Niech X będzie nieujemną zmienną losową. Mówimy, że X ma własność braku pamięci, jeżeli

$$\forall_{s,t \geq 0} P(X > s+t | X > t) = P(X > s)$$

Twierdzenie 6

Nieujemna zmienna losowa X ma własność braku pamięci wtedy i tylko wtedy, gdy ma rozkład wykładniczy.

Dowód. \Leftarrow

Zakładamy, że $X \sim \text{Exp}$, $P(X > t) = e^{-\alpha t}$

$$\begin{aligned} P(X > t + s | X > t) &= \frac{P(X > t + s \wedge X > t)}{P(X > t)} = \\ &= \frac{P(X > t + s)}{P(X > t)} = \\ &= \frac{e^{-\alpha(t+s)}}{e^{-\alpha t}} = \\ &= e^{-\alpha s} = \\ &= P(X > s) \end{aligned}$$

\Rightarrow

Zakładamy, że X ma własność braku pamięci

$$\begin{aligned} P(X > t + s | X > t) &= P(X > s) \\ \frac{P(X > t + s \wedge X > t)}{P(X > t)} &= P(X > s) \\ P(X > s + t) &= P(X > s) P(X > t) \\ \bar{F}_X(s + t) &= \bar{F}_X(s) \bar{F}_X(t) \text{ dla } s, t \geq 0 \end{aligned}$$

Mamy równanie funkcyjne dla $g : [0, \infty) \rightarrow \mathbb{R}$

$$\forall_{s, t \geq 0} g(t + s) = g(t)g(s)$$

$g(t) = \bar{F}(t)$ ograniczona, prawostronnie ciągła oraz $\bar{F}(0) = 1$ i

$$\lim_{x \rightarrow \infty} \bar{F}(x) = 0$$

Odrzucamy trywialne rozwiązania równania $g \equiv 0$, $g \equiv 1$

$$\begin{aligned} g(2s) &= g(s + s) = g(s) \cdot g(s) = g(s)^2 \geq 0 \\ g(1) &= \underbrace{\left(\frac{1}{m} + \frac{1}{m} + \dots + \frac{1}{m} \right)}_{m \text{ razy}} = g\left(\frac{1}{m}\right) g\left(\frac{1}{m}\right) \dots g\left(\frac{1}{m}\right) = \left[g\left(\frac{1}{m}\right) \right]^m \\ g\left(\frac{1}{m}\right) &= g(1)^{\frac{1}{m}} \\ g\left(\frac{k}{m}\right) &= \underbrace{\left(\frac{1}{m} + \frac{1}{m} + \dots + \frac{1}{m} \right)}_{k \text{ składników}} = g\left(\frac{1}{m}\right) g\left(\frac{1}{m}\right) \dots g\left(\frac{1}{m}\right) = \\ &= g\left(\frac{1}{m}\right)^k = [g(1)]^{\frac{k}{m}} = g(1)^{\frac{k}{m}} \end{aligned}$$

Gdyby $g(1) = 0 \Rightarrow g\left(\frac{1}{m}\right) = 0 \Rightarrow \lim_{m \rightarrow \infty} g\left(\frac{1}{m}\right) = 0$, ale $g(0) = 1$

Zatem $g(1) > 0$.

Gdyby $g(1) > 1 \Rightarrow g(k) = g(1)^k \xrightarrow{k \rightarrow \infty} 0$, ale $\lim_{x \rightarrow \infty} g(x) = 0$

Zatem $0 < g(1) < 1$. Przyjmijmy, że $g(1) = e^{-\alpha}$ dla pewnego $\alpha > 0$. Wtedy $g\left(\frac{k}{m}\right) = (e^{-\alpha})^{\frac{k}{m}} = e^{-\alpha \frac{k}{m}}$

Dla dowolnego $x \geq 0$, $\lim_{n \rightarrow \infty} \frac{k^{(n)}}{m^{(n)}} \left(\overline{\mathbb{Q}} = \mathbb{R} \right)$

$$g(x) = \lim_{n \rightarrow \infty} g\left(\frac{k^{(n)}}{m^{(n)}}\right) = \lim_{n \rightarrow \infty} e^{-\alpha \frac{k^{(n)}}{m^{(n)}}}$$

$$\forall_{x \geq 0} 1 - F(x) = \overline{F}(x) = e^{-\alpha x}; X \sim \text{Exp}$$

□

Uwaga!

W dziedzinie $\mathbb{N}_0 = \{0, 1, 2, \dots\}$ jedynym rozkładem o własności braku pamięci jest rozkład geometryczny.

Definicja 11

Niech X będzie zmienną losową opisującą czas pracy bezawaryjnej. Intensywnością awarii nazywamy funkcję $\lambda_X : [0, \infty) \rightarrow [0, \infty)$

$$\lambda_X(t) = \frac{f_X(t)}{\overline{F}_X(t)} = \frac{f_X(t)}{R_X(t)} = -\frac{R'_X(t)}{R_X(t)}$$

$$R'_X = (1 - F_X)' = -F'_X = -f_X$$

Uwaga!

λ_X jest określona tylko dla zmiennych losowych absolutnie ciągłych.

W medycynie mówimy o intensywności śmierci albo ogólniej o funkcji hazardu. Rozkład (gęstość) wyznacza jednoznacznie funkcję intensywności awarii.

$$\lambda_X(t) = \frac{f_X(t)}{P(x > t)} = \frac{f_X(t)}{\int_t^\infty f_X(u) du}$$

Interpretacja funkcji intensywności awarii.

$$\begin{aligned}
& \lim_{\Delta \rightarrow 0^+} \frac{P(t < X \leq t + \Delta T | X > t)}{\Delta t} = \\
&= \lim_{\Delta \rightarrow 0^+} \frac{\frac{P(X_t \in (t, t + \Delta t] | X_t > t)}{R_X(t)}}{\Delta t} = \\
&= \lim_{\Delta \rightarrow 0^+} \frac{\frac{P(X_t \in (t, t + \Delta t])}{\Delta t}}{R_X(t)} = \\
&= \lim_{\Delta \rightarrow 0^+} \frac{\frac{1}{\Delta t} \int_t^{t+\Delta t} f_X(u) du}{R_X(t)} = \\
&= \frac{f_X(t)}{R_X(t)}
\end{aligned}$$

Rozdział 4

19 października 2015

Twierdzenie 7

Funkcja intensywności awarii wyznacza jednoznacznie F_X . ($F_X \longleftrightarrow \lambda_X$)

Dowód.

$$\lambda_X = -\frac{R'_x}{R_X} = -(\ln R_X)'$$

$$\Lambda_X(x) = \int_0^x \lambda_X(u) du = - \int_0^x (\ln R_X) du = -\ln R_X|_0^x = -\ln R_X(x) + \ln \overbrace{R_X(0)}^{=1}$$

$$R_X(x) = e^{-\int_0^x \lambda_X(u) du}$$

$$F_X(x) = 1 - e^{-\int_0^x \lambda_X(u) du}$$

□

Definicja 12

Jeżeli urządzenie opisane jest funkcją intensywności awarii λ_X , to

1. mówimy, że urządzenie starzeje się, gdy $\lambda_X \nearrow$ jest funkcją rosnącą
2. mówimy, że urządzenie dociera się, gdy $\lambda_X \searrow$ jest funkcją malejącą

Uwaga!

$$\lambda_X = \text{const} \Leftrightarrow X \sim \text{Exp}$$

4.1 Klasyczne rozkłady w teorii niezawodności

Definicja 13

Mówimy, że nieujemna zmienna losowa X ma rozkład Weibulla, gdy

$$\begin{aligned} F_X(t) &= 1 - e^{-(\lambda t)^\beta} & t \geq 0 & \quad \lambda, \beta > 0 \\ R_X(t) &= e^{-(\lambda t)^\beta} & t \geq 0 & \quad \lambda, \beta > 0 \end{aligned}$$

Dla rozkładu Weibulla

$$\lambda_X(t) = \frac{\lambda\beta(\lambda t)^{\beta-1}e^{-(\lambda t)^\beta}}{e^{-(\lambda t)^\beta}} = \lambda^\beta\beta t^{\beta-1}$$

Układ dociera się, gdy $\beta < 1$

Układ starzeje się, gdy $\beta > 1$

$$\text{Weib}_{\lambda,1} = \text{Exp}(\lambda)$$

W praktyce inżynierskiej

$$F_X(t) = \alpha_1 e^{-\lambda_1 t} + \alpha_2 e^{-\lambda_2 t} + \alpha_3 \frac{\text{const}}{\sqrt{2\pi}} \int_{\frac{t-m}{\sigma}}^{\infty} e^{-\frac{1}{2}u^2} du$$

Czyli mieszane rozkłady $\text{Exp} \approx \text{Exp} \approx \Gamma$

4.2 Formalne definicje z teorii procesów stochastycznych

Definicja 14

Niech $T(\neq \emptyset)$ będzie zbiorem indeksów. Procesem stochastycznym indeksowanym elementami zbioru T nazywamy rodzinę $\{X_t : t \in T\}$ zmiennych losowych (ogólniej elementów losowych) określonych na wspólnej przestrzeni probabilistycznej (Ω, \mathcal{F}, P) . Jeżeli $\text{card}(T) < \infty$ albo $\text{card}(T) = \aleph_0$, to mówimy o procesach z indeksem dyskretnym. Jeżeli $\text{card}(T) = \mathfrak{c}$, to mówimy, o procesach nad indeksami "ciągłymi".

T identyfikujemy z biegnącym czasem

$T = \{0, 1, \dots, N\}$ albo $T = \{1, 2, \dots, N\}$ albo $T = \{0, 1, 2, \dots\}$ albo $T = \{-3, -2, -1, 0, 1, 2, 3, \dots\}$ - procesy z czasem dyskretnym.

$T = [a, b], [a, \infty), (-\infty, 0], (-\infty, +\infty)$ - procesy z czasem ciągłym

$\mathfrak{X} = \{X_t : t \in T\}$ - matematyczny opis (model) ewolucji w czasie

Definicja 15

Dla ustalonego procesu stochastycznego $\mathfrak{X} = \{X_t : t \in T\}$ trajektorią (realizacją) odpowiadającą zdarzeniu elementarnemu $\omega \in \Omega$ nazywamy funkcję $T \ni t \rightarrow X_t(\omega) \in \mathbb{R}$

Przykład 4

W urnie mamy 1 kulę białą i 1 kulę niebieską. Po wylosowaniu jednej kuli zwracamy ją do urny dodając jedną kulę w wylosowanym kolorze (po n -tym losowaniu mamy w urnie $2 + n$ kul). Procesy stochastyczne na tym mechanizmie (losowym). (\equiv procesy urnowe).

1. X_n - liczba kul białych w urnie po n -tym losowaniu

$$X_0 = 1$$

$$X_1 = \left(P(X_1 = 1) = P(X_1 = 2) = \frac{1}{2} \right)$$

$$X_3 \in \{1, 2, 3\}, \dots$$

$\mathfrak{X} = \{X\}_{n=0}^\infty$ - proces stochastyczny z czasem dyskretnym,
 $T = \{0, 1, 2, \dots\} = \mathbb{N}_0$

- 2.

$$Y_n = \begin{cases} 1 & \text{gdy kula wylosowana w } n\text{-tym cięgnięciu jest niebieska} \\ 3 & \text{gdy kula wylosowana w } n\text{-tym cięgnięciu jest biała} \end{cases}$$

$$\{Y_n\}_{n=1}^\infty, \quad T = \{1, 2, \dots\}$$

3. Z_n = liczba wylosowanych kul białych w cięgnięciach $1, 2, \dots, n$

4. Zrób to sam(a)

4.3 Spacer losowy na grupie

$\xi_1, \xi_2, \xi_3, \dots$ ciąg Berboulliego niezależnych zmiennych losowych o tym samym rozkładzie

$$P(\xi_j = 1) = P(\xi_j = -1) = \frac{1}{2}$$

X_0 niezależna zmienna losowa od ciągu $(\xi_j)_{j=1}^\infty$ o wartościach w \mathbb{Z} .
Spacerem losowym nazywamy

$$S_{X_0, n} = X_0 + \xi_1 + \dots + \xi_n = X_0 + \sum_{j=1}^n \xi_j$$

Zauważmy, że

$$P(S_{X_{0,n+1}} - S_{X_{0,n}} = \pm 1) = P(\xi_{n+1} = \pm 1) = \frac{1}{2}$$

$$P(S_{X_{0,n+1}} = j | S_{X_{0,n}} = \pm 1) = \begin{cases} \frac{1}{2} & , \text{ gdy } |i - j| = 1 \\ 0 & , \text{ gdy } |i - j| \neq 1 \end{cases}$$

Uwaga!

Jeżeli $\mathfrak{X} = \{X_t\}_{t \in T}$ jest procesem stochastycznym, to $Y_t = g_t(X_t)$, $t \in T$ jest też procesem stochastycznym $g_t : \mathbb{R} \rightarrow \mathbb{R}$ (funkcja borelowska).

Definicja 16

Niech $\mathfrak{X} = \{X_t : t \in T\} = \{X_t\}_{t \in T}$ będzie procesem stochastycznym określonym na (Ω, \mathcal{F}, P) , przy czym $T = \mathbb{Z}$ albo $\mathbb{N}, \mathbb{R}, \mathbb{R}_+, \mathbb{Q}, \mathbb{Q}_+$. Mówimy, że \mathfrak{X} ma przyrosty:

- niezależne, gdy

$$\forall n \in \mathbb{N} \forall t_j \in T \forall t_0 < t_1 < \dots < t_n X_{t_1} - X_{t_0}, X_{t_2} - X_{t_1}, \dots, X_{t_n} - X_{t_{n-1}}$$

są zmiennymi losowymi niezależnymi

- jednorodne, gdy

$$\forall t_1, t_2 \in T; t_1 < t_2 \forall t_1 + h, t_2 + h \in T (X_{t_2} - X_{t_1}) \sim (X_{t_2 + h} - X_{t_1 + h})$$

- stacjonarne, gdy

$$\forall n \in \mathbb{N} \forall t_1, t_2 \in T; t_1 < t_2 \forall t_1 + h, t_2 + h \in T \\ (X_{t_1} - X_{t_0}, \dots, X_{t_n} - X_{t_{n-1}}) \sim (X_{t_1 + h} - X_{t_0 + h}, \dots, X_{t_n + h} - X_{t_{n-1} + h})$$

Uwaga!

Stacjonarność przyrostów implikuje jednorodność przyrostów.

Definicja 17

Niech $\mathfrak{X} = \{X_t : t \in T\}$ będzie procesem stochastycznym określonym na (Ω, \mathcal{F}, P) przy czym $T = \mathbb{Z}$ albo $\mathbb{N}, \mathbb{R}, \mathbb{R}_+, \mathbb{Q}, \mathbb{Q}_+$. Mówimy, że proces \mathfrak{X} jest stacjonarny, gdy

$$\forall n \in \mathbb{N} \forall t_j \in T \forall t_0 < t_1 < \dots < t_n \forall h : t_0 + h, \dots, t_n + h \in T (X_{t_0}, X_{t_1}, \dots, X_{t_n}) \sim (X_{t_0 + h}, X_{t_1 + h}, \dots, X_{t_n + h})$$

Oznaczenia

$\mu_{t_0, t_1, \dots, t_n} \stackrel{\text{ozn.}}{=} \mu_{(X_{t_0}, X_{t_1}, \dots, X_{t_n})}$ - rozkład wektora losowego

$(X_{t_0}, X_{t_1}, \dots, X_{t_n}) \in \mathbb{R}^{n+1}$, $n = 0, 1, 2 \dots$

μ_t - rozkład X_t losowych o tym samym, czyli rozkład jednowymiarowy

$\mu_{r,t}$ rozkład (X_r, X_t) , czyli rozkład dwuwymiarowy itd.

$F_{t_0, t_1, \dots, t_n} \stackrel{\text{ozn.}}{=} F_{(X_{t_0}, X_{t_1}, \dots, X_{t_n})}$

Definicja 18

Jeżeli $\mathfrak{X} = \{X_t : t \in T\}$ jest procesem stochastycznym, to rozkładem skończenie wymiarowym odpowiadającym wyborowi indeksów $(t_1, t_2, \dots, t_n) \in T^n$ nazywamy rozkład wektora losowego $(X_{t_0}, X_{t_1}, \dots, X_{t_n})$. Oznaczam

$$\mu_{(t_1, t_2, \dots, t_n)} \stackrel{df}{=} \mathcal{L}((X_{t_0}, X_{t_1}, \dots, X_{t_n})) \in \mathcal{P}(\mathbb{R}^n)$$

Rodzina rozkładów skończenie wymiarowych procesów $\mathfrak{X} = \{X_t : t \in T\}$ nazywamy

$$\mathcal{M}^{\mathfrak{X}} = \left\{ \mu_{(t_1, t_2, \dots, t_n)} : t_1, t_2, \dots, t_n \in T, n = 1, 2, \dots \right\}$$

Uwaga!

Zmienną losową X charakteryzuje F_X

Wektor losowy $\vec{X} = (X_1, \dots, X_n)$ charakteryzuje $F_{\vec{X}}$ dystrybucja łączna n -wymiarowa.

Proces stochastyczny \mathfrak{X} charakteryzuje $\mathcal{M}^{\mathfrak{X}}$

Lemat 1

Proces $\mathfrak{X} = \{X_t : t \in T\}$ o przyrostach niezależnych ma przyrosty stacjonarne wtedy i tylko wtedy, gdy ma przyrosty jednorodne.

Dowód.

” \Rightarrow ” jasne

” \Leftarrow ”

Wybieramy $t_0 < t_1 < \dots < t_n \in T$ oraz h ”dowolne”, takie, że $t_0 + h, t_1 + h, \dots, t_n + h \in T$

$$\begin{aligned} & \mu_{(X_{t_1}-X_{t_0}, X_{t_2}-X_{t_1}, \dots, X_{t_n}-X_{t_{n-1}})} = \\ & = \mu_{(X_{t_1}-X_{t_0})} \otimes \mu_{(X_{t_2}-X_{t_1})} \otimes \dots \otimes \mu_{(X_{t_n}-X_{t_{n-1}})} \stackrel{jed.}{=} \\ & = \mu_{(X_{t_1+h}-X_{t_0+h})} \otimes \mu_{(X_{t_2+h}-X_{t_1+h})} \otimes \dots \otimes \mu_{(X_{t_n+h}-X_{t_{n-1}+h})} = \\ & = \mu_{(X_{t_1+h}-X_{t_0+h}, X_{t_2+h}-X_{t_1+h}, \dots, X_{t_n+h}-X_{t_{n-1}+h})} \end{aligned}$$

□

Rozdział 5

26 października 2015

Definicja 19 (Proces Poissona)

Mówimy, że proces $\{N_t\}_{t \in [0, \infty)}$ określony na przestrzeni probabilistycznej (Ω, \mathcal{F}, P) jest procesem liczącym, jeżeli

1. $N_0 = 0$

$$\forall \omega \in \Omega \forall t \in T N_T(\omega) \in \mathbb{N}_0 = \{0, 1, 2, \dots\}$$

- 2.

$$\forall 0 \leq s < t \forall \omega \in \Omega N_s(\omega) \leq N_t(\omega)$$

3. $\forall 0 \leq s < t N_t(\omega) - N_s(\omega)$ reprezentuje liczbę zdarzeń jakie zaszły na odcinku czasowym $(s, t]$.

Definicja 20 (Proces jednorodny)

Mówimy, że proces liczący $\{N_t\}_{t \in [0, \infty)}$ określony na przestrzeni probabilistycznej (Ω, \mathcal{F}, P) jest jednorodnym procesem Poissona z intensywnością $\lambda > 0$ - liczba, jeżeli spełnia

- i $N(0) = 0$ z prawdopodobieństwem 1
- ii $\{N_t\}_{t \in [0, \infty)}$ ma przyrosty niezależne
- iii $\forall 0 \leq s < t N_t(\omega) - N_s(\omega)$ ma rozkład Poissona z parametrem $\lambda(t - s)$

$$\left[\forall_{k \in \{0, 1, 2, \dots\}} P(N(t) - N(s) = k) = \frac{[\lambda(t - s)]^k}{k!} e^{-\lambda(t-s)} \right]$$

Uwaga!

(iii) implikuje, że przyrosty są jednorodne

$$N(t+h) - N(s+h) \sim \text{Poiiss}(\lambda(t+h - (s+h))) = \text{Poiiss}(\lambda(t-s)) \sim N(t) - N(s)$$

Zatem (iii) w połączeniu z (ii) mamy proces o przyrostach stacjonarnych (niezależnych).

Uwaga!

$$\mathbb{E}N(t) = \lambda t$$

$$\text{Var}N(t) = \lambda t$$

Twierdzenie 8

Niech $\{N_t\}_{t \in [0, \infty)}$ będzie procesem liczącym określonym na przestrzeni probabilistycznej (Ω, \mathcal{F}, P) . Wówczas $\{N_t\}_{t \in [0, \infty)}$ jest jednorodnym procesem Poissona z intensywnością $\lambda > 0$ wtedy i tylko wtedy, gdy spełnia

1. $N(0) = 0$ z pr. 1
2. $\{N_t\}_{t \in [0, \infty)}$ ma jednorodne i niezależne przyrosty
- 3.

$$P(N(h) = 1) = \lambda \cdot h + o(h)$$

$$\left[\frac{o(h)}{h} \xrightarrow{h \rightarrow 0} 0 \right]$$

4.

$$P(N(h) \geq 2) = P(N(h) = 2 \vee N(h) = 3 \vee \dots) = o(h)$$

Dowód. \Rightarrow

(i) \equiv (1)

(ii) + (iii) \Rightarrow (2)

$$P(N(h) = 1) \stackrel{(iii)}{=} \frac{(\lambda h)^1}{1!} e^{-\lambda h} = \lambda h e^{-\lambda h}$$

3)

$$P(N(h) = 1) - \lambda h \stackrel{?}{=} o(h)$$

$$\frac{\lambda h e^{-\lambda h} - \lambda h}{h} = \lambda (e^{-\lambda h} - 1) \xrightarrow{h \rightarrow 0} (e^{-\lambda 0} - 1) = 0$$

4)

$$\frac{\frac{P(N(h) \leq 2)}{h}}{\frac{1 - P(N(h) = 0) - P(N(h) = 1)}{h}} \xrightarrow[h \rightarrow 0]{?} 0 \stackrel{(iii)}{=} \frac{1 - e^{-\lambda h} - \lambda h e^{-\lambda h}}{h}$$

Stosując regułę de l'Hospitala

$$\lim_{h \rightarrow 0} \frac{P(N(h) \leq 2)}{h} = \lim_{h \rightarrow 0} \frac{\lambda e^{-\lambda h} - \lambda(e^{-\lambda h} - \lambda h e^{-\lambda h})}{1} = \lim_{h \rightarrow 0} \lambda^2 h e^{-\lambda h} = 0$$

\Leftarrow

(i) \equiv (1)

(2) \Rightarrow (ii)

Jak pokazać (iii)? $P_n(t) = P(N(t) = n) \quad n = 0, 1, 2, \dots$

Etapami

$$P_0(t) = P(N(t) = 0) \stackrel{?}{=} e^{-\lambda t} = \frac{(\lambda t)^0}{0!} e^{-\lambda t}$$

$$\begin{aligned} P_0(t+h) &= P(N(t+h) = 0) = \\ &= P(N(t) = 0 \wedge N(t+h) - N(t) = 0) \stackrel{N(t) \perp\!\!\!\perp N(t+h)}{=} \\ &= P(N(t) = 0) P(N(t+h) - N(t) = 0) \stackrel{(2)}{=} \\ &= P_0(t) \cdot P(N(h) = 0) \stackrel{(3)}{=} \\ &= P_0(t) \cdot (1 - P(N(h) = 1) - P(N(h) \geq 2)) = \\ &= P_0(t) (1 - \lambda h - o(h) - o(h)) = \\ &= P_0(t) - \lambda P_0(t) h - 2o(h) P_0(t) = \\ &= P_0(t) - \lambda P_0(t) h - o(h) \end{aligned}$$

$$\begin{aligned} \frac{P_0(t+h) - P_0(t)}{h} &= -\lambda P_0(t) - \frac{o(h)}{h} \\ P'_0(t) &= -\lambda P_0(t) \end{aligned}$$

z warunkiem $P_0(0) = P(N(0) = 0) = 1$

$$P_0(t) = e^{-\lambda t}$$

$$P_0(0) = P(N(0) = 0) = \frac{(\lambda h)^0}{0!} e^{-\lambda h}$$

Indukcyjnie pokazuje się, że

$$\forall_{n \geq 0} P(N(t) = n) = \frac{(\lambda h)^n}{n!} e^{-\lambda h}$$

Pokazaliśmy, już I krok indukcyjny i formuła zachodzi dla $n=0$.

$$\begin{aligned} P_n(t+h) &= P(N(t+h) = n) = \\ &= P(\{N(t) = n \wedge N(t+h) - N(t) = 0\} \cup \\ &\quad \cup \{N(t) = n-1 \wedge N(t+h) - N(t) = 1\} \cup \\ &\quad \cup \{N(t) < n-1 \wedge N(t+h) - N(t) \geq 2\}) = \\ &= P(N(t) = n \wedge N(t+h) - N(t) = 0) + \\ &\quad + P(N(t) = n-1 \wedge N(t+h) - N(t) = 1) + \\ &\quad + P(N(t) < n-1 \wedge N(t+h) - N(t) \geq 2) \stackrel{(2)}{=} \\ &= P(N(t) = n)P(N(h) = 0) + \\ &\quad + P(N(t) = n-1)P(N(h) = 1) + \\ &\quad + P(N(t) < n-1)P(N(h) \geq 2) = \\ &= P(N(t) = n)P(N(h) = 0) + P(N(t) = n-1)P(N(h) = 1) + o(h) = \\ &= P_n(t)e^{-\lambda h} + P_{n-1}(t)(\lambda h + o(h)) + o(h) = \\ &= P_n(t)(1 - \lambda h + o(h)) + \lambda h P_{n-1}(t) + o(h) = \\ &= P_n(t) - \lambda h P_n(t) + \lambda h P_{n-1}(t) + o(h) \end{aligned}$$

$$\begin{aligned} P_n(t+h) &= P_n(t) - \lambda h P_n(t) + \lambda h P_{n-1}(t) + o(h) \\ \frac{P_n(t+h) - P_n(t)}{h} &= \frac{-\lambda h P_n(t) + \lambda h P_{n-1}(t)}{h} + \frac{o(h)}{h} \end{aligned}$$

Przechodząc $h \rightarrow 0$

$$\begin{aligned} P'_n(t) &= -\lambda P_n(t) + \lambda P_{n-1}(t) \\ P'_n(t) + \lambda P_n(t) &= \lambda P_{n-1}(t) \\ P'_n(t)e^{\lambda t} + \lambda P_n(t)e^{\lambda t} &= \lambda P_{n-1}(t)e^{\lambda t} \\ (P_n(t)e^{\lambda t})' &= \lambda P_{n-1}(t)e^{\lambda t} \quad n = 1, 2, 3, \dots \end{aligned}$$

dla $n = 1$

$$\begin{aligned} (P_1(t)e^{\lambda t})' &= \lambda P_0(t)e^{\lambda t} = \lambda e^{-\lambda t} e^{\lambda t} = \lambda \\ P_1(t)e^{\lambda t} &= \lambda t + C \end{aligned}$$

Warunek początkowy

$$P_1(0) = P(N(0) = 1) = 0$$

daje

$$P_1(0)e^{\lambda 0} = \lambda \cdot 0 + C \Rightarrow C = 0$$

Ostatecznie

$$P_1(t)e^{\lambda t} = \lambda t$$

$$P_1(t) = \frac{(\lambda t)^1}{1!} e^{-\lambda t}$$

W II kroku indukcyjnym założymy, że

$$\left(P_n(t) e^{\lambda t} \right)' = \lambda \frac{(\lambda t)^{n-1}}{(n-1)!} e^{-\lambda t} \cdot e^{\lambda t} = \frac{\lambda^n \cdot t^{n-1}}{(n-1)!}$$

$$P_n(t) e^{\lambda t} = \int \frac{\lambda^n t^{n-1}}{(n-1)!} dt = \frac{\lambda^n t^n}{n!} + C$$

Warunek

$$P_n(0) = P(N(0) = n) = 0 \Rightarrow C = 0$$

Na mocy indukcji matematycznej

$$\forall_{n \geq 0} P(N(t) = n) = P_n(t) = \frac{(\lambda t)^n}{n!} e^{-\lambda t}$$

(iii)

$$P(N(t) - N(s) = n) =$$

$$= P(N(s + (t - s)) - N(s) = n) \stackrel{(2)}{=} \\ = P(N(t - s) = n) = \frac{(\lambda(t - s))^n}{n!} e^{-\lambda(t-s)}$$

□

5.1 Własności trajektorii Procesu Poissona

Fakt 1

Z prawdopodobieństwem 1 trajektoria ma tylko skończenie wiele skoków na każdym skończonym odcinku czasowym $[0, t]$.

A_n - zdarzenie polegające na tym, że na odcinku $[0, n]$ było nieskończenie wiele skoków

A_n - zdarzenie polegające na tym, że na odcinku skończonym było skończenie wiele skoków

$$B^c = \Omega \setminus B = \bigcup_{n=1}^{\infty} A_n$$

$$\begin{aligned} P(A_n) &= \\ &= P(\text{na odcinku } [0, n] \text{ było nieskończenie wiele skoków}) = \\ &= P(\forall_{k \in \mathbb{N}} N(n) \geq k) = \\ &= P\left(\bigcap_{k=1}^{\infty} \{N(n) \geq k\}\right) = \\ &= \lim_{k \rightarrow \infty} P(N(n) \geq k) = \\ &= \lim_{k \rightarrow \infty} P\left(\bigcup_{j=k}^{\infty} N(n) = j\right) = \\ &= \lim_{k \rightarrow \infty} \underbrace{\sum_{j=k}^{\infty} \frac{(\lambda n)^j}{j!} e^{-\lambda n}}_{\text{ogon szeregu zbieżnego}} = 0 \end{aligned}$$

$$\forall_n P(A_n) = 0$$

$$\begin{aligned} 0 &\leq P\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} P(A_n) = 0 \\ P(B^c) &= 0 \Rightarrow P(B) = 1 - P(B^c) = 1 - 0 = 1 \end{aligned}$$

Uwaga!

Jednorodny proces Poissona nie eksploduje (na skończonym odcinku czasu).

Fakt 2

Z prawdopodobieństwem 1 skoki trajektorii są równe 1.

$$P(\{\omega \in \Omega : [0, \infty) \ni t \rightarrow N_t(\omega) \text{ ma skoki równe } 1\}) = 1$$

Zdarzenie przeciwne

$$\begin{aligned} &\{\omega \in \Omega : [0, \infty) \ni t \rightarrow N_t(\omega) \text{ ma skoki } \geq 2\} = \\ &= \bigcup_{n=1}^{\infty} \{\omega \in \Omega : [0, \infty) \ni t \rightarrow N_t(\omega) \text{ ma skoki } \geq 2 \text{ na odcinku } [0, n]\} = \bigcup_{n=1}^{\infty} A_n \end{aligned}$$

$$A_n = \bigcup_{j=0}^{n \cdot m - 1} \left\{ \text{skok} \geq 2 \text{ zdarzył się na } \left(\frac{j}{m}, \frac{j+1}{m} \right] \right\} \leq \bigcup_{j=0}^{n \cdot m - 1} \left\{ N\left(\frac{j+1}{m}\right) - N\left(\frac{j}{m}\right) \geq 2 \right\}$$

$$\begin{aligned} 0 &\leq P(A_n) \leq \sum_{j=0}^{n \cdot m - 1} P\left(N\left(\frac{j}{m} + \frac{1}{m}\right) - N\left(\frac{j}{m}\right) \geq 2\right) \stackrel[\text{jednorodność}]{\text{przyrostu}} \\ &= \sum_{j=0}^{n \cdot m - 1} P\left(N\left(\frac{1}{m}\right) \geq 2\right) = n \cdot m \left(1 - P\left(N\left(\frac{1}{m}\right) = 0\right) - P\left(N\left(\frac{1}{m}\right) = 1\right)\right) = \\ &= n \left(1 - e^{-\frac{1}{m} \cdot \lambda} - \frac{1}{m} e^{-\frac{1}{m} \cdot \lambda}\right) \cdot \frac{1}{\frac{1}{m}} \leq n \cdot \varepsilon \end{aligned}$$

$$\lim_{x \rightarrow 0^+} \frac{1 - e^{-\lambda x} - \lambda x e^{-\lambda x}}{x} \stackrel{\text{"H"}}{=} \lim_{x \rightarrow 0^+} \frac{\lambda e^{-\lambda x} - \lambda e^{-\lambda x} + \lambda^2 x e^{-\lambda x}}{1} = 0$$

Jeśli

$$X < \delta_\varepsilon$$

wtedy

$$\left| \frac{1 - e^{-\lambda x} - \lambda x e^{-\lambda x}}{x} \right| < \varepsilon \text{ dla } \frac{1}{m} < \delta_\varepsilon \left(\equiv \left(m > \frac{1}{\delta_\varepsilon} \right) \right)$$

$$0 \leq P(A_n) \leq \varepsilon \cdot n$$

Zatem $\forall_n P(A_n) = 0$

Stąd

$$P\left(\bigcup_{n=1}^{\infty} A_n\right) = 0$$

$$P(\{\omega \in \Omega : [0, \infty) \ni t \rightarrow N_t(\omega) \text{ ma skok} \geq 2\}) = 0$$

$$P(\{\omega \in \Omega : [0, \infty) \ni t \rightarrow N_t(\omega) \text{ ma skok} = 1\}) = 1$$

Fakt 3

Z prawdopodobieństwem 1 trajektorie dążą do ∞ , gdy $t \rightarrow \infty$

$$P\left(\left\{\omega \in \Omega : \lim_{t \rightarrow \infty} N_t(\omega) = \infty\right\}\right) = 1$$

Zdanie przeciwne

$$\left\{ \omega \in \Omega : \lim_{t \rightarrow \infty} N_t(\omega) < \infty \right\} = \bigcup_{n=1}^{\infty} \left\{ \omega \in \Omega : \lim_{t \rightarrow \infty} N_t(\omega) < n \right\} = \bigcup_{n=1}^{\infty} A_n$$

$$\begin{aligned} A_n &= \left\{ \omega \in \Omega : \forall_{t \in [0, \infty)} N_t(\omega) \leq n \right\} = \\ &= \left\{ \omega \in \Omega : \forall_{k \in \mathbb{N}} N_k(\omega) \leq n \right\} = \\ &= \bigcap_{k=1}^{\infty} \left\{ \omega \in \Omega : N_k(\omega) \leq n \right\} \end{aligned}$$

$$\begin{aligned} P(A_n) &= P\left(\bigcap_{k=1}^{\infty} \{N_k \leq n\}\right) = \\ &= \lim_{k \rightarrow \infty} P(N_k \leq n) = \\ &= \lim_{k \rightarrow \infty} P(N_k = 0 \vee N_k = 1 \vee \dots \vee N_k = n) = \\ &= \lim_{k \rightarrow \infty} \sum_{j=0}^n P(N_k = j) = \\ &= \lim_{k \rightarrow \infty} \sum_{j=0}^n \frac{(\lambda k)^j}{j!} \cdot e^{-\lambda k} = 0 \end{aligned}$$

$$P\left(\bigcup_{n=1}^{\infty} A_n\right) = 0$$

Stąd z prawdopodobieństwem 1

$$\lim_{t \rightarrow \infty} N_t = \infty$$

Twierdzenie 9

Jeżeli $\{N_t\}_{t \in [0, \infty)}$ jest jednorodnym procesem Poissona z intensywnością $\lambda > 0$, to z prawdopodobieństwem 1 trajektorie $[0, \infty) \ni t \rightarrow N_t(\omega)$ są funkcjami schodkowymi, startującymi z 0, o skokach równych 1, o skończenie wielu skokach na każdym odcinku skończonym i dążących do nieskończoności (gdy $t \rightarrow \infty$) i prawostronnie ciągłymi.

Moment skoku \equiv chwila skoku (T_1, T_2, \dots)

Czas oczekiwania na kolejny skok X_1, X_2, \dots "międzyczasy"; "czasypomiędzy"

Twierdzenie 10

Ciąg zmiennych losowych X_1, X_2, \dots dla jednorodnego procesu Poissona z intensywnością $\lambda > 0$ jest ciągiem niezależnym o tym samym rozkładzie $\text{Exp}(\lambda)$.

Dowód.

$$P(X_1 \leq t) = P(N_t \geq 1) = 1 - P(N_t = 0) = 1 - e^{-\lambda t} \quad \text{dla } t \geq 0$$

$F_{X_1}(t) = 1 - e^{-\lambda t}$. Z definicji $X_n \geq 0$.

$$X_1 \sim \text{Exp}(\lambda)$$

□

Rozdział 6

9 listopada 2015

$\{N(t)\}_{t \geq 0}$ jednorodny proces Poissona z intensywnością $\lambda = \text{const} > 0$
 $X_n(\omega)$ zmienna losowa czas pomiędzy $n - 1$ i n -tym zdarzeniem ("międzyczas")
 X_1, X_2, \dots i.i.d. $\sim \text{Exp}(\lambda)$

Dowód. pokazaliśmy, że $X_1 \sim \text{Exp}(\lambda)$
 (X_1, X_2, \dots, X_n) czy składowe są niezależne o rozkładzie $\text{Exp}(\lambda)$?

$$f_{X_1, \dots, X_n}(x_1, \dots, x_n) = (\lambda e^{-\lambda x_1}) \cdot (\lambda e^{-\lambda x_2}) \cdot \dots \cdot (\lambda e^{-\lambda x_n})$$

Wystarczy. Żeby czasy skończyły się na tablicy policzymy dla $n = 2$

$$\begin{aligned} f_{X_1, X_2}(x_1, x_2) & \lim_{\substack{\Delta t_1 \rightarrow 0 \\ \Delta t_2 \rightarrow 0}} \frac{P(X_1 \in (x_1, x_1 + \Delta t_1] \wedge X_2 \in (x_2, x_2 + \Delta t_2])}{\Delta t_1 \cdot \Delta t_2} = \\ & = \lim_{\substack{\Delta t_1 \rightarrow 0 \\ \Delta t_2 \rightarrow 0}} \frac{1}{\Delta t_1 \cdot \Delta t_2} \cdot P(N(x_1) = 0, N(x_1 + \Delta t_1) - N(x_1) = 1, \\ & \quad N(x_1 + x_2) - N(x_1 + \Delta t_1) = 0, N(x_1 + x_2 + \Delta t_2) - N(x_1 + x_2) = 1) = \\ & = \lim_{\substack{\Delta t_1 \rightarrow 0 \\ \Delta t_2 \rightarrow 0}} \frac{1}{\Delta t_1 \cdot \Delta t_2} \cdot P(N(x_1) = 0) P(N(x_1 + \Delta t_1) - N(x_1) = 1) \\ & \quad P(N(x_1 + x_2) - N(x_1 + \Delta t_1) = 0) P(N(x_1 + x_2 + \Delta t_2) - N(x_1 + x_2) = 1)) = \\ & = \lim_{\substack{\Delta t_1 \rightarrow 0 \\ \Delta t_2 \rightarrow 0}} \frac{1}{\Delta t_1 \cdot \Delta t_2} \cdot e^{-\lambda x_1} (\lambda \cdot \Delta t_1)^1 e^{-\lambda \Delta t_1} P(x_2 - \Delta t_1 = 0) \cdot \lambda \Delta t_2 e^{-\lambda \Delta t_2} = \\ & = \lim_{\substack{\Delta t_1 \rightarrow 0 \\ \Delta t_2 \rightarrow 0}} \lambda e^{-\lambda x_1} \cdot e^{-\lambda \Delta t_1} \cdot e^{-\lambda(x_2 - \Delta t_1)} \cdot \lambda e^{-\lambda \Delta t_2} = \\ & = \lambda e^{-\lambda x_1} \cdot \lambda e^{-\lambda x_2} = f_{\text{Exp}(\lambda)}(x_1) f_{\text{Exp}(\lambda)}(x_2) \end{aligned}$$

X_1, X_2 są niezależne i $X_1, X_2 \sim \text{Exp}(\lambda)$

Dla dowolnych $n \in \mathbb{N}$ rozumowanie jest takie samo, jedynie rachunki dłuższe. \square

Wnioski

Niech $T_n = X_1 + \dots + X_n$ czas oczekiwania na n -te zdarzenie. Wówczas T ma rozkład Erlanga z parametrami $\Gamma_{n,\lambda}$

$$f_{T_n}(t) = \frac{\lambda^n \Gamma(n)}{t^{n-1} e^{-\lambda t}}$$

Dowód. Wiemy, że

$$X_j \sim \text{Exp}(\lambda) \Rightarrow X_1 + \dots + X_n \sim \Gamma_{n,\lambda}$$

$t > 0$

$$T_n \leq t \Leftrightarrow N(t) \geq n$$

$$F_{T_n}(t) = P(N(t) \geq n) = \sum_{j=n}^{\infty} \frac{(\lambda t)^j}{j!} e^{-\lambda t}$$

$$\begin{aligned} f_{T_n}(t) &= F'_{T_n}(t) = \\ &= \sum_{j=n}^{\infty} \left(\frac{(\lambda t)^j}{j!} e^{-\lambda t} \right)' = \\ &= \sum_{j=n}^{\infty} \frac{\lambda^{j+1}}{j!} j t^{j+1} e^{-\lambda t} + \sum_{j=n}^{\infty} \frac{\lambda^j t^j}{j!} e^{-\lambda t} = \\ &= \frac{\lambda^{(n-1)+1}}{(n-1)!} t^{n-1} e^{-\lambda t} = \\ &= \frac{\lambda^n}{\Gamma(n)} t^{n-1} e^{-\lambda t} \end{aligned}$$

To rozkład Erlanga z parametrami n, λ

\square

6.1 Statystyki pozycyjne

Y_1, Y_2, \dots, Y_n - zmienne losowe

Permutujemy, aby uzyskać ciąg niemalejący

$$\begin{aligned} \tilde{Y}_1(\omega) &\leq \tilde{Y}_2(\omega) \leq \dots \leq \tilde{Y}_n(\omega) \\ Y_{\alpha(1)}(\omega) &\leq Y_{\alpha(2)}(\omega) \leq \dots \leq Y_{\alpha(n)}(\omega) \end{aligned}$$

Permutacja α zależy od ω

Zakładamy, że zmienne losowe Y_1, \dots, Y_n są typu ciągłego (a nawet absolutnie ciągłego) i niezależne. Z prawdopodobieństwem 1 mamy

$$\tilde{Y}_1(\omega) < \tilde{Y}_2(\omega) < \dots < \tilde{Y}_n(\omega)$$

bo $P(Y_i = Y_j) = 0$ dla $i \neq j$

My założymy dodatkowo, że Y_1, \dots, Y_n mają ten sam rozkład.

Reasumując Y_1, \dots, Y_n i.i.d. z gęstością f_Y

$$\begin{aligned} & f_{(\tilde{Y}_1, \dots, \tilde{Y}_n)}(t_1, \dots, t_n) = \\ &= \lim_{\substack{\Delta t_1 \rightarrow 0 \\ \vdots \\ \Delta t_n \rightarrow 0}} \frac{n! P(Y_1 \in [t_1, t_1 + \Delta t_1), \dots, Y_n \in [t_n, t_n + \Delta t_n))}{\Delta t_1 \cdot \dots \cdot \Delta t_n} = \\ &= n! \lim_{\substack{\Delta t_1 \rightarrow 0 \\ \vdots \\ \Delta t_n \rightarrow 0}} \frac{P(Y_1 \in [t_1, t_1 + \Delta t_1))}{\Delta t_1} \cdot \frac{P(Y_2 \in [t_2, t_2 + \Delta t_2))}{\Delta t_2} \cdot \dots \cdot \frac{P(Y_n \in [t_n, t_n + \Delta t_n))}{\Delta t_n} = \\ &= n! f_{Y_1}(t_1) \cdot f_{Y_2}(t_2) \cdot \dots \cdot f_{Y_n}(t_n) = \\ &= n! \prod_{j=1}^n f_Y(t_j) \end{aligned}$$

$$f_{(\tilde{Y}_1, \dots, \tilde{Y}_n)}(t_1, t_2, \dots, t_n) = \frac{n!}{t^n} \mathbb{1}_{\{0 < t_1 < \dots < t_n < t\}}$$

Twierdzenie 11

Niech $\{N(t)\}_{t \geq 0}$ jednorodny proces Poissona. Wówczas warunkowy rozkład momentu skoku pod warunkiem $N(t) = 1$ jest rozkładem jednostajnym na $[0, t]$.

Dowód.

$$\begin{aligned} & P(X_1 \leq t_1 | N(t) = 1) = \\ &= \frac{P(X_1 \leq t_1 \wedge N(t) = 1)}{P(N(t) = 1)} = \\ &= \frac{P(N(t_1) = 1 \wedge N(t) = 1)}{P(N(t) = 0)} = \\ &= \frac{P(N(t_1) = 1) P(N(t) = 1)}{P(N(t) = 0)} = \\ &= \frac{P(N(t_1) = 1) P(N(t - t_1) = 1)}{P(N(t) = 0)} = \\ &= \frac{\lambda t_1 e^{-\lambda t_1} e^{-\lambda(t-t_1)}}{\lambda t e^{-\lambda t}} = \frac{t_1}{t} \end{aligned}$$

$$F_{X_1|N(t)=1}(x) = \begin{cases} 0 & x \leq 0 \\ \frac{x}{t} & 0 < x < t \\ 1 & x \geq t \end{cases}$$

□

Twierdzenie 12

Rozkład warunkowy wektora momentu skoków (T_1, T_2, \dots, T_n) pod warunkiem zdarzenia $N(t) = n$ ma gęstość $f_{(T_1, \dots, T_n)}(t_1, \dots, t_n) = \frac{n!}{t^n} \mathbb{1}_{\{0 < t_1 < \dots < t_n < t\}}$. Czyli jest taki sam jak rozkład statystyk pozycyjnych dla Y_1, \dots, Y_n i.i.d. na przedziale $[0, t]$.

Dowód. Zobaczmy jak "idzie" dla $n = 2$ $f_{(T_1, T_2)}(t_1, t_2) = ?$

Oczywiście $0 < t_1 < t_2 < t$

$$\begin{aligned} & f_{(T_1, T_2)}(t_1, t_2) = \\ &= \lim_{\substack{\Delta t_1 \rightarrow 0 \\ \Delta t_2 \rightarrow 0}} \frac{P(T_1 \in [t_1, t_1 + \Delta t_1), T_2 \in [t_2, t_2 + \Delta t_2))}{\Delta t_1 \cdot \Delta t_2} = \\ &= \lim_{\substack{\Delta t_1 \rightarrow 0 \\ \Delta t_2 \rightarrow 0}} \frac{P(T_1 \in [t_1, t_1 + \Delta t_1), T_2 \in [t_2, t_2 + \Delta t_2), N(t) = 2)}{\Delta t_1 \cdot \Delta t_2 P(N(t) = 2)} = \\ &= \lim_{\substack{\Delta t_1 \rightarrow 0 \\ \Delta t_2 \rightarrow 0}} \frac{P(N(t_1)=0, N(t_1+\Delta t_1)-N(t_1)=1, N(t_2)-N(t_1+\Delta t_1)=0, N(t_2+\Delta t_2)-N(t_2)=1, N(t)-N(t_2+\Delta t_2)=0)}{\Delta t_1 \cdot \Delta t_2 \frac{(\lambda t)^2}{2!} e^{-\lambda t}} = \\ &= \lim_{\substack{\Delta t_1 \rightarrow 0 \\ \Delta t_2 \rightarrow 0}} \frac{P(N(t_1) = 0) P(N(t_1 + \Delta t_1) - N(t_1) = 1) P(N(t_2) - N(t_1 + \Delta t_1) = 0)}{\Delta t_1 \cdot \Delta t_2 \frac{(\lambda t)^2}{2!} e^{-\lambda t}} \cdot \\ &\quad \cdot P(N(t_2 + \Delta t_2) - N(t_2) = 1) P(N(t) - N(t_2 + \Delta t_2) = 0) = \\ &= \lim_{\substack{\Delta t_1 \rightarrow 0 \\ \Delta t_2 \rightarrow 0}} \frac{e^{-\lambda t_1} \cdot \lambda \Delta t_1 e^{-\lambda \Delta t_1} \cdot e^{\lambda t} \cdot e^{\lambda \Delta t} \cdot e^{-\lambda \Delta t_2} \cdot e^{-\lambda t} \cdot e^{\lambda t_2} \cdot e^{\lambda \Delta t_2}}{\frac{t^2}{2} \cdot e^{-\lambda t}} = \\ &= \frac{2!}{t^2} \mathbb{1}_{\{0 < t_1 < t_2 < t\}} \end{aligned}$$

□

6.2 Niejednorodny proces Poissona

$\lambda(t) \geq 0$ - intensywność pojawiania się zdarzeń zależny od czasu.

Definicja 21 (Niejednorodny proces Poissona)

Mówimy, że proces $\{N(t)\}_{t \geq 0}$ jest niejednorodnym procesem Poissona z funkcją intensywności (deterministyczną) $\lambda : [0, \infty) \rightarrow \mathbb{R}_+$. (ciągła)

- $N(0) = 0$ z pr. 1
- $\{N(t)\}_{t \geq 0}$ ma przyrosty niezależne
- $P(N(t + \Delta t) - N(t) = 1) = \lambda(t) \cdot \Delta t + o(\Delta t)$
- $P(N(t + \Delta t) - N(t) \geq 2) = o(\Delta t)$

Twierdzenie 13

Jeżeli $\{N(t)\}_{t \geq 0}$ jest niejednorodnym procesem Poissona z ciągłą funkcją intensywności $\lambda : [0, \infty) \rightarrow \mathbb{R}_+$, to

$$P(N(s+t) - N(t) = k) = \frac{(\mu(s+t) - \mu(t))^k}{k!} e^{-(\mu(s+t) - \mu(t))}$$

To znaczy

$$\forall s, t > 0 \quad N(s+t) - N(t) \sim \text{Poisson}(\mu(s+t) - \mu(t))$$

gdzie

$$\mu(t) = \int_0^t \lambda(u) du$$

Dowód. Ustalmy t

$$P_k(s) = P(N(t+s) - N(t) = k)$$

$$\text{Czy } P(N(t+s) - N(t) = k) = \frac{(\mu(s+t) - \mu(t))^k}{k!} e^{-(\mu(s+t) - \mu(t))}?$$

Dowód indukcyjnie po k . Rozpoczynamy od $k = 0$

$$\begin{aligned} & P(N(t+s+\Delta s) - N(t+s) = 0 \wedge N(t+s) - N(t) = 0) = \\ & = P(N(t+s+\Delta s) - N(t+s) = 0) P(N(t+s) - N(t) = 0) = \\ & = \left(1 - P(N(t+s+\Delta s) - N(t+s) = 1) + o(\Delta s)\right) \cdot P_0(s) = \\ & = \left(1 - \lambda(t+s)\Delta s + o(\Delta s)\right) \cdot P_0(s) = \\ & = P_0(s) - \lambda(t+s)P_0(s)\Delta s + o(\Delta s) \end{aligned}$$

$$\begin{aligned}
\frac{P_0(s + \Delta t) - P_0(s)}{\Delta s} &= -\lambda(t + s)P_0(s) - \frac{o(\Delta s)}{\Delta s} \\
P'_0(s) &= -\lambda(t + s)P_0(s) \\
\frac{P'_0(s)}{P_0(s)} &= -\lambda(t + s) \\
(\ln P_0(s))' &= -\lambda(t + s) \\
\ln P_0(s) &= -\int_0^s \lambda(t + n) dn \\
\ln P_0(s) &= -\int_t^{t+s} \lambda(n) dn \\
P_0(s) &= \exp\left(-\int_t^{t+s} \lambda(n) dn\right) \\
P_0(s) &= \exp\left(-\int_0^{t+s} \lambda(n) dn + \int_0^t \lambda(n) dn\right) \\
P_0(s) &= e^{-(\mu(t+s) - \mu(t))}
\end{aligned}$$

Dla $k = 1$ formuła zachodzi. Krok indukcyjny robi się tak samo jak w przypadku jednorodnym. \square

Ogólnie
 $\{\tilde{N}(t)\}_{t \geq 0}$ niejednorodny proces Poissona $\supseteq \{N(t)\}_{t \geq 0}$ standardowy proces Poissona (jednorodny z $\lambda = 1$ szczególny przypadek)
 Załóżmy, że $\lambda(u) > 0$, ciągle (ewentualnie $\lambda(0) = 0$)

$$\mu(t) = \int_0^t \lambda(u) du \xrightarrow{t \rightarrow \infty} \int_0^\infty \lambda(u) du = \infty$$

$\mu(t)$ jest funkcją $\mu(0) = 0$, μ ściśle rosnące i klasy $C([0, \infty])$

Twierdzenie 14

Jeśli $\{N(t)\}_{t \geq 0}$ jest niejednorodnym procesem Poissona z funkcją intensywności $\lambda : [0, \infty) \rightarrow \mathbb{R}_+$ ciągłą, $\lambda(u) > 0$ dla $u > 0$ i $\int_0^\infty \lambda(u) du = \infty$, to proces $N(t) \stackrel{df}{=} \tilde{N}(\mu^{-1}(t))$ jest niejednorodnym procesem Poissona z funkcją intensywności

$$\lambda(t) = \mu'(t)$$

Twierdzenie 15

Niech $\{N(t)\}_{t \geq 0}$ będzie standardowym procesem Poissona oraz $\mu : [0, \infty) \rightarrow [0, \infty)$ będzie funkcją klasy C^1 , ściśle rosnącą, $\mu(0) = 0$, $\lim_{t \rightarrow \infty} \mu(t) = \infty$. Wówczas proces $\tilde{N}(t) \stackrel{\text{df}}{=} N(\mu(t))$ jest niejednorodnym procesem Poissona z funkcją intensywności

$$\lambda(t) = \mu'(t)$$

Wniosek

Niejednorodne procesy Poissona powstają przez deterministyczne przeskalowanie czasu w standardowym procesie Poissona.

Naturalnym uogólnieniem są procesy Coxa.

$$N(t + \Delta t) - N(t) = 1 \quad \text{z intensywnością } \lambda_t$$

Dowód.

$$\begin{aligned} \tilde{N}(\mu^{-1}(t)) &= N(t) \\ \tilde{N}(\mu^{-1}(0)) &= N(0) \end{aligned}$$

$N(t)$ jest rosnące, gdyż \tilde{N} jest liczący.

$N(t)$ ma przyrosty niezależne, gdyż \tilde{N} ma przyrosty niezależne

$$\begin{aligned} &P(N(t+s) - N(t) = k) = \\ &= P(\tilde{N}(\mu^{-1}(t+s)) - \tilde{N}(\mu^{-1}(t)) = k) = \\ &= \frac{(\mu(\mu^{-1}(t+s)) - \mu(\mu^{-1}(t)))^k}{k!} = \\ &= e^{-\mu(\mu^{-1}(t+s)) - \mu(\mu^{-1}(t))} = \\ &= \frac{(t+s-t)^k}{k!} e^{-s} \sim Poiss(1) \end{aligned}$$

Niezależność przyrostów $\tilde{N}(\mu^{-1}(t))$ wynika z niezależności przyrostów $\tilde{N}T = (t)$ i faktu, że μ^{-1} jest rosnąca. \square

Rozdział 7

16 listopada 2015

7.1 Złożony proces Poissona

Definicja 22

Niech X_1, X_2, \dots będzie ciągiem niezależnych zmiennych losowych o tym samym rozkładzie, a N zmienną losową o rozkładzie Poissona z intensywnością $\lambda > 0$ i niezależną od X_1, X_2, \dots . Złożonym procesem Poissona nazywamy rozkład zmiennej losowej

$$W = \sum_{j=1}^N X_j$$

Wyjaśnienie dla ustalonego $\omega \in \Omega$

$$W(\omega) = \sum_{j=1}^{n(\omega)} X_j(\omega)$$
$$\sum_{j=0}^0 \blacksquare = 0$$

Zastosowania - ubezpieczenia

Problem - znając rozkłady X_j wyznaczyć rozkład W .

Twierdzenie 16

Przy oznaczeniach z definicji

$$\begin{aligned} \mathbb{E}(W) &= \lambda \cdot \mathbb{E}X_1 & (o ile \mathbb{E}X_1 < \infty) \\ \text{Var}(W) &= \lambda \cdot \mathbb{E}X_1^2 & (o ile \mathbb{E}X_1^2 < \infty) \end{aligned}$$

Dowód. Uprościmy zakładając, że $\mathbb{E}e^{t|X|} < \infty$ dla $t \in (-\infty, \varepsilon]$

$$\begin{aligned}
& \mathbb{E}e^{tW} = \\
&= \int_{\Omega} e^{tW} dP = \\
&= \sum_{k=0}^{\infty} \mathbb{E} \left(e^{tW} | N = k \right) P(N = k) = \\
&= \sum_{k=0}^{\infty} \mathbb{E} \left(\exp \left(t \sum_{j=1}^N X_j \right) | N = k \right) \frac{\lambda^k}{k!} e^{-\lambda} = \\
&= \mathbb{E} \left(\exp \left(t \sum_{j=1}^N X_j \right) | N = 0 \right) e^{-\lambda} + \sum_{k=1}^{\infty} \mathbb{E} \left(\exp \left(t \sum_{j=1}^N X_j \right) | N = k \right) \frac{\lambda^k}{k!} e^{-\lambda} = \\
&= 1 \cdot e^{-\lambda} + \sum_{k=1}^{\infty} \left(\prod_{j=1}^k \mathbb{E} e^{tX_j} \right) \frac{\lambda^k}{k!} e^{-\lambda} = \\
&= e^{-\lambda} + \sum_{k=1}^{\infty} \frac{M_X(t)^k \cdot \lambda^k}{k!} \cdot e^{-\lambda} = \\
&= \left[1 + \sum_{k=1}^{\infty} \frac{(\lambda M_X(t))^k}{k!} \right] e^{-\lambda} = \\
&= \sum_{k=0}^{\infty} \frac{(\lambda M_X(t))^k}{k!} \cdot e^{-\lambda} = \\
&= e^{\lambda M_X(t) - \lambda} = \\
&= e^{\lambda(M_X(t) - 1)} = \\
&= M_W(t)
\end{aligned}$$

Wariancja

$$\begin{aligned}
\mathbb{E}W &= M'_W(0) = e^{\lambda(M_X(0)-1)} \cdot M'_X(0) = e^0 \cdot \lambda \cdot \mathbb{E}X = \lambda \mathbb{E}X \\
\mathbb{E}W^2 &= M''(0) = \lambda^2 e^{\lambda(M_X(0)-1)} M'_X(0)^2 + \lambda e^{\lambda(M_X(0)-1)} M''_X(0) = \\
&= \lambda^2 (\mathbb{E}X)^2 + \lambda \mathbb{E}X^2 \\
\text{Var}(W) &= \mathbb{E}W^2 - (\mathbb{E}W)^2 = \lambda^2 (\mathbb{E}X)^2 + \lambda \mathbb{E}X - (\lambda \mathbb{E}X)^2 = \lambda \mathbb{E}X^2
\end{aligned}$$

□

Uwaga!

Licząc na wprost można pozbyć się tych dodatkowych założeń.

Definicja 23 (Złożony proces Poissona)

Niech X_1, X_2, \dots będzie ciągiem niezależnych zmiennych losowych o tym samym

rozkładzie oraz $\{N(t)\}_{t \geq 0}$ procesem Poissona niezależnym od X_1, X_2, \dots . Złożonym procesem Poissona nazywamy procesem stochastyczny

$$W(t) = \sum_{j=1}^{N(t)} X_j$$

Zastosowania

- $W(t)$ - reprezentowaną kwotę roszczeń
- $N(t)$ - liczba roszczeń napływających do firmy ubezpieczeniowej na odcinku czasu $[0, t]$
- X_j - j -te roszczenie

Winosek

$$\begin{aligned}\mathbb{E}W(t) &= \lambda t \mathbb{E}X_1 \\ \text{Var}W(t) &= \lambda t \mathbb{E}X_1^2\end{aligned}$$

gdy $\{N(t)\}_{t \geq 0}$ jest jednorodnym procesem Poissona

7.1.1 Klasyczny model ryzyka

$$S(t) = \underbrace{u}_{\substack{\text{kapitał} \\ \text{początkowy}}} + \underbrace{c}_{\substack{\text{składka} \\ \text{na jednostkę} \\ \text{ubezpieczenia}}} t - \underbrace{\sum_{j=1}^{N(t)} X_j}_{\substack{\text{zagregowane} \\ \text{roszczenia}}}$$

Problem

Wyznacz $c > 0$ taki, że

$$P(\exists_{t \geq 0} S(t) < 0) \approx 0,0001$$

7.1.2 Dualny model ryzyka

$$W(t) = \underbrace{w}_{\substack{\text{kapitał} \\ \text{początkowy}}} - \underbrace{c}_{\substack{\text{koszt} \\ \text{na jednostkę} \\ \text{czasu}}} t + \underbrace{\sum_{j=1}^{N(t)} X_j}_{\substack{\text{zagregowane} \\ \text{zyski}}}$$

$$P(\exists_{t \geq 0} W(t) < 0) \approx \text{przejęte normy bankowe}$$

7.2 Moment stopu

Niech $\mathcal{F}_0 \subseteq \mathcal{F}_1 \subseteq \dots \subseteq \mathcal{F}$ niemalejący ciąg pod σ -ciał w (Ω, \mathcal{F}, P)

$$\mathbb{F} = (\mathcal{F}_n)_{n \geq 0}$$

nazywamy filtracją

Przykład 5

X_0, X_1, \dots ciąg zmiennych losowych określonych na (Ω, \mathcal{F}, P)

$$\mathcal{F}_n = \sigma(X_j : j \leq n)$$

$\mathbb{F} = (\mathcal{F}_n) = (\sigma(X_j : j \leq n))$ - filtracja naturalna

Definicja 24

Przy ustalonej filtracji $\mathbb{F} = (\mathcal{F}_n)_{n \geq 0}$ mówimy, że zmienna losowa $\tau : \Omega \rightarrow \mathbb{N}_0$ jest momentem stopu (momentem zatrzymania, momentem Markowa), jeśli

$$\forall n \in \mathbb{N}_0 \quad \{\tau = k\} \in \mathcal{F}_n$$

Twierdzenie 17

Przy ustalonej filtracji $\mathbb{F} = (\mathcal{F}_n)_{n \geq 0}$, $\tau : \Omega \rightarrow \mathbb{N}_0$ jest momentem stopu wtedy i tylko wtedy, gdy

$$\forall k \in \mathbb{N}_0 \quad \{\tau = k\} \in \mathcal{F}_k$$

Dowód. " \Rightarrow "

Bardzo ważne uwagi

$$\{\tau \geq k\} \in \mathcal{F}_{k-1}$$

$$\Omega \setminus \{\tau < k\} = \Omega \setminus \bigcup_{j=0}^{k-1} \{\tau = j\} \in \mathcal{F}_{k-1}$$

$$\{\tau = k\} = \{\tau \leq k\} \setminus \{\tau \leq k-1\} \in \mathcal{F}_k$$

" \Leftarrow "

$$\{\tau \leq n\} = \bigcup_{k=0}^n \{\tau = k\} \in \mathcal{F}_n$$

□

Twierdzenie 18 (Tożsamość Walda)

Niech X_1, X_2, \dots będzie ciągiem niezależnych zmiennych losowych o tym samym rozkładzie i skończonej wartości oczekiwanej $\mathbb{E}X_1 \in \mathbb{R}$ oraz τ będzie momentem stopu względem filtracji naturalnej. Wówczas

$$\mathbb{E} \sum_{j=1}^{\tau} X_j = (\mathbb{E}\tau) \cdot (\mathbb{E}X_1)$$

Dowód. (Etap I)

$$\begin{aligned} & \mathbb{E} \sum_{j=1}^{\tau} |X_j| = \\ &= \mathbb{E} \left(\sum_{n=0}^{\infty} \mathbb{1}_{\{\tau=n\}} \cdot \sum_{j=1}^{\tau} |X_j| \right) = \\ &= \mathbb{E} \left(\sum_{n=0}^{\infty} \mathbb{1}_{\{\tau=n\}} \cdot \sum_{j=1}^n |X_j| \right) = \\ &= \mathbb{E} \left(\mathbb{1}_{\{\tau=0\}} \sum_{j=1}^0 |X_j| + \mathbb{1}_{\{\tau=1\}} |X_1| + \dots + \mathbb{1}_{\{\tau=n\}} (|X_1| + |X_2| + \dots + |X_n|) \right) = \\ &= \mathbb{E} \left(0 + \sum_{j=1}^{\infty} \mathbb{1}_{\{\tau=j\}} \cdot |X_1| + \sum_{j=2}^{\infty} \mathbb{1}_{\{\tau=j\}} \cdot |X_2| + \dots + \sum_{j=n}^{\infty} \mathbb{1}_{\{\tau=j\}} \cdot |X_n| + \dots \right) \stackrel{B-L}{=} \\ &= \sum_{n=1}^{\infty} \mathbb{E} \left(\mathbb{1}_{\{\tau \geq n\}} \cdot |X_n| \right) = \\ &= \sum_{n=1}^{\infty} P(\tau \geq n) \mathbb{E}|X_n| = \\ &= \mathbb{E}|X_1| \cdot \sum_{n=1}^{\infty} P(\tau \geq n) = \\ &= (\mathbb{E}\tau) \cdot (\mathbb{E}|X_1|) \end{aligned}$$

(Etap II)

Powtarzamy cały dowód z etapem 1 opuszczając wartość bezwzględną i argumentując zamiast $\stackrel{B-L}{dla \geq 0}$ twierdzeniem Fubiniego

$$\int |f| d\mu_1 \otimes \mu_2 < \infty \Leftrightarrow \int f d\mu_1 \otimes \mu_2 = \int \left[\int f(\dots) d\mu_1 \right] d\mu_2$$

$$\mathbb{E} \left(\sum_{j=1}^{\tau} X_j \right) = \mathbb{E}\tau \cdot \mathbb{E}(X_1)$$

□

7.3 Łańcuchy Markowa

Zajmiemy się łańcuchami Markowa z czasem dyskretnym na skończonej lub przeliczalnej przestrzeni fazowej.

Definicja 25

Niech (Ω, \mathcal{F}, P) będzie przestrzenią probabilistyczną, S zbiór skończony lub przeliczalny z σ -ciałem $\mathcal{G} = 2^S$. Mówimy, że ciąg elementów (zmiennych) losowych $X_1, X_2, \dots, X_n : (\Omega, \mathcal{F}, P) \rightarrow (S, \mathcal{G})$ jest łańcuchem Markowa, jeżeli dla dowolnych $i, j, i_{n-1}, i_{n-2}, \dots, i_0 \in S$ oraz dowolnego $n \in \mathbb{N}_0$

$$P(X_{n+1} = j | X_n = i, X_{n-1} = i_{n-1}, \dots, X_0 = i_0) = P(X_{n+1} = j | X_n = i) = p_{ij}^{[n, n+1]}$$

przy założeniu

$$P(X_n = i, X_{n-1} = i_{n-1}, \dots, X_0 = i_0) > 0$$

$p_{ij}^{[n, n+1]}$ - prawdopodobieństwo przejścia ze stanu $i \in S$ do stanu $j \in S$ przy zmianie czasu z n na $n+1$.

Definicja 26

Jeżeli łańcuch Markowa X_0, X_1, \dots spełnia

$$\forall i, j \in S \forall n \in \mathbb{N}_0 p_{ij}^{[n, n+1]} = p_{ij}$$

to łańcuch Markowa nazywa się jednorodnym (w czasie)

Oznaczenie

$$P^{[n, n+1]} = [p_{ij}^{[n, n+1]}]_{S \times S}$$

nazywa się macierzą prawdopodobieństw przejść z n do $n+1$

Uwaga!

Każdy skończony lub przeliczalny zbiór S można "ponumerować".

$$S = \{s_1, s_2, \dots, s_n\} \qquad S = \{s_1, s_2, \dots\}$$

Można utożsamiać s_j z etykietą j . Można od razu zakładać, że

$$\begin{array}{lll} S = \{1, 2, \dots, N\} & \text{alternatywnie} & S = \{0, 1, \dots, N\} \\ S = \mathbb{N} & \text{alternatywnie} & S = \mathbb{N}_0 \end{array}$$

Zamiast elementów losowych X_1, X_2, \dots mamy zmienne o wartościach w $\mathbb{N}, \mathbb{N}_0, \{1, \dots, N\}$.

Lemat 2

Macierz prawdopodobieństw przejść $P = [p_{ij}]$ spełnia

1. $\forall_{i,j} 0 \leq p_{ij} \leq 1$
2. $\forall_i \sum_j p_{ij} = 1$

Dowód.

1. $p_{ij} = P(X_1 = j | X_0 = i) \in [0, 1]$
- 2.

$$\sum_j p_{ij} = \sum_j P(X_1 = j | X_0 = i) = P\left(\bigcup_{j \in S} \{X_1 = j\} | X_0 = i\right) = P(\Omega | X_0 = i) = 1$$

□

Ostrzeżenie

Fizycy (również w biologii/medycynie)

$$P(X_1 = j | X_0 = i) = p_{j|i} = p_{ij}$$

Definicja 27

Niech X_0, X_1, \dots będzie łańcuchem Markowa $p_{ij}^{[m, m+n]} \stackrel{df}{=} P(X_{m+n} = j | X_m = i)$ prawdopodobieństwo przejścia w n krokach począwszy od chwili m do chwili $m+n$ dla jednorodnego

$$p_{ij}^{\{n\}} \stackrel{df}{=} P(X_{m+n} = j | X_m = i) = P(X_n = j | X_0 = i)$$

$$P^{\{n\}} \stackrel{ozn.}{=} [p_{ij}^{\{n\}}]_{S \times S}$$

Twierdzenie 19

Jeżeli X_0, X_1, \dots jest jednorodnym łańcuchem Markowa o macierzy przejść P , to

$$\forall_{n \in \mathbb{N}} P^{\{n\}} = \underbrace{P \circ P \circ \dots \circ P}_n = P^n$$

Dowód. Indukcja po n

1. Dla $n = 1$

$$p^{\{1\}} = [p_{ij}^{\{1\}}] = [p_{ij}] = P$$

2.

$$\begin{aligned}
p_{ij}^{\{n+1\}} &= \\
&= P(X_{n+1} = j | X_0 = i) = \\
&= \frac{P(X_{n+1} = j, X_0 = i)}{P(X_0 = i)} = \\
&= \frac{P\left(X_{n+1} = j, \bigcup_l^{\Omega} \{X_n = l\}, X_0 = i\right)}{P(X_0 = i)} = \\
&= \sum_l \frac{P(X_{n+1} = j, X_n = l, X_0 = i)}{P(X_0 = i)} = \\
&= \sum_l \frac{P(X_{n+1} = j, X_n = l, X_0 = i)}{P(X_n = l, X_0 = i)} \cdot \frac{P(X_n = l, X_0 = i)}{P(X_0 = i)} = \\
&= \sum_l P(X_{n+1} = j | X_n = l, X_0 = i) \cdot P(X_n = l | X_0 = i) = \\
&= \sum_l P(X_{n+1} = j | X_n = l) \cdot P(X_n = l | X_0 = i) = \\
&= p_{lj} \cdot p_{il}^{\{n\}}
\end{aligned}$$

3. $p_{il}^{\{n\}} = (P^n)_{il}$

$$p_{ij}^{\{n+1\}} = \sum_l \underbrace{p_{il}^{\{n\}}}_{\text{z założenia indukcyjnego}} p_{lj} = \sum_l (P^n)_{il} (P)_{lj} = (P^{n+1})_{ij}$$

□

Twierdzenie 20 (Twierdzenie Chapmana-Kołmogorowa)

Niech x_0, x_1, \dots będzie jednorodnym łańcuchem Markowa o macierzy prawdopodobieństw przejść $P = [p_{ij}]_{S \times S}$. Wówczas dla dowolnych $n, m \geq 0$ oraz stanów $i, j \in S$

$$\begin{aligned}
P(X_{n+m} = j | X_0 = i) &= \sum_l P(X_n = l | X_0 = i) P(X_m = j | X_0 = l) \\
\forall_{i,j \in S} p_{ij}^{\{n+m\}} &= \sum_{l \in S} p_{il}^{\{n\}} p_{lj}^{\{m\}}
\end{aligned}$$

Dowód. $P^{n+m} = P^n \circ P^m$

$$\begin{aligned}
\underbrace{P \circ \dots \circ P}_{n+m \text{ razy}} &= \underbrace{P \circ \dots \circ P}_n \circ \underbrace{P \circ \dots \circ P}_m \\
[P_{ij}^{\{n+m\}}] &= [P_{ij}^{\{n\}}] \circ [P_{ij}^{\{m\}}]
\end{aligned}$$

□

Twierdzenie 21

Niech x_0, x_1, \dots będzie jednorodnym łańcuchem Markowa i $P(X_0 = i) = \mu_i$ ($(\mu_0, \mu_1, \mu_2, \dots)$ rozkład początkowy). Wówczas $\rho_j = P(X_n = j)$ rozkład procesu w chwili n spełnia

$$\rho = (\rho_0, \rho_1, \dots) = (\mu_0, \mu_1, \dots) \circ P^n \quad \left(= \mathcal{L}(X_0) \circ P^n \right)$$

Dowód.

$$P(X_n = j) = \sum_i P(X_n = j | X_0 = i) \underbrace{P(X_0 = i)}_{\mu_i} = \sum_i \mu_i \cdot p_{ij}^{\{n\}} = (\mu \circ P)_j^n$$

$$\mathcal{L}(X_{n+1}) = \mathcal{L}(X_0) \circ P^n$$

□

Rozdział 8

31 listopada 2015

Przykład 6

Niech $\varepsilon_1, \varepsilon_2, \dots$ ciąg zmiennych losowych niezależnych o tym samym rozkładzie, skoncentrowanych na \mathbb{Z} .

$$X_n = \sum_{j=1}^n \varepsilon_j$$
$$\forall_{n \neq 1} P(\varepsilon_n = k) = \mu_k \quad \left(\mu_k \geq 0, \sum_{k=-\infty}^{\infty} \mu_k = 1 \right)$$

$(X_n)_{n \geq 1}$ jest procesem Markowa o przestrzeni stanów $S = \mathbb{Z}$.

$$P(X_{n+1} = j | X_n = i, X_{n-1} = i_{n-1}, \dots, X_1 = i_1) =$$
$$= \frac{P(X_{n+1} = j, X_n = i, X_{n-1} = i_{n-1}, \dots, X_1 = i_1)}{P(X_n = i, X_{n-1} = i_{n-1}, \dots, X_1 = i_1)}$$

$$\frac{P(\varepsilon_{n+1} = j, \varepsilon_n = i, \varepsilon_{n-1} = i_{n-1}, \dots, \varepsilon_1 = i_1)}{P(\varepsilon_n = i, \varepsilon_{n-1} = i_{n-1}, \dots, \varepsilon_1 = i_1)} =$$
$$= \frac{P(\varepsilon_{n+1} = j) P(\varepsilon_n = i) P(\varepsilon_{n-1} = i_{n-1}) \dots P(\varepsilon_1 = i_1)}{P(\varepsilon_n = i) P(\varepsilon_{n-1} = i_{n-1}) \dots P(\varepsilon_1 = i_1)} =$$
$$= P(\varepsilon_{n+1} = j - i) = \mu_{j-i} = p_{i,j}$$

Mamy własność Markowa. Co więcej jest to łańcuch Markowa jednorodny w czasie $[\mu_{(j+l)+(i+l)}]$, ale i jednorodny w przestrzeni.

Jeżeli $\varepsilon_1, \varepsilon_2, \dots$ byłyby niezależne, ale o różnych rozkładach, to $Y_n = X_1 + \dots + X_n$ też jest łańcuchem markowa, ale niejednorodnym.

Twierdzenie 22 (Prawdopodobieństwo ścieżki (path, string, trajektorii))

Niech $(X_n)_{n \geq 0}$ będzie łańcuchem Markowa o macierzy prawdopodobieństw przejść

$$P = [p_{ij}].$$

$$\begin{aligned} & P(X_{n+k} = i_{n+k}, X_{n+k-1} = i_{n+k-1}, \dots, X_n = i_n) = \\ & = P(X_{n+k} = i_{n+k} | X_{n+k-1} = i_{n+k-1}, \dots, X_n = i_n) P(X_{n+k-1} = i_{n+k-1}, \dots, X_n = i_n) \end{aligned}$$

Dowód. $k \geq 0$ indukcyjnie

$$\begin{aligned} & p_{i_{n+k-1}, i_{n+k}} p_{i_{n+k-2}, i_{n+k-1}} \dots p_{i_n, i_{n+1}} \cdot P(X_n = i_n) = \\ & = p_{i_{n+k-1}, i_{n+k}} \cdot P(X_{n+k-1} = i_{n+k-1}, \dots, X_n = i_n) = \\ & = P(X_n = i_n) \cdot \prod_{l=n+1}^{n+k} p_{i_{l-1}, i_l} \end{aligned}$$

W szczególności, gdy $n = 0$

$$\begin{aligned} & P(X_k = i_k, \dots, X_0 = i_0) = \\ & = P(X_0 = i_0) \cdot \prod_{l=1}^k p_{i_{l-1}, i_l} = \\ & = \mu_{i_0} \cdot \prod_{l=1}^k p_{i_{l-1}, i_l} \end{aligned}$$

□

Oznaczenie

$$\mu = (\mu_i)_{i \in S} = \mu^{(0)} = (P(X_0 = i))_{i \in S} = \mathcal{L}(X_0)$$

Rozkład początkowy procesu $(X_n)_{n \geq 0}$

$$\begin{aligned} & P(X_{n+k} = i_{n+k}, \dots, X_{n+1} = i_{n+1} | X_n = i_n, \dots, X_0 = i_0) = \\ & = P(X_{n+k} = i_{n+k}, \dots, X_{n+1} = i_{n+1} | X_n = i_n) \end{aligned}$$

dla dowolnych n, k, i, \dots

Dowód.

$$\begin{aligned} & P(X_{n+k} = i_{n+k}, \dots, X_{n+1} = i_{n+1} | X_n = i_n, \dots, X_0 = i_0) = \\ & = \frac{P(X_{n+k} = i_{n+k}, \dots, X_{n+1} = i_{n+1}, X_n = i_n, \dots, X_0 = i_0)}{P(X_n = i_n, \dots, X_0 = i_0)} = \\ & = \frac{p_{i_{n+k-1}, i_{n+k}} \dots p_{i_0, i_1} \cdot P(X_0 = i_0)}{p_{i_{n-1}, i_n} \dots p_{i_0, i_1} \cdot P(X_0 = i_0)} = \\ & = \prod_{l=0}^{n+k-1} p_{i_l, i_{l+1}} = \\ & = P(X_{n+k} = i_{n+k}, \dots, X_{n+1} = i_{n+1} | X_n = i_n) \end{aligned}$$

□

Własność Markowa (sprzęgająca przeszłość z przyszłością; symetrie przeszłości z przyszłością)

$$\mathcal{F}_{n,\infty} = \sigma(X_n, X_{n+1}, \dots)$$

$$\mathcal{F}_{0,n} = \sigma(X_0, \dots, X_n)$$

$\mathcal{F}_{-\infty,n} = \sigma(\dots, X_{n-1}, X_n)$ Jeżeli proces stochastyczny $(X_n)_{n \geq 0}$ spełnia własność Markowa, to

$$\forall_{\substack{A \in \mathcal{F}_{0,n} \\ B \in \mathcal{F}_{n,\infty}}} P(A \cap B | X_n = i) = P(A | X_n = i) P(B | X_n = i)$$

Warunek Markowa $\equiv \mathcal{F}_{0,n}$ i $\mathcal{F}_{n,\infty}$ są warunkowo X_n niezależne.

Równość wystarczy udowodnić dla

$$A = \{X_0 = i_0, \dots, X_{n-1} = i_{n-1}, X_n = i\}$$

$$B = \{X_n = i, X_{n+1} = i_{n+1}, \dots, X_{n+k} = i_{n+k}\} \in \mathcal{C}_{n,n+k}$$

Dowód.

$$\begin{aligned} & P(A \cap B | X_n = i) = \\ &= \frac{P(A \cap B \cap \{X_n = i\})}{P(X_n = i)} = \\ &= \frac{P(X_{n+k} = i_{n+k}, \dots, X_{n+1} = i_{n+1}, X_n = i, X_{n-1} = i_{n-1}, \dots, X_0 = i_0)}{P(X_n = i, \dots, X_0 = i_0)} \cdot \\ & \cdot \frac{P(X_n = i, \dots, X_0 = i_0)}{P(X_n = i)} = \\ &= P(X_{n+k} = i_{n+k}, \dots, X_{n+1} = i_{n+1}, X_n = i | X_n = i, \dots, X_0 = i_0) \cdot \\ & \cdot P(X_n = i, \dots, X_0 = i_0 | X_n = i) = \\ &= P(A | X_n = i) P(B | X_n = i) \end{aligned}$$

□

8.1 Mocna własność Markowa

Twierdzenie 23 (Mocna własność Markowa)

Niech $(X_n)_{n \geq 0}$ będzie łańcuchem Markowa, jednorodnym o macierzy prawdopodobieństw przejść $P = [p_{ij}]$. Jeżeli T jest momentem Markowa względem filtracji naturalnej) to proces stochastyczny

$$Y_n \stackrel{df}{=} X_{n+T}, \quad n = 0, 1, \dots$$

jest też łańcuchem Markowa o macierzy prawdopodobieństw przejść $[p_{ij}]$.

Dowód.

$$\begin{aligned}
& P(Y_{n+1} = j | Y_n = i, Y_{n-1} = i_{n-1}, \dots, Y_0 = i_0) = \\
& = P(X_{n+1+T} = j | X_{n+T} = i, X_{n-1+T} = i_{n-1}, \dots, X_T = i_0) = \\
& = \frac{P(X_{n+1+T} = j, X_{n+T} = i, X_{n-1+T} = i_{n-1}, \dots, X_T = i_0)}{P(X_{n+T} = i, X_{n-1+T} = i_{n-1}, \dots, X_T = i_0)} = \\
& = \frac{\sum_{k=0}^{\infty} P(X_{n+1+T} = j, X_{n+T} = i, X_{n-1+T} = i_{n-1}, \dots, X_T = i_0, T = k)}{\sum_{k=0}^{\infty} P(X_{n+T} = i, X_{n-1+T} = i_{n-1}, \dots, X_T = i_0, T = k)} = \\
& = \frac{\sum_{k=0}^{\infty} P(X_{n+1+k} = j, X_{n+k} = i, X_{n-1+k} = i_{n-1}, \dots, X_k = i_0, T = k)}{\sum_{k=0}^{\infty} P(X_{n+k} = i, X_{n-1+k} = i_{n-1}, \dots, X_k = i_0, T = k)} =
\end{aligned}$$

Zauważmy, że zachodzi

$$\begin{aligned}
& \{T = k\} \in \sigma\{X_0, X_1, \dots, X_k\} \\
& \{T = k\} = \bigcup_m \underbrace{\{X_k = m_k, \dots, X_0 = m_0\}}_{\text{atom}}
\end{aligned}$$

wykorzystując powyższy opis

$$\begin{aligned}
& \frac{\sum_{k=0}^{\infty} P\left(X_{n+1+k} = j, X_{n+k} = i, X_{n-1+k} = i_{n-1}, \dots, X_k = i_0, \bigcup_m \{X_k = m_k, \dots, X_0 = m_0\}\right)}{\sum_{k=0}^{\infty} P\left(X_{n+k} = i, X_{n-1+k} = i_{n-1}, \dots, X_k = i_0, \bigcup_m \{X_k = m_k, \dots, X_0 = m_0\}\right)} = \\
& = \frac{\sum_{k=0}^{\infty} \sum_m P(X_{n+1+k} = j, X_{n+k} = i, X_{n-1+k} = i_{n-1}, \dots, X_k = i_0, X_k = m_k, \dots, X_0 = m_0)}{\sum_{k=0}^{\infty} \sum_m P(X_{n+k} = i, X_{n-1+k} = i_{n-1}, \dots, X_k = i_0, X_k = m_k, \dots, X_0 = m_0)} = \\
& = \frac{\sum_{k=0}^{\infty} \sum_m P(X_{n+1+k} = j | X_{n+k} = i, X_{n-1+k} = i_{n-1}, \dots, X_k = i_0, X_k = m_k, \dots, X_0 = m_0)}{\sum_{k=0}^{\infty} \sum_m P(X_{n+k} = i, X_{n-1+k} = i_{n-1}, \dots, X_k = i_0, X_k = m_k, \dots, X_0 = m_0)} = \\
& = \frac{P(X_{n+k} = i, X_{n-1+k} = i_{n-1}, \dots, X_k = i_0, X_k = m_k, \dots, X_0 = m_0)}{\sum_{k=0}^{\infty} \sum_m p_{ij} P(X_{n+k} = i, X_{n-1+k} = i_{n-1}, \dots, X_k = i_0, X_k = m_k, \dots, X_0 = m_0)} = \\
& = \frac{\sum_{k=0}^{\infty} \sum_m P(X_{n+k} = i, X_{n-1+k} = i_{n-1}, \dots, X_k = i_0, X_k = m_k, \dots, X_0 = m_0)}{\sum_{k=0}^{\infty} \sum_m P(X_{n+k} = i, X_{n-1+k} = i_{n-1}, \dots, X_k = i_0, X_k = m_k, \dots, X_0 = m_0)} = \\
& = p_{ij} \frac{\sum_{k=0}^{\infty} \sum_m P(X_{n+k} = i, X_{n-1+k} = i_{n-1}, \dots, X_k = i_0, X_k = m_k, \dots, X_0 = m_0)}{\sum_{k=0}^{\infty} \sum_m P(X_{n+k} = i, X_{n-1+k} = i_{n-1}, \dots, X_k = i_0, X_k = m_k, \dots, X_0 = m_0)} = \\
& = p_{ij}
\end{aligned}$$

□

Rozkład początkowy Y_0 ?

$$P(Y_0 = i) = P(X_T = i) = \sum_{k=0}^{\infty} P(X_k = i, T = k)$$

Wniosek


$$P(X_{T+n} = j | X_T) = p_{X_T, j}^{(n)}$$

$$\mathbb{E}(\mathbb{1}_{\{X_{T+n}=j\}} | X_T) = p_{X_T, j}^{(n)}$$

Grafowa wizualizacja łańcucha Markowa

Stany - wierzchołki grafu

Prawdopodobieństwa przejść $[p_{ij}]$ - krawędzie skierowane tylko te, gdzie $p_{ij} > 0$



Definicja 28

Niech $(X_n)_{n \geq 0}$ będzie łańcuchem Markowa. Mówimy, że stan $j \in S$ jest osiągalny ze stanu $i \in S$, jeżeli istnieje $n \geq 0$, że $P(X_n = j | X_0 = i) > 0$.

- $p_{i,j}^{(n)} > 0$
- $p_{i,j}^{[0,n]} > 0$

$p_{i,j}^{[0,n]} > 0$ dla niejednorodnego łańcucha markowa nie Będzie przedmiotem rozważań.

Piszemy wtedy $i \longrightarrow j$ dokładniej $i \xrightarrow{n} j$

$$\equiv P(X_0 = i, X_1 = i_1, \dots, X_{n-1} = i_{n-1}, X_n = j) > 0$$

dla pewnej ścieżki $[i, i_1, i_2, \dots, i_{n-1}, j]$

Definicja 29

Mówimy, że stan $i, j \in S$ komunikują się, gdy $i \longrightarrow j$ oraz $j \longrightarrow i$

$$[p_{ij}^{(n)} > 0 \wedge p_{ji}^{(m)} > 0]$$

Piszemy wtedy

$$i \longleftrightarrow j$$

Twierdzenie 24

Relacja komunikowania się \longleftrightarrow jest relacją równoważności.

Dowód. 1. Zwrotność $i \longleftrightarrow i$

$$p_{ii}^{(0)} = 1 > 0$$

2. Symetria $i \longleftrightarrow j \stackrel{df}{\iff} i \longrightarrow j \wedge j \longrightarrow i$

3. Przechodniość $i \longleftrightarrow j \wedge j \longleftrightarrow k \Rightarrow i \longleftrightarrow k$
 $i \longleftrightarrow k?$

$$i \longrightarrow j \wedge j \longrightarrow k$$

$$p_{ij}^{(n)} > 0 \wedge p_{jk}^{(m)} > 0$$

$$p_{ik}^{(n=k)} \stackrel{GK}{=} \sum_{l \in S} p_{il}^{(n)} p_{lk}^{(m)} \geq p_{ij}^{(n)} p_{jk}^{(m)}$$

Zatem $i \longrightarrow k$. Analogicznie $k \longrightarrow i$.

□

Wniosek.

przestrzeń stanów $S = \dot{\cup} [i]_{/\leftrightarrow}, [i]_{/\leftrightarrow} = \{j \in S : i \longleftrightarrow j\}$

$S_{/\leftrightarrow}$ przestrzeń ilorazowa

Przestrzeń stanów dzieli się na rozłączne klasy. Niektóre klasy są jednoelementowe.

Czasami $[i]_{/\leftrightarrow} = \{i\}$

Definicja 30

Dla ustalonego łańcucha Markowa $(X_n)_{n \geq 0}$ o macierzy prawdopodobieństw przejść $P = [p_{ij}]$ okresem stanu i nazywamy liczbę

$$d(i) = NWD \{n \geq 0 : p_{ij}^{(n)} > 0\} = NWD \{n - m : p_{ij}^{(n)}, p_{ij}^{(m)} > 0\}$$

Uwaga!

Jeżeli $\forall_{n \geq 1} p_{ii}^{(n)} = 0$, to $d(i) = \infty$.

Jeżeli $d(i) = 1$, to stan i nazywamy aperiodycznym.

Przykład 7

$$P(X_{n+1} = j | X_n = i) = \begin{cases} p & j = i + 1 \\ q & j = i - 1 \\ 0 & \text{pozostałe} \end{cases}$$

$$P_{ii}^{(2n)} > 0$$

$$p_{ii}^{(2n+1)} \equiv 0$$

Konkluzja

$$\forall_{i \in \mathbb{Z}} d(i) = d = 2.$$

$$i \longleftrightarrow j \text{ dla dowolnych } i, j \in \mathbb{Z}$$

Definicja 31

Niech $(X_n)_{n \geq 0}$ będzie jednorodnym łańcuchem Markowa. Mówimy, że łańcuch Markowa jest nieprzewiedlny (*irreducible*), jeśli

$$\forall_{i, j \in S} i \longleftrightarrow j.$$

Rozdział 9

7 grudnia 2015

Definicja 32

Niech $(X_n)_{n \geq 0}$ będzie łańcuchem Markowa (z czasem dyskretnym i skończoną lub przeliczalną przestrzenią stanów S). Mówimy, że łańcuch $X_{(n)}_{n \geq 0}$ jest nieprzewiedlny, gdy

$$\forall_{i,j \in S} i \longleftrightarrow j.$$

Twierdzenie 25

Niech $(X_n)_{n \geq 0}$ będzie jednorodnym łańcuchem Markowa (z czasem dyskretnym i skończoną lub przeliczalną przestrzenią stanów S) o macierzy prawdopodobieństw przejść $[p_{ij}]_{S \times S}$. Jeżeli $i \longleftrightarrow j$, to $d(i) = d(j)$.

Przypomnienie: $d(i) = \text{NWD} \{n \geq 0 : p_{ii}^{(n)} > 0\}$

Dowód. $i \longleftrightarrow j$, $p_{ij}^{(n)} > 0$, $p_{ji}^{(m)} > 0$ dla pewnych n, m (myślimy, że $i \neq j$)

$$p_{ii}^{(n+m)} = \sum_{k \in S} p_{ik}^{(n)} p_{kj}^{(m)} \geq p_{ij}^{(m)} > 0$$

$$p_{ii}^{l(n+m)} > 0$$

$$\underbrace{p_{ii}^{(n+m)} \cdot p_{ii}^{(n+m)} \cdots p_{ii}^{(n+m)}}_{l \text{ razy}}$$

$$d(j) = p_{jj}^{(s)} > 0$$

$$p_{ii}^{(n+s+m)} \geq p_{ij}^{(n)} p_{jj}^{(s)} p_{ji}^{(m)}$$

$$p_{ii}^{(n+m)} > 0$$

$$d(i) | n + s + m = n + m + s$$

$d(i)|n+m$

Stąd $d(i)|s$ każde takie s , że $p_{jj}^{(s)} > 0$.

Z teorii podzielności liczb naturalnych $d(i)|d(j)$.

Z symetrii $\longleftrightarrow d(j)|d(i)$.

Ostatecznie $d(i) = d(j)$

□

Winosek

Jeżeli łańcuch Markowa jest nieprzewiedlny, to

$$\forall_{i,j \in S} d(i) = d(j)$$

Oznaczenia:

$(X_n)_{n \geq 0}$ - łańcuch Markowa jednorodny o macierzy prawdopodobieństw przejść

$$P = [p_{ij}]_{S \times S}$$

$$f_{ij}^{(n)} = P(X_1 \neq j, \dots, X_{n-1} \neq j, X_n = j), \quad n \geq 1$$

$$f_{ij} = \sum_{n=1}^{\infty} f_{ij}^{(n)} = \sum_{n=1}^{\infty} P(X_1 \neq j, \dots, X_{n-1} \neq j, X_n = j) =$$

$$= P\left(\bigcup_{n=1}^{\infty} \{X_1 \neq j, \dots, X_{n-1} \neq j, X_n = j\}\right) =$$

$$= P(\exists_{n \geq 1} X_n = j | X_0 = i)$$

Moment Markowa

$$T_{ij} \stackrel{df}{=} \inf \{n \geq 1 : X_n = j, X_0 = i\}$$

Pierwsza chwila uderzenia w stan j .

$$T_j \stackrel{df}{=} \inf \{n \geq 1 : X_n = j\}$$

Ogólnie

$$T_D \stackrel{df}{=} \inf \{n \geq 1 : X_n \in D\}, D \subseteq S \quad \text{hitting time}$$

$$P(T_{ij} < \infty | X_0 = i) = P_i(T_{ij} < \infty) = f_{ij}$$

Definicja 33

Niech $(X_n)_{n \geq 1}$ będzie łańcuchem Markowa z macierzą prawdopodobieństw przejść

$P[p_{ij}]_{S \times S}$. Mówimy, że stan $j \in S$ jest powracający, jeżeli $f_{jj} = 1$.

Mówimy, że stan $j \in S$ jest chwilowy, jeżeli $f_{jj} < 1$.

Twierdzenie 26 (Charakteryzacja stanów powracających)

Niech $(X_n)_{n \geq 0}$ będzie jednorodnym łańcuchem Markowa z macierzą prawdopodobieństw przejść $P = [p_{ij}]_{S \times S}$. Wówczas następujące warunki są równoważne:

1. stan j jest powracający
2. $P(\{\omega \in \Omega : X_n(\omega) = j \text{ dla nieskończenie wielu } n \in \mathbb{N}\} | X_0 = j) = 1$
3. $\sum_{n=1} p_{jj}^{(n)} = \infty$

$$L(\omega) = \# \{n \geq 1 : X_n = j\} = \sum_{n=1}^{\infty} \mathbb{1}_{\{j\}}(X_n(\omega))$$

$$\{L_j \geq 1\} = \{T_j(\omega) < \infty\}$$

$$\{L_j \geq 2\} = \{\exists_{n \geq 1} X_{t_j+n} = j\}$$

$$T_j^{[2]}(\omega) = \inf \{n > T_j(\omega) : X_n(\omega) = j\} \quad \text{chwila drugiego trafienia w } j$$

$$T_j^{[k]}(\omega) = \inf \{n > T_j^{[k-1]}(\omega) : X_n(\omega) = j\} \quad \text{chwila } k\text{-tego trafienia do } j$$

$$f_{jj} = P(T_j < \infty) = P(L_j \geq 1)$$

$$P(L_j \geq 2) = P\left(\exists_{n \geq 1} X_{t_j^{[1]}+n} = j | X_0 = j\right)$$

$$\begin{aligned} T_j^{[1]} &= \sum_{l=1}^{\infty} P\left(\exists_{n \geq 1} X_{T_j^{[1]}+n}(\omega) = j | T_j^{[1]} = l\right) P\left(T_j^{[1]} = l | X_0 = j\right) = \\ &= \sum_{l=1}^{\infty} f_{jj} \cdot P\left(T_j^{[1]} = l | X_0 = j\right) = \\ &= f_{jj} \cdot \sum_{l=1}^{\infty} P\left(T_j^{[1]} = l | X_0 = j\right) = \\ &= f_{jj} \cdot P\left(T_j^{[1]} < \infty | X_0 = j\right) = f_{jj}^2 \end{aligned}$$

W ten sam sposób

$$P(L_j \geq m) = f_{jj}^m$$

Dowód. (1) \Rightarrow (2)

Jeżeli $f_{jj} = 1$, to

$$\forall_{n \in \mathbb{N}} P(L_j \geq m) = f_{jj}^m = 1^m = 1$$

$$P(\{\omega \in \Omega : L_j(\omega) = \infty\}) = P\left(\bigcap_{n=1}^{\infty} \{L_j \geq m\}\right) = \lim_{m \rightarrow \infty} P(L_j \geq m) = 1$$

$$P\left(\left\{\omega \in \Omega : \sum_{n=1}^{\infty} \mathbb{1}_{\{j\}}(X_n(\omega) = \infty)\right\}\right) = P(\{\omega \in \Omega : L_j(\omega) = \infty\}) = 1$$

(2) \Rightarrow (3)

$$\begin{aligned}
& \sum_{n=1}^{\infty} p_{jj}^{(n)} = \\
&= \sum_{n=1}^{\infty} \int_{\Omega} \mathbb{1}_{\{j\}}(X_n) dP_j = \\
&= \sum_{n=1}^{\infty} \mathbb{E}_j \mathbb{1}_{\{j\}}(X_n) = \\
&= \mathbb{E}_j \sum_{n=1}^{\infty} \mathbb{1}_{\{j\}}(X_n) = \\
&= \mathbb{E}_j L_j(\omega) = \infty
\end{aligned}$$

(3) \Rightarrow (1)

Przypuśćmy, że $f_{jj} < 1$.

$$P_j(L_j \geq m) = f_{jj}^m$$

$$\begin{aligned}
\sum_{n=1}^{\infty} P_j(L_j \geq m) &= \sum_{n=1}^{\infty} f_{jj}^m = \frac{f_{jj}}{1 - f_{jj}} < \infty \\
\mathbb{E}_{P_j}(L_j) &= \sum_{n=1}^{\infty} p_{jj}^{(n)} = \infty
\end{aligned}$$

Sprzeczność. □

Lemat 3

$(X_n)_{n \geq 0}$ jednorodny łańcuch Markowa z macierzą prawdopodobieństw przejść $P = [p_{ij}]_{S \times S}$. Jeżeli j jest stanem powracającym oraz $j \longleftrightarrow i$ ($f_{ji} > 0$). Wówczas $f_{ij} = 1$.

Dowód.

$$j \longrightarrow i \Rightarrow \exists_{n_0} p_{ji}^{(n_0)} > 0$$

$P(L_j = \infty | X_0 = j) = 1$. Zatem istnieje $n > n_0$ takie, że $X_n = j$.

$$P(\{\omega \in \Omega : X_n(\omega) = j \text{ dla pewnego } n > n_0 | X_0 = j\}) = 1$$

$$\begin{aligned}
1 &= P_j(\exists_{n > n_0} X_n = j) = \\
&= \sum_{l \in S} P(\exists_{n > n_0} X_n = j | X_{n_0} = l) P_j(X_{n_0} = l) = \\
&= \sum_{l \in S} P_j(\exists_{n \geq 1} X_{n+n_0} = j | X_{n_0} = l) p_{jl}^{(n_0)} = \\
&= \sum_{l \in S} f_{ij} p_{jl}^{(n_0)}
\end{aligned}$$

$$\begin{aligned}
1 - \sum_{l \in S} f_{ij} p_{jl}^{(n_0)} &= \\
&= \sum_{l \in S} p_{jl}^{(n_0)} - \sum_{l \in S} f_{ij} p_{jl}^{(n_0)} = \\
&= \sum_{l \in S} \underbrace{p_{jl}^{(n_0)}}_{\geq 0} \underbrace{(1 - f_{ij})}_{\geq 0}
\end{aligned}$$

Jeżeli $p_{jl}^{(n_0)} > 0$, to $1 - f_{ij} = 0$

Właśnie $j \longrightarrow i$ spełnia $p_{ji}^{(n_0)} > 0$ zatem ostatecznie $f_{ij} = 1$ □

Lemat 4

Niech $(X_n)_{n \geq 0}$ będzie jednorodnym łańcuchem Markowa o macierzy prawdopodobieństw przejść $P = [p_{ij}]$. Jeżeli $j \in S$ jest stanem chwilowym to dla dowolnego $i \in S$

$$\sum_{n=1}^{\infty} p_{ij}^{(n)} < \infty$$

co implikuje

$$\lim_{n \rightarrow \infty} p_{ij}^{(n)} = 0$$

Dowód. Ustalmy $i \in S$. Jeżeli $\forall_{n \geq 1} p_{ij}^{(n)} = 0$ (tzn. $\neg(i \longleftrightarrow j)$), to oczywiście

$$\sum_{n=1}^{\infty} p_{ij}^{(n)} = \sum_{n=1}^{\infty} 0 = 0$$

Zatem będziemy rozpatrywali przypadek $\exists_{n \geq 1} p_{ij}^{(n)} > 0$.

$$\begin{aligned}
p_{ij}^{(n)} &= P(X_n = j | X_0 = i) = \\
&= \frac{P(X_n = j, X_0 = i)}{P(X_0 = i)} = \\
&= \frac{P(\{X_n = j\} \cap \{T_j \leq n\} \cap \{X_0 = i\})}{P(X_0 = i)} = \\
&= \frac{P\left(\{X_n = j\} \cap \bigcup_{k=1}^{\infty} \{T_j = k\} \cap \{X_0 = i\}\right)}{P(X_0 = i)} = \\
&= \sum_{k=1}^n \frac{P(\{X_n = j\} \cap \{X_1 \neq j, \dots, X_{k-1} \neq j, X_k = j\} \cap \{X_0 = i\})}{P(X_0 = i)} = \\
&= \sum_{k=1}^n \frac{P(X_n = j | X_k = j, X_{k-1} \neq j, \dots, X_0 = i)}{P(X_0 = i)} P(X_k = j, X_{k-1} \neq j, \dots, X_0 = i) = \\
&= \sum_{k=1}^n p_{jj}^{(n-k)} f_{ij}^{[k]} = p_{ij}^{(n)}
\end{aligned}$$

W ostatnim przejściu pamiętamy, że $\sum_{n=0}^{\infty} p_{jj}^{(n)} < \infty$

$$\begin{aligned} \sum_{n=1}^{\infty} p_d^{(n)} &= \sum_{n=1}^{\infty} \left(\sum_{k=1}^n f_{ij}^{[k]} p_{jj}^{(n-k)} \right) = \\ &= \sum_{k=1}^{\infty} f_{ij}^{[k]} \sum_{n=k}^{\infty} p_{jj}^{(n-k)} = \\ &= \left(\sum_{n=1}^{\infty} p_{jj}^{(n)} \right) \sum_{k=1}^{\infty} f_{ij}^{[k]} < \infty \end{aligned}$$

$$\sum_{n=1}^{\infty} p_{ij}^{(n)} < \infty$$

□

Wniosek

Jeżeli przestrzeń stanów S dla jednorodnego łańcucha Markowa $(X_n)_{n \geq 0}$ jest skończona ($\#S < \infty$), to istnieje co najmniej jeden stan powracający.

Dowód. Przypuśćmy, że wszystkie stany są chwilowe.

$$\forall i \in S \forall j \in S \sum_{n=0}^{\infty} p_d^{(n)} = \rho_{ij} < \infty$$

$$\begin{aligned} \sum_{j \in S} \sum_{i \in S} \sum_{n=0}^{\infty} p_d^{(n)} &= \sum_{i,j \in S} \rho_{ij} < \infty \\ \sum_{n=0}^{\infty} \sum_{i \in S} \sum_{j \in S} p_d^{(n)} &= \sum_{n=0}^{\infty} (\#S \cdot 1) = \infty \end{aligned}$$

□

Uwaga!

Może się zdarzyć, że dla $\#S = \infty$ nie ma w ogóle stanów powracających.

Oznaczenia

Część konserwatywna procesu $(X_n)_{n \geq 0}$

$$C = \{j \in S : j \text{ jest stanem powracającym}\} = \left\{ j \in S : \sum_{n=1}^{\infty} p_{jj}^{(n)} = \infty \right\}$$

Część dysypatywna procesu $(X_n)_{n \geq 0}$

$$D = \{j \in S : p_{jj}^{(n)} \rightarrow 0\}$$

Definicja 34

Niech $(X_n)_{n \geq 0}$ będzie jednorodnym łańcuchem Markowa na przestrzeni stanów S o macierzy prawdopodobieństw przejść $P = [p_{ij}]_{S \times S}$. Mówimy, że $A \subseteq S$ jest zamknięty (niezmienniczy), jeśli spełnia

$$\forall i \in A \forall j \notin A \ p_{ij} = 0$$

Inaczej

$$P \mathbb{1}_A(i) = \sum_{j \in A} p_{ij} = \sum_{j \in A} \mathbb{1}_A(j) p_{ij}$$

Twierdzenie 27

Część konserwatywna procesu jest zbiorem zamkniętym.

Dowód. Niech $i \in C$ oraz $i \longleftrightarrow j$. Przypuśćmy $p_{ij}^{(n_0)} > 0$. Wtedy $f_{ij} = 1$ z lematu.

$$\exists_{n_0 \geq 1} p_{ij}^{(n_0)} > 0$$

$$\begin{aligned} \sum_{k=1}^{\infty} p_{jj}^{(k)} &\geq \\ &\geq \sum_{k=m_0+n_0+1}^{\infty} p_{jj}^{(k)} \geq \\ &\geq \sum_{k=m_0+n_0+1}^{\infty} p_{ji}^{(m_0)} p_{ii}^{(k-n_0-m_0)} p_{ij}^{(n_0)} = \\ &= \underbrace{p_{ji}^{(m_0)}}_{\geq 0} \sum_{l=1}^{\infty} \underbrace{p_{ii}^{(l)}}_{\infty} \underbrace{p_{ij}^{(n_0)}}_{\geq 0} = \infty \end{aligned}$$

□

Rozdział 10

14 grudnia 2015

Komentarz związany z kolokwium

$\{N(t)\}_{t \geq 0}$ jednorodny proces Poissona z intensywnością $\lambda > 0$

$\text{cov}(N(t), N(s)) = \lambda(t \wedge s) = \lambda \cdot \min\{s, t\}$

$\mathbb{E}(N(t) \cdot N(s)) = \text{cov}(N(t), N(s)) + \mathbb{E}N(t)\mathbb{E}N(s) = \lambda \cdot \min\{s, t\} + \lambda s \cdot \lambda t$ dla $t \geq s$

$\mathbb{E}(N(t) \cdot N(s)) = \mathbb{E}((N(t) \cdot N(s)) \cdot N(s) + N(t)^2)$ koniec komentarza

Niech $(X_n)_{n \geq 0}$ będzie jednorodnym łańcuchem Markowa z macierzą prawdopodobieństw przejść $P = [p_{ij}]$. Oznaczmy

$$\tau_j = \begin{cases} \min\{n \geq 1 : X_n(\omega) = j\} \\ \infty, \text{ jeżeli } \forall_{n \geq 1} X_n(\omega) \neq j \end{cases}$$

moment Markowa.

$$m_{jj} = \mathbb{E}_j(\tau_j) = \sum_{n=1}^{\infty} n \cdot f_{jj}^{[n]} = \int_{\Omega} \tau_j dP(\cdot | X_0 = j)$$

Przypomnienie

$$f_{jj}^{[n]} = P(X_1 \neq j, \dots, X_{n-1} \neq j, X_n = j | X_0 = j)$$

Definicja 35

Mówimy, że stan $j \in C$ jest dodatnio powracający, jeżeli $m_{jj} < \infty$.

Mówimy, że stan $j \in C$ jest 0 powracający, jeżeli $m_{jj} = \infty$.

Uwaga!

Oczywiście, jeżeli $j \in D = S \setminus C$ to $P_j(\tau_j = \infty) > 0$. Zatem

$$\forall_{j \in D} m_{jj} = \infty$$

Definicja 36

Mówimy, że miara probabilistyczna μ na $(S, 2^S)$ jest niezmiennicza (stacjonarna) dla j łańcucha Markowa $(X_n)_{n \geq 0}$ o macierzy prawdopodobieństw przejść P , jeżeli

$$\begin{aligned} \forall_{j \in S} \sum_{i \in S} \mu_i \cdot p_{ij} &= \mu_j \\ \underline{\mu} \circ P &= \underline{\mu} \end{aligned}$$

$$\begin{aligned} \mathcal{P}(S) \ni \underline{\mu} &\rightarrow \underline{\mu} \circ P \in \mathcal{P}(S) \\ (\mu_0, \mu_1, \mu_2, \dots) \circ \begin{bmatrix} p_{0,0} & p_{0,1} & \dots \\ p_{1,0} & p_{1,1} & \dots \\ \vdots & \vdots & \ddots \end{bmatrix} &= (\mu_0, \mu_1, \mu_2, \dots) \end{aligned}$$

Uwaga!

Niech X_0 ma rozkład $\underline{\mu} [P(X_0 = i) = \mu_i]$. Rozkład x_1 ?

$$P(X_1 = j) = \sum_{i \in S} P(X_1 = j | X_0 = i) P(X_0 = i) = \sum_{i \in S} \mu_i \cdot p_{ij} = \underline{\mu} \circ P$$

$$\begin{aligned} \underline{\mu} &\text{ rozkład } X_0 \\ \underline{\mu} \circ P &\text{ rozkład } X_1 \\ \underline{\mu} \circ P^2 &\text{ rozkład } X_2 \end{aligned}$$

Twierdzenie 28

Niech $(X_n)_{n \geq 0}$ będzie jednorodnym łańcuchem Markowa o macierzy prawdopodobieństw przejść $P = [p_{ij}]_{S \times S}$. Jeżeli $r \in C$ jest stanem dodatnio powracającym, wówczas istnieje dokładnie jedna miara probabilistyczna niezmiennicza π o własności $\pi_r > 0$. Co więcej

$$\pi_r = \begin{cases} \frac{1}{m_{rr} = \mathbb{E}_r \tau_r}, & j = r \\ 0, & j \notin [r] \\ \frac{1}{\mathbb{E}_r \tau_r} \cdot \left(1 + P_{r_j} + \sum_{n=1}^{\infty} \sum_{i_1, \dots, i_n \in S \setminus \{r\}} p_{ri_1} \cdot p_{i_1 i_2} \cdot \dots \cdot p_{i_n-1 j}\right), & j \in [r] \wedge j \neq r \end{cases}$$

Wniosek

$$\begin{aligned} C &= C_+ \cup C_0 \\ C_+ &= \{r \in C : \mathbb{E}_r \tau_r < \infty\} = \{j \in C : \mu_j > 0 \text{ dla pewnej } \underline{\mu} \circ P = \underline{\mu}\} \end{aligned}$$

Twierdzenie 29

Niech $(X_n)_{n \geq 0}$ będzie jednorodnym łańcuchem Markowa na przestrzeni stanów S o macierzy prawdopodobieństw przejść $P[p_{ij}]$. Łańcuch $(X_n)_{n \geq 0}$ jest stacjonarny wtedy i tylko wtedy, gdy $\mu^{(0)} = \mathcal{L}(X_0)$ rozkład początkowy jest miarą niezmienniczą.

Dowód. \Rightarrow Ze stacjonarności $(X_0, X_1, \dots, X_n) \sim (X_1, X_2, \dots, X_{n+1})$. $\mathcal{L}(X_0) = \mathcal{L}(X_1)$. Ale pamiętamy, że $\underline{\mu}^{(1)} = \underline{\mu}^{(0)} \circ P$, czyli mamy $\underline{\mu}^{(0)} = \mu^{(0)} \circ P$. **Uwaga!**

Iterując $\underline{\mu}^{(n)} = \underline{\mu}^{(0)} \circ P^n$ dla dowolnego $n \geq 0$

\Leftarrow

Założmy, że $\underline{\mu}^{(0)} = \underline{\mu}^{(0)} \circ P$.

$\mu_{(X_0, \dots, X_n)} = \mu_{(X_k, \dots, X_{n+k})}$ dla dowolnego $k = 1, 2, \dots$?

$$P(X_0 = i_0, X_1 = i_1, \dots, X_n = i_n) = P(X_k = i_0, X_{k+1} = i_1, \dots, X_{k+n} = i_n)$$

dla dowolnego wyboru $i_0, i_1, \dots, i_n \in S$

$$\begin{aligned} & P(X_0 = i_0) p_{i_0 i_1} \cdot p_{i_1 i_2} \cdot \dots \cdot p_{i_{n-1} i_n} \\ & P(X_k = i_0) p_{i_0 i_1} \cdot p_{i_1 i_2} \cdot \dots \cdot p_{i_{n-1} i_n} \\ & P(X_k = i_0) = (\underline{\mu}^{(0)} \circ P^k)_{i_0} = \mu_{i_0}^{(0)} = P(X_0 = i_0) \end{aligned}$$

Stąd $P(X_0 = i_0) p_{i_0 i_1} \cdot p_{i_1 i_2} \cdot \dots \cdot p_{i_{n-1} i_n} = P(X_k = i_0) p_{i_0 i_1} \cdot p_{i_1 i_2} \cdot \dots \cdot p_{i_{n-1} i_n}$ dla dowolnego $k \geq 0$. Czyli otrzymaliśmy stacjonarność X_0, X_1, \dots \square

Twierdzenie 30

Niech $(X_n)_{n \geq 0}$ będzie jednorodnym łańcuchem Markowa z macierzą prawdopodobieństw przejść $P = [p_{ij}]$. Wówczas

1.

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{k=1}^n p_{jj}^{(k)} = \frac{1}{m_{jj}}$$

2.

$$\lim_{n \rightarrow \infty} p_{jj}^{(n)} = \frac{1}{m_{jj}}$$

jeżeli dodatkowo założymy, że j jest aperiodyczny

3.

$$\lim_{n \rightarrow \infty} p_{jj}^{(n)} = \frac{d}{m_{jj}}$$

jeżeli dodatkowo założymy, że $d(j) = d$.

Uwaga!

Powyższe twierdzenie nosi nazwę średniego twierdzenia ergodycznego na l^1 .

PROCES RUCHU BROWNA

Intuicyjne wprowadzenie w teorię procesów ruchu Browna (procesów Wienera).

X_1, \dots ciąg niezależnych zmiennych losowych o tym samym rozkładzie takich, że

$$P(X_k = -1) = P(X_k = 1) = \frac{1}{2}$$

$$X_t^{\Delta x} = \Delta x \cdot X_1 + \Delta x \cdot X_2 + \dots \Delta x \cdot X_{\lfloor \frac{t}{\Delta t} \rfloor} \text{ dla } t \geq 0$$

Spacer losowy o skokach $\pm \Delta x$

$$\mathbb{E} X_t^{\Delta x} = \sum_{j=1}^{\lfloor \frac{t}{\Delta t} \rfloor} \mathbb{E} \Delta x \cdot X_j = 0$$

$$\text{Var} X_t^{\Delta x} = \sum_{j=1}^{\lfloor \frac{t}{\Delta t} \rfloor} \text{Var} (\Delta x \cdot X_j) = \Delta x^2 \cdot \left\lfloor \frac{t}{\Delta t} \right\rfloor \cdot 1$$

Dobieramy $\Delta x, \Delta t$

Rozdział 11

21 grudnia 2015

$X_t^{\Delta x} = \Delta x \cdot X_1 + \dots + \Delta x \cdot X_{\lfloor \frac{t}{\Delta t} \rfloor}$, X_1, X_2, \dots - i.i.d.

$X_j \in \{-1, 1\}$

$P(X_j = 1) = P(X_j = -1) = \frac{1}{2}$

$$X_t^{\Delta x} \xrightarrow[\Delta x \rightarrow 0^+]{\Delta t \rightarrow 0^+} ?$$

Założmy, że $\Delta x = c\sqrt{\Delta t}$

$c > 0$ - stała

$$\begin{aligned} & \frac{\Delta x \cdot X_1 + \dots + \Delta x \cdot X_{\lfloor \frac{t}{\Delta t} \rfloor}}{\sqrt{\lfloor \frac{t}{\Delta t} \rfloor} \Delta x} \xrightarrow{\mathcal{D}} \mathfrak{X} \sim \mathcal{N}(0, 1) \\ & \Delta x \cdot X_1 + \dots + \Delta x \cdot X_{\lfloor \frac{t}{\Delta t} \rfloor} = \\ & = \sqrt{\lfloor \frac{t}{\Delta t} \rfloor} \Delta x^2 \cdot \frac{\Delta x \cdot X_1 + \dots + \Delta x \cdot X_{\lfloor \frac{t}{\Delta t} \rfloor}}{\sqrt{\lfloor \frac{t}{\Delta t} \rfloor} \Delta x} \xrightarrow{\mathcal{D}} \mathcal{N}(0, c^2 t) \\ & \left(\frac{t}{\Delta t} - 1 \right) \Delta x^2 \leq \left\lfloor \frac{t}{\Delta t} \right\rfloor \Delta x^2 \leq \frac{t \Delta x^2}{\Delta t} \end{aligned}$$

Definicja 37

Dla $t \geq 0$ niech

$$X_t \stackrel{df}{=} \lim_{\substack{\Delta t \rightarrow 0 \\ \Delta x = c\sqrt{\Delta t}}} X_t^{\Delta x}$$

Wniosek

$$X_t \sim \mathcal{N}(\mu = 0, \text{Var} = c^2 t)$$

$$\underbrace{\Delta x X_1 + \dots + \Delta x X_{\lfloor \frac{s}{\Delta t} \rfloor}}_{X_s} + \underbrace{\Delta x X_{\lfloor \frac{s}{\Delta t} \rfloor + 1} + \dots + \Delta x X_{\lfloor \frac{t}{\Delta t} \rfloor}}_{X_{t-s}} \rightarrow X_t$$

$$X_s \sim \mathcal{N}(0, c^2 s)$$

$$X_{t-s} \sim \mathcal{N}(0, c^2 (t-s))$$

$X_t - X_s$ ten sam rozkład co X_{t-s} oraz $X_{t-s} \perp\!\!\!\perp X_s$

Otrzymany proces jest procesem o przyrostach niezależnych, jednorodnych. Mała kolizja oznaczeń; proces graniczny oznaczamy $\{X_t\}_{t \geq 0}$ i wyjściowy ciąg Bernoulliego niestety oznaczamy X_1, X_2, \dots

Definicja 38

Mówimy, że proces stochastyczny $\mathfrak{X} = \{X_t\}_{t \geq 0}$ jest procesem ruchu Browna, jeżeli spełnia

1. $X_0 = 0$ z pr. 1
2. $\{X_t\}_{t \geq 0}$ jest procesem o przyrostach niezależnych i jednorodnych
3. $\forall t \geq 0 \quad X_t \sim \mathcal{N}(0, c^2 t)$
4. Trajektorie $X_t(\omega)$ są funkcjami ciągłymi (zmiennej t) dla P prawie wszystkich $\omega \in \Omega$

Pytanie

Czy taki proces stochastyczny istnieje?

Heurystycznie pokazaliśmy, że atk.

Tak, istnieje (dowód pełny podał Wiener; w latach 60 piękny dowód istnienia podał Z. Ciesielski (Sopot, IMPAN))

Uwaga!

(10),(2),(3) implikuje (4) [z dokładnością do wersji]

Od tej pory będziemy zakładali $c = 1$.

Standardowy proces ruchu Browna ma rozkłady $X_t \sim \frac{1}{\sqrt{2\pi t}} e^{-\frac{x^2}{2t}}$. $\text{Var} X_t = t$

Definicja 39

Mówimy, że proces stochastyczny $\{Y_t\}_{t \geq 0}$ określony na (Ω, \mathcal{F}, P) i wartościach w przestrzeni fazowej (stanów) $(S < \mathcal{G})$ jest procesem Markowa, jeżeli

$$\forall n \in \mathbb{N} \forall Y_{n-1}, Y_{n-2}, \dots, Y_0 \in S \forall B \in \mathcal{G} \forall t_n > t_{n-1} > \dots > t_0$$

zachodzi warunek Markowa

$$P(Y_{t_n} \in B | Y_{t_{n-1}} = y_{n-1}, Y_{t_{n-2}} = y_{n-2}, \dots, Y_{t_0} = y_0) = P(Y_{t_n} \in B | Y_{t_{n-1}} = y_{n-1})$$

$$F_{Y_{t_n} | Y_{t_{n-1}} = y_{n-1}, Y_{t_{n-2}} = y_{n-2}, \dots, Y_{t_0} = y_0} = F_{Y_{t_n} | Y_{t_{n-1}} = y_{n-1}}$$

Oznaczenie

$$P(Y_t \in B | Y_s = y) = P^{[s,t]}(y, B) \quad 0 \leq s < t$$

funkcja prawdopodobieństwa przejścia. Czas ciągły i przestrzeń stanów (może być ciągła).

Twierdzenie 31

Proces ruchu Browna jest procesem Markowa.

Dowód. Ustalmy $n \in \mathbb{N}$, $t_0 < t_1 < \dots < t_{n-1} < t_n$, $y_0, y_1, \dots, y_{n-1} \in \mathbb{R}$, $B \in \mathfrak{B}_{\mathbb{R}}$ □

$$\begin{aligned} & P(X_{t_n} \in B | X_{t_{n-1}} = y_{n-1}, \dots, X_{t_0} = y_0) = \\ & = P(X_{t_n} - X_{t_{n-1}} \in B - y_{n-1} | X_{t_{n-1}} - X_{t_{n-2}} = y_{n-1} - y_{n-2}, \dots, X_{t_1} - X_{t_0} = y_1 - y_0, \\ & \quad X_{t_0} = y_0) \end{aligned}$$

Niezależność przyrostów

$$\begin{aligned} & P(X_{t_n} - X_{t_{n-1}} \in B - y_{n-1}) = \\ & = \int_{B - y_{n-1}} \frac{1}{\sqrt{2\pi(t_n - t_{n-1})}} \exp\left(-\frac{x^2}{2(t_n - t_{n-1})}\right) dx = \\ & = \int_{B - y_{n-1}} \frac{1}{\sqrt{2\pi(t_n - t_{n-1})}} \exp\left(-\frac{(x - y_{n-1})^2}{2(t_n - t_{n-1})}\right) dx = \\ & = P^{[t_{n-1}, t_n]}(y_{n-1}, B) \end{aligned}$$

$$\mathbb{E}(\mathbb{1}_{\{X_{t_n} \in B\}} | X_{t_{n-1}}, \dots, X_{t_0}) \stackrel{?}{=} \mathbb{E}(\mathbb{1}_{\{X_{t_n} \in B\}} | X_{t_{n-1}})$$

$$\begin{aligned} & P(X_{t_n} \in B | X_{t_{n-1}} = y_{n-1}) = \\ & = P(X_{t_n} - y_{n-1} \in B - y_{n-1} | X_{t_{n-1}} - X_0 = y_{n-1} - 0) = \\ & = P(X_{t_n} - y_{n-1} \in B - y_{n-1} | X_{t_{n-1}} - X_0 = y_{n-1}) \end{aligned}$$

Niezależność przyrostów $X_{t_n} - X_{t_{n-1}} \perp\!\!\!\perp X_{t_{n-1}} - X_0$

$$\begin{aligned}
& P(X_{t_n} - y_{n-1} \in B - y_{n-1}) = \\
& = P(X_{t_n - t_{n-1}} \in B - y_{n-1}) = \\
& = \int_{B - y_{n-1}} \frac{1}{\sqrt{2\pi(t_n - t_{n-1})}} \exp\left(-\frac{x^2}{2(t_n - t_{n-1})}\right) dx = \\
& = \int_B \frac{1}{\sqrt{2\pi(t_n - t_{n-1})}} \exp\left(-\frac{(x - y_{n-1})^2}{2(t_n - t_{n-1})}\right) dx
\end{aligned}$$

Dygresja formalna

$$\mathbb{E}\left(\mathbb{1}_{\{X_{t_n} \in B\}} | X_{t_{n-1}}, \dots, X_{t_0}\right) = P^{[t_{n-1}, t_n]}(X_{t_{n-1}, B})$$

Twierdzenie 32

Jeżeli $\{B_t\}_{t \in [0, \infty)}$ jest standardowym procesem ruchu Browna to

$$\text{cov}(B_s, B_t) = s \wedge t \quad (= \min\{s, t\})$$

Dowód.

$$\begin{aligned}
& \text{cov}(B_s, B_t) = \\
& = \mathbb{E}B_s B_t - \mathbb{E}B_s \mathbb{E}B_t = \\
& = \mathbb{E}B_s B_t \stackrel{s=s \wedge t}{=} \\
& = \mathbb{E}((B_t - B_s + B_s) B_s) = \\
& = \mathbb{E}((B_t - B_s) B_s + B_s^2) = \\
& = \mathbb{E}((B_t - B_s) B_s) + \mathbb{E}B_s^2 = \\
& = \mathbb{E}(B_t - B_s) \mathbb{E}(B_s) + \text{Var}B_s^2 = s = s \wedge t
\end{aligned}$$

□

Ostrzeżenie

Dwa różne procesy $\{N_t\}_{t \geq 0}$, $\{B_t\}_{t \geq 0}$ mają tę samą funkcję autokorelacji $c(s, t) = s \wedge t$

Twierdzenie 33

Niech $\{X_t\}_{t \geq 0}$ będzie standardowym procesem ruchu Browna. Dla dowolnych $t_1 < t_2 < \dots < t_n$, $n \geq 1$, wektor gaussowski $(X_{t_1}, X_{t_2}, \dots, X_{t_n})$ ma gęstość n -wymiarową (niezdegenerowaną) postaci

$$f_{(X_{t_1}, X_{t_2}, \dots, X_{t_n})}(x_1, x_2, \dots, x_n) = \prod_{j=1}^n \int_B \frac{1}{\sqrt{2\pi(t_j - t_{j-1})}} \exp\left(-\frac{(x_j - y_{j-1})^2}{2(t_j - t_{j-1})}\right) dx$$

Dowód. $(X_{t_1} - X_{t_0}, X_{t_2} - X_{t_1}, \dots, X_{t_n} - X_{t_{n-1}})$ ma gęstość

$$\begin{aligned} & f_{(X_{t_1}, X_{t_2} - X_{t_1}, \dots, X_{t_n} - X_{t_{n-1}})}(x_1, x_2, \dots, x_n) = \\ &= \prod_{j=1}^n f_{X_{t_j} - X_{t_{j-1}}}(x_j) = \prod_{j=1}^n f_{X_{t_j} - X_{t_{j-1}}}(x_j) \frac{1}{\sqrt{2\pi(t_j - t_{j-1})}} \exp\left(-\frac{x_j^2}{2(t_j - t_{j-1})}\right) \\ & \psi(X_{t_1}, X_{t_2} - X_{t_1}, \dots, X_{t_n} - X_{t_{n-1}}) = (X_{t_1}, X_{t_2}, \dots, X_{t_n}) \end{aligned}$$

Jak wygląda $\psi : \mathbb{R}^n \rightarrow \mathbb{R}^n$?

$$\psi(x_1, x_2 - x_1, \dots, x_n - x_{n-1}) = (x_1, \dots, x_n)$$

$$\psi(y_1, y_2, \dots, y_n) = (y_1, y_1 + y_2, y_1 + y_2 + y_3, \dots, y_1 + y_2 + \dots + y_n)$$

ψ operacja liniowa.

$$\begin{aligned} & f_{\psi(\bar{z})}(z_1, \dots, z_n) = f(\psi^{-1}) |J_{\psi^{-1}}| \\ & \psi^{-1}(z_1, \dots, z_n) = (z_1, z_2 - z_1, \dots, z_n - z_{n-1}) \end{aligned}$$

Macierz

$$\begin{aligned} J_{\psi^{-1}} &= \begin{bmatrix} 1 & 0 & 0 & \dots & 0 & 0 \\ -1 & 1 & 0 & \dots & 0 & 0 \\ 0 & -1 & 1 & \dots & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & \dots & 1 & 0 \\ 0 & 0 & 0 & \dots & -1 & 1 \end{bmatrix} \\ & |J_{\psi^{-1}}| = 1 \end{aligned}$$

$$\begin{aligned} & f_{(X_{t_1}, X_{t_2}, \dots, X_{t_n})}(x_1, \dots, x_n) = f_{(X_{t_1}, X_{t_2} - X_{t_1}, \dots, X_{t_n} - X_{t_{n-1}})}(\psi^{-1}(x_1, \dots, x_n)) = \\ &= \prod_{j=1}^n \frac{1}{\sqrt{2\pi(t_j - t_{j-1})}} \exp\left(-\frac{(x_j - y_{j-1})^2}{2(t_j - t_{j-1})}\right) \end{aligned}$$

□

11.1 Własności trajektorii standardowego procesu ruchu Browna

$\mathbb{R}_+ \ni t \rightarrow B_t(\omega)$ jest funkcją ciągłą dla P p.w. $\omega \in \Omega$.

Problem różniczkowalności

$$P\left(\left|\frac{X_{t+\Delta t}(\omega) - X_t(\omega)}{\Delta t}\right| > n\right) = 2 \int_n^\infty \frac{1}{\sqrt{2\pi \frac{1}{\Delta t}}} \exp\left(-\frac{x^2}{2 \cdot \frac{1}{\Delta t}}\right) dx \xrightarrow{\Delta t \rightarrow 0} 1$$

Według prawdopodobieństwa $\left| \frac{X_{t+\Delta t} - X_t}{\Delta t} \right| \xrightarrow{\Delta t \rightarrow 0} \infty$

Trajektorie procesu ruchu Browna są nigdzie różniczkowalne z prawdopodobieństwem 1.

Twierdzenie 34 (Prawo iterowania logarytmu)

Niech $\{B_t\}_{t \geq 0}$ będzie standardowym procesem Wienera (ruch Browna). Wówczas

$$P \left(\left\{ \omega \in \Omega : \limsup_{t \rightarrow +\infty} \frac{B_t(\omega)}{\sqrt{2t \ln(\ln t)}} = 1 \right\} \right) = 1$$

$$P \left(\left\{ \omega \in \Omega : \liminf_{t \rightarrow +\infty} \frac{B_t(\omega)}{\sqrt{2t \ln(\ln t)}} = -1 \right\} \right) = 1$$

Twierdzenie 35 (Lokalne prawo iterowania logarytmu)

Niech $\{B_t\}_{t \geq 0}$ będzie standardowym procesem Wienera (ruch Browna). Wówczas

$$P \left(\left\{ \omega \in \Omega : \limsup_{t \rightarrow 0^+} \frac{B_t(\omega)}{\sqrt{2t \ln(\ln t)}} = 1 \right\} \right) = 1$$

$$P \left(\left\{ \omega \in \Omega : \liminf_{t \rightarrow 0^+} \frac{B_t(\omega)}{\sqrt{2t \ln(\ln t)}} = -1 \right\} \right) = 1$$

Wniosek

Z prawdopodobieństwem 1, trajektoria $B_t(\omega)$ w okolicy $t_0 = -0$ przecina poziom 0 nieskończenie wiele razy.

Wniosek

Z prawdopodobieństwem 1, trajektoria $B(\omega)$

$$\limsup_{t \rightarrow 0^+} \frac{B_t(\omega)}{t} = +\infty \qquad \liminf_{t \rightarrow 0^+} \frac{B_t(\omega)}{t} = -\infty$$

Syntezyując punkty skupienia $\frac{B_t(\omega)}{t} \underset{t \rightarrow 0^+}{=} [-\infty, +\infty]$

Widać

$$\frac{B_t(\omega)}{t} = \frac{B_t(\omega)}{\sqrt{2t \ln |\ln t|}} \cdot \frac{2t \ln |\ln t|}{t}$$

11.2 Procesy stacjonarne

Definicja 40

Mówimy, że proces stochastyczny $\{X_t\}_{t \in T}$ jest procesem stacjonarnym w większym

sensie (ściśle stacjonarnym, mocno stacjonarnym, *strickly stationary*,...), jeżeli

$$\begin{aligned} \forall_n \forall_{t_0 < t_1 < \dots < t_n} \forall_h \mu_{(X_{t_0}, X_{t_1}, \dots, X_{t_n})} &= \mu_{(X_{t_0+h}, X_{t_1+h}, \dots, X_{t_n+h})} \\ \forall_n \forall_{t_0 < t_1 < \dots < t_n} \forall_h \forall_{B \in \mathfrak{B}_{\mathbb{R}}} P((X_{t_0}, X_{t_1}, \dots, X_{t_n}) \in B) &= P((X_{t_0+h}, X_{t_1+h}, \dots, X_{t_n+h}) \in B) \end{aligned}$$

$T = \mathbb{Z}, \mathbb{N}_0, \mathbb{R}_+, \mathbb{R}$, operacja $t_0 + h, t_1 + h, \dots, t_n + h$ nie może wyprowadzić poza T

Definicja 41

Mówimy, że proces stochastyczny $\{X_t\}_{t \in T}$ jest stacjonarny w szerszym sensie (słabo stacjonarny, *weakly stationary*), jeżeli $\forall_{t \in T} X_t \in L^2(P)$

1.

$$\forall_{t \in T} m_t = \mathbb{E}X_t = m = \text{const}$$

2.

$$\begin{aligned} \forall_{s, t \in T} \forall_h c(s, t) &= \text{cov}(X_s, X_t) = \text{cov}(X_{s+h}, X_{t+h}) = c(s+h, t+h) \\ & (= c(0, t-s) = c(t-s)) \end{aligned}$$

$$\text{Var}(X_0) = c(0) = \text{Var}(X_t) = \text{const}$$

Twierdzenie 36

Jeżeli $\{X_t\}_{t \in T}$ jest stacjonarny w węższym sensie i $X_t \in L^2(P)$ to jest stacjonarny w szerszym sensie (ale nie na odwrót).

Dowód. $\mu_{X_t} = \mu_{X_s}$ dla dowolnych $s, t \in T$

□

$$\begin{aligned} \mathbb{E}X_t &= \int_{\mathbb{R}} x d\mu_{X_t}(x) = \int_{\mathbb{R}} x d\mu_{X_s}(x) = \mathbb{E}X_s = m = \text{const} \\ \text{cov}(X_s, X_t) &\stackrel{?}{=} \text{cov}(X_{s+h}, X_{t+h}) \end{aligned}$$

$$\begin{aligned} &\int_{\mathbb{R}^2} (x-m)(y-m) d\mu_{(X_s, X_t)}(x, y) = \\ &= \int_{\mathbb{R}^2} (x-m)(y-m) d\mu_{(X_{s+h}, X_{t+h})}(x, y) = \\ &= \text{cov}(X_{s+h}, X_{t+h}) \end{aligned}$$

Definicja 42

Mówimy, że proces stochastyczny $\{X_t\}_{t \in \mathbb{R}}$ jest procesem gaussowskim, jeżeli

$\forall_n \forall_{t_1 < t_2 < \dots < t_n} (X_{t_1}, X_{t_2}, \dots, X_{t_n})$ ma rozkład gaussowski

$\mu_{(X_{t_1}, X_{t_2}, \dots, X_{t_n})}$ jest miarą gaussowską na \mathbb{R}^n (być może zdegenerowaną). Czyli

$$\varphi_{(X_{t_1}, X_{t_2}, \dots, X_{t_n})}(\tau_1, \tau_2, \dots, \tau_n) = \exp \left(i \sum_{k=1}^n \tau_k \cdot \mathbb{E} X_{t_k} - \frac{1}{2} \sum_{k=1}^n \sum_{l=1}^n v_{k,l} \cdot \tau_k \tau_l \right)$$

gdzie $\text{cov}(X_{t_k}, X_{t_l})$

Oznaczenia

$$V(t_1, \dots, t_n) = [\text{cov}(X_{t_k}, X_{t_l})]_{n \times n}$$

$$m(t_1, t_2, \dots, t_n) = (\mathbb{E} X_{t_1}, \mathbb{E} X_{t_2}, \dots, \mathbb{E} X_{t_n})$$

Rozdział 12

11 stycznia 2016

Twierdzenie 37

Niech $\mathfrak{X} = \{X_t\}_{t \in T}$ będzie procesem gaussowskim. Wówczas \mathfrak{X} jest stacjonarny w węższym sensie wtedy i tylko wtedy, gdy \mathfrak{X} jest stacjonarny w szerszym sensie.

Dowód. \Rightarrow mocna stacjonarność implikuje słabą stacjonarność

$$X_t \in L^2 \left(\text{gdyż } X_t \in \bigcap_p L^p, \text{ a nawet } \mathbb{E} e^{\alpha |X_t|^2} < \infty \text{ dla pewnej } \alpha > 0 \right)$$

\Leftarrow

$$\begin{aligned} \mu_{t_1, \dots, t_n} &\sim \mathcal{N}(m_{t_1, \dots, t_n}, V_{t_1, \dots, t_n}), \quad m_{t_1+h, \dots, t_n+h} = (\mathbb{E} X_{t_1+h}, \dots, \mathbb{E} X_{t_n+h}) = \\ &= (\mathbb{E} X_{t_1}, \dots, \mathbb{E} X_{t_n}) = \\ &= m_{t_1, \dots, t_n} \end{aligned}$$

i analogicznie

$$V_{t_1+h, \dots, t_n+h} = [\text{cov}(X_{t_j+h}, X_{t_k+h})]_{n \times n} = [\text{cov}(X_{t_j}, X_{t_k})]_{n \times n} = V_{t_1, \dots, t_n}$$

$$\begin{aligned} \mu_{t_1+h, \dots, t_n+h}^{\mathfrak{X}} &= \mathcal{N}(m_{t_1+h, \dots, t_n+h}, V_{t_1+h, \dots, t_n+h}) = \\ &= \mathcal{N}(m_{t_1, \dots, t_n}, V_{t_1, \dots, t_n}) = \mu_{t_1, \dots, t_n}^{\mathfrak{X}} \end{aligned}$$

□

Twierdzenie 38

Proces gaussowski $\mathfrak{X} = \{X_t\}_{t \in T}$ jest procesem Markowa wtedy i tylko wtedy, gdy

$$\begin{aligned} \forall_{n \in \mathbb{N}} \forall_{t_1 < \dots < t_n = s < t} \mathbb{E}(X_t | X_{t_1}, \dots, X_{t_n}, X_s) &= \mathbb{E}(X_t | X_s) \\ \forall_{n \in \mathbb{N}} \forall_{t_1 < \dots < t_n = s < t} \forall_{g: \mathbb{R} \rightarrow \mathbb{R}} \mathbb{E}(g(X_t) | X_{t_1}, \dots, X_{t_n}, X_s) &= \mathbb{E}(g(X_t) | X_s) \end{aligned}$$

gdzie g jest ograniczoną funkcją borelowską.

Przykład 8

Funkcja autokorelacji gaussowskiego procesu stacjonarnego i markowskiego. $\mathfrak{X} = \{X_t\}_{t \geq 0}$, $\mathbb{E}X_t = m_t = 0$.

$$\begin{aligned}\mathbb{E}(X_{t+s}|X_s) &= \\&= \frac{\text{cov}(t+s, X_s)}{\sqrt{\text{Var}X_{t+s}}\sqrt{\text{Var}X_s}} \cdot \frac{\sqrt{X_{t+s}}}{\sqrt{\text{Var}X_s}} X_s + (0 + \dots + 0) = \\&= \frac{\text{cov}(t, X_0)}{\text{Var}X_s} \cdot X_s = \frac{c(t)}{c(0)} X_s = \\&= \frac{\text{cov}(t, X_0)}{\text{Var}X_s} \cdot X_s = \frac{c(t)}{\text{Var}X_0} X_s\end{aligned}$$

$$\text{cov}(X_{t+s}, X_s) = \text{cov}(X_t, X_0) = c(t)$$

$$\begin{aligned}&c(0) \cdot \text{cov}(X_0, X_{t+s}) = \\&= c(0) \cdot \mathbb{E}(X_0 \cdot X_{t+s}) = \\&= c(0) \cdot \mathbb{E}(\mathbb{E}(X_0 \cdot X_{t+s}|X_0, X_s)) = \\&= c(0) \cdot \mathbb{E}(X_0 \cdot \mathbb{E}(X_{t+s}|X_0, X_s)) = \\&= c(0) \cdot \mathbb{E}\left(X_0 \cdot \frac{c(t)}{c(0)} X_s\right) = \\&= c(0) \cdot \frac{c(t)}{c(0)} \mathbb{E}(X_0 \cdot X_s) = \\&= c(t) \mathbb{E}(X_0 \cdot X_s) = \\&= c(t) \cdot c(s)\end{aligned}$$

Jak rozwiązać równanie funkcyjne $C(0) \cdot c(t+s) = c(t) \cdot c(s)$? Dla uproszczenia załóżmy, że $c: \mathbb{R} \rightarrow \mathbb{R}$ jest funkcją ciągłą (borelowską)

$$\begin{aligned}\varphi(s) &= \frac{c(s)}{c(0)} \\ \varphi(s+t) &= \frac{c(s+t)}{c(0)} = \frac{c(t)c(s)}{c(0)c(0)} = \varphi(t) \cdot \varphi(s) \\ \varphi(s+t) &= \varphi(s)\varphi(t) \\ \forall_{s,t>0} \varphi(s) &= e^{-\alpha|s|}\end{aligned}$$

dla pewnej stałej $\alpha > 0$ $\text{cov}(X_0, X_s) = e^{-\alpha|s|}$

Gdy $\alpha = 0$ daje proces stały $X_t = X$

12.1 Procesy gałązkowe

Z_0 - liczba osobników, cząstek w chwili $t = 0$ - generacja zerowa

Z_1 - liczba osobników, cząstek w chwili $t = 1$ - pierwsza generacja

\vdots

Z_n - liczba osobników, cząstek w chwili $t = n$ - n -ta generacja

$(Z_n)_{n \geq 0}$ proces z czasem dyskretnym, $Z_n \in \mathbb{N}_0 = \{0, 1, 2, \dots\}$. W chwili $k \geq 0$ mamy Z_k osobników. Każda osobniczka rodzi $X_1, X_2, \dots, X_j, \dots, X_{Z_k}^k, X_{Z_k+1}^k, \dots$, "dzieci". X_j^k , $j = 1, 2, \dots$ niezależne zmienne losowe o wartościach w \mathbb{N}_0 i tych samych rozkładach.

$G_{X_j^k}(s) = G_X(s)$ - funkcja tworząca

$$\begin{aligned} Z_n &= \sum_{j=1}^{Z_{n-1}} X_j^{n-1} \Rightarrow \\ G_{Z_n} \mathbb{E}s^{Z_n} &= \\ &= G_{\sum_{j=1}^{Z_{n-1}} X_j^{n-1}}(s) = \\ &= G_{Z_{n-1}}(G_Z(s)) = \\ &= G_{Z_{n-1}} \circ G_Z(s) = \\ &= G_{Z_0} \circ G_X^{\circ n}(s) \end{aligned}$$

Wniosek

Jeżeli $Z_0 = 1$ z pr. 1 ($G_{Z_0}(s) = s$), to $G_{Z_n}(s) = G_{Z_0}(G_X^{\circ n}(s)) = G_X^{\circ n}(s)$

Twierdzenie 39

Dla procesu gałązkowego $\{Z_n\}_{n \geq 0}$, $Z_0 = 1$ z pr. 1.

1.

$$\mathbb{E}Z_n = \mu^n$$

$$\text{gdzie } \mu = \mathbb{E}X_j^k = \mathbb{E}X$$

2.

$$\text{Var}Z_n = \begin{cases} n\sigma^2 & , \text{ gdy } \mu = 1, \sigma^2 = \text{Var}(X) \\ \frac{\sigma^2(\mu^n - 1)\mu^{n-1}}{\mu - 1} & , \text{ gdy } \mu \neq 1 \end{cases}$$

Dowód.

□

Twierdzenie 40

Reich $(Z_n)_{n \geq 0}$ będzie procesem gałęzkowym; $Z_0 = 1$. Wówczas prawdopodobieństwo wymarcia populacji (w skończonym czasie) jest równe najmniejszemu pierwiastkowi równania

$$G_X(s) = s.$$

Dowód. Jeżeli $Z_n = 0$, to $Z_{n+1} = Z_{n+2} = \dots = 0$

$$\begin{aligned} \{Z_1 = 0\} &\subseteq \{Z_2 = 0\} \subseteq \{Z_3 = 0\} \subseteq \dots \subseteq \{Z_n = 0\} \subseteq \{Z_{n+1} = 0\} \subseteq \dots \\ P\left(\bigcup_{n=1}^{\infty} \{Z_n = 0\}\right) &= \lim_{n \rightarrow \infty} P(Z_n = 0) = \lim_{n \rightarrow \infty} G_{Z_n}(0) = \lim_{n \rightarrow \infty} G_X^{cn}(0) = s^* = G_X(s^*) \end{aligned}$$

Rozpatrzmy przypadki:

$X = 1$ z pr. 1; $G_X(s)$ ma najmniejszy pierwiastek $s^* = 0$. Oczywiście prawdopodobieństwo wynosi 0.

$$\mu = \mathbb{E}X = 1 = G'_X(1)$$

$s^* = 1 =$ prawdopodobieństwo wymarcia populacji □

Paradoks $P(\exists_{n \geq 1} Z_n = 0) = 1$, ale $\mathbb{E}Z_n = 1 = \mu^n$ dla każdego n

Rozdział 13

18 stycznia 2016

13.1 Twierdzenie Kołmogorowa o rozkładach zgodnych

Definicja 43

Niech (S, \mathcal{G}) będzie przestrzenią mierzalną taką, że $\forall_{s \in S} \{s\} \in \mathcal{G}$ oraz (Ω, \mathcal{F}, P) przestrzeń probabilistyczna. Procesem stochastycznym na przestrzeni stanów (fazowej) (S, \mathcal{G}) nazywamy rodzinę elementów losowych $X_t : (\Omega, \mathcal{F}, P) \rightarrow (S, \mathcal{G})$ (tzn. $\forall_{t \in T} \forall_{B \in \mathcal{G}} X_t^{-1}(B) \in \mathcal{F}$), gdzie $t \in T$ (zbiór indeksów). Jeżeli $S = \mathbb{R}, \mathcal{G} = \mathfrak{B}_{\mathbb{R}}$, wtedy proces $\{X_t\}_{t \in T}$ nazywamy procesem stochastycznym rzeczywistym.

- X - zmienna losowa ($T = \{t\}, X = X_t$) - charakteryzowany jest przez $F_X (\equiv \mu_X, f_X, \varphi_X, M_X)$
- $\vec{X} = (X_1, \dots, X_n)$ ($T = \{1, 2, \dots, n\}$) - charakteryzowany jest przez $F_{\vec{X}} (\equiv \mu_{\vec{X}}, f_{\vec{X}}, \varphi_{\vec{X}}, M_{\vec{X}})$
- X_1, X_2, \dots ciąg zmiennych losowych - (np. łańcuch Markowa) $P = [p_{ij}]$
- $\mathfrak{X} = \{X_t\}_{t \in T}$ przez co jest charakteryzowany?

Definicja 44

Niech $\{X_t\}_{t \in T}$ będzie procesem stochastycznym Dla ustalonego $(t_1, \dots, t_n) \in T^n, n \in \mathbb{N}$

$$\mu_{t_1, \dots, t_n}(A) \stackrel{df}{=} P((X_{t_1}, \dots, X_{t_n}) \in A) (= \mu_{(X_{t_1}, \dots, X_{t_n})})$$

$A \in \mathcal{G} \otimes \mathcal{G} \otimes \dots \otimes \mathcal{G}$. ($\mathfrak{B}_{\mathbb{R}^n}$, gdy mamy proces stochastyczny rzeczywisty)
 μ_{t_1, \dots, t_n} nazywamy rozkładem skończenie wymiarowym odpowiadającym (t_1, \dots, t_n) .

Definicja 45

Niech $\mathfrak{X} = \{X_t\}_{t \in T}$ będzie procesem stochastycznym. Rodzinę rozkładów skończenie wymiarowych procesu \mathfrak{X} nazywamy rodzinę (wszystkich) miar na $S^n = S \times S \times \cdots \times S$ $\mu_{(t_1, \dots, t_n)}, t_j \in T, n \in \mathbb{N}$, tzn.

$$M^{\mathfrak{X}} = \left\{ \mu_{(t_1, \dots, t_n)} : t_1, t_2, \dots, t_n \in T, n = 1, 2, \dots \right\}$$

Dygresja 1. $\mathcal{M}^{\mathfrak{X}}$ jest charakterystyką procesu \mathfrak{X}

Dygresja 2. Ewolucja teorii stochastycznej $F_X \rightsquigarrow F_{\bar{X}} \rightsquigarrow \mathcal{M}^{\mathfrak{X}}$

Uwaga!

Nie wykluczamy $t_i = t_j$ dla niektórych $i \neq j$.

Definicja 46

Przestrzeń kanoniczną dla procesu $\mathfrak{X} = \{X_t\}_{t \in T}$ nazywamy $S^T = \{f : T \rightarrow S\}$. W przypadku procesów rzeczywistych $S^T = \mathbb{R}^T$.

Dygresja

$$\text{card} \mathbb{R}^{[0, \infty]} = \mathfrak{c}^{\mathfrak{c}} = 2^{\aleph_0 \times \mathfrak{c}} = 2^{\mathfrak{c}}$$

Uwaga!

$S^T = \{(f(t))_{t \in T}\} \leftrightarrow$ rodzina wszystkich trajektorii i hipotetycznych przekrojów procesu \mathfrak{X} .

$$\begin{aligned} \underline{t} &= (t_1, \dots, t_n), A \in \mathcal{G}^{\otimes n}(\mathfrak{B}_{\mathbb{R}}^n) \\ C_{\underline{t}, A} &= \{f \in S^T : (f(t_1), \dots, f(t_n)) \in A\} \end{aligned}$$

Definicja 47

$C_{\underline{t}, A}$ nazywamy cylindrem (skończenie wymiarowym o bazie $\underline{t} \in T^n$ i $A \in \mathcal{G}^{\otimes n}$)

Uwaga!

Cylindry nie są wyznaczone jednoznacznie.

$$\begin{aligned} C_{\underline{t}, A} &= \{f \in S^T : f(t) \in A\} = C_{(t, t), A \times A} \\ C_{(t, s), A \times S} &= \{f \in S^T : (f(t), f(s)) \in A \times S\} \end{aligned}$$

Definicja 48

Ciałem cylindrów procesu $\mathfrak{X} = \{X_t\}_{t \in T}$ nazywamy

$$\mathcal{C} = \{C_{\underline{t}, A} : (t_1, \dots, t_n) \in T^n, A \in \mathcal{G}^{\otimes n}, n \in \mathbb{N}\}$$

Twierdzenie 41

\mathcal{C} jest ciałem podzbiorów przestrzeni kanonicznej S^T .

Dowód. 1.

$$\Phi = C_{t,\Phi} = \{f : T \rightarrow S : f(t) \in \Phi\} = C_{(t,t),A \times Ac}$$

2. $C \in \mathcal{C}$; $C \in C_{\underline{t},A}$,

$$\begin{aligned} C^c &= C_{\underline{t},A^c} = \{f : T \rightarrow S : (f(t_1), \dots, f(t_n)) \in A^c\} \\ C^c &= C_{\underline{t},A^c} = \{f : T \rightarrow S : (f(t_1), \dots, f(t_n)) \notin A\} \end{aligned}$$

3.

$$\begin{aligned} &C_{(t_1, \dots, t_n), A_1} \cup C_{(t_1, \dots, t_n), A_2} = \\ &= \{f : T \rightarrow S : (f(t_1), \dots, f(t_n)) \in A_1 \vee (f(t_1), \dots, f(t_n)) \in A_2\} = \\ &= \{f : T \rightarrow S : (f(t_1), \dots, f(t_n)) \in A_1 \cup A_2\} = \\ &= C_{(t_1, \dots, t_n), A_1 \cup A_2} \in \mathcal{C} \\ &C_{(t_1, \dots, t_n), A_1} = C_{(t_1, \dots, t_n, s_1, \dots, s_m), A_1 \times S^m} \\ &C_{(s_1, \dots, s_m), A_2} = C_{(t_1, \dots, t_n, s_1, \dots, s_m), S^n \times A_2} \\ &C_{\underline{t}, A_1} \cup C_{\underline{s}, A_2} = C_{(t_1, \dots, t_n, s_1, \dots, s_m), A_1 \times S^m \cup S^n \times A_2} \in \mathcal{C} \end{aligned}$$

□

Definicja 49

Niech $\mathfrak{X} = \{X_t\}_{t \in T}$ będzie procesem stochastycznym. σ -ciałem cylindrycznym nazywamy $\mathcal{G}^T = \sigma(\mathcal{C})$. (dla rzeczywistego procesu stochastycznego B^T).

Twierdzenie 42

$A \in \mathcal{G}$ wtedy i tylko wtedy, gdy istnieje $(t_1, t_2, \dots) \in T \times T \times \dots = T^{\mathbb{N}}$ i baza $B \in \mathcal{G} \otimes \mathcal{G} \otimes \dots = G^{\otimes \mathbb{N}}$, $A = \{f \in S^T : (f(t_1), f(t_2), \dots) \in B\}$

Dowód. Rozpatrzmy rodzinę

$$\mathcal{H} = \left\{ A \in \mathcal{G}^T : \exists_{(t_1, t_2, \dots) \in T^{\mathbb{N}}} \exists_{B \in \mathcal{G}^{\otimes \mathbb{N}}} A = D_{\underline{t}, B} = \{f : T \rightarrow S : (f(t_1), f(t_2), \dots) \in B\} \right\}$$

$$\mathcal{C} \subseteq \mathcal{H}$$

$$C_{(t_1, \dots, t_n), E} = C_{(t_1, \dots, t_n, s_{n+1}, \dots), E \times S^{\infty}}$$

Sprawdzamy, że \mathcal{H} jest σ -ciałem podzbiorów S^T .

$$\Phi \in \mathcal{H}, D_{\underline{t}, B} = D_{\underline{t}, B^c}$$

$$\bigcup_{j=1}^{\infty} D_{\underline{t}^{(j)}, B^{(j)}}$$

$$\mathcal{C} \subseteq \mathcal{H} \subseteq \mathcal{G}^T = \sigma(\mathcal{C})$$

$$\mathcal{G}^T = \sigma(\mathcal{C}) \subseteq \mathcal{H} \subseteq \mathcal{G}^T$$

$$\text{Stąd } \mathcal{H} = \mathcal{G}^T$$

□

Wniosek

$T = [0, 1], C([0, 1]) \subseteq \mathbb{R}^T = \mathbb{R}^{[0, 1]}, C([0, 1]) \notin B^{[0, 1]}$ nie jest mierzalna względem sig -ciała cylindrycznego.

Twierdzenie 43

Niech $\mathfrak{X} = \{X_t\}_{t \in T}$ będzie procesem stochastycznym na przestrzeni (S, \mathcal{G}) . Wówczas

$$(\Omega, \mathcal{F}, P) = \omega \longrightarrow (X_t(\omega))_{t \in T} \in (S^T, \mathcal{G}^T)$$

jest odwzorowaniem mierzalnym. Zatem $\mu_{\mathfrak{X}}(A) \stackrel{\text{df}}{=} P((X_t(\cdot))_{t \in T} \in A)$ definiuje miarę σ -addytywną na (S^T, \mathcal{G}^T) i w konsekwencji otrzymujemy przestrzeń probabilistyczną $(S^T, \mathcal{G}^T, \mu_{\mathfrak{X}})$.

Definicja 50

Niech $\{\nu_{(t_1, \dots, t_n)} : n \in \mathbb{N}, t_1, \dots, t_n \in T\}$ będzie rodziną miar probabilistycznych ν_{t_1, \dots, t_n} miara probabilistyczna σ -addytywna na $(\mathbb{R}^n, \mathfrak{B}_{\mathbb{R}^n})$. Mówimy, że ta rodzina jest zgodna, jeżeli spełnia:

- dla dowolnego $n, B \in \mathfrak{B}_{\mathbb{R}^n}$, dowolnych $t_1, \dots, t_n \in T$, dowolnego $t_{n+1} \in T$

$$\nu_{t_1, \dots, t_n, t_{n+1}}(B \times \mathbb{R}) = \nu_{t_1, \dots, t_n}(B)$$

- dla dowolnego $n \in \mathbb{N}$, dowolnych $B_1, \dots, B_n \in \mathfrak{B}_{\mathbb{R}^n}$ i dowolnej permutacji $\gamma : \{1, \dots, n\} \rightarrow \{1, \dots, n\}$

$$\nu_{t_1, \dots, t_n}(A_1 \times \dots \times A_n) = \nu_{t_{\gamma(1)}, \dots, t_{\gamma(n)}}(A_{\gamma(1)} \times \dots \times A_{\gamma(n)})$$

Prosty fakt

$$\nu_{t_{n+1}, t_1, \dots, t_n}(\mathbb{R} \times B) = \nu_{t_1, \dots, t_n}(B)$$

Twierdzenie 44

Niech $\mathfrak{X} = \{X_t\}_{t \in T}$ będzie procesem stochastycznym. Wówczas rodzina rozkładów skończenie wymiarowych $\mathcal{M}^{\mathfrak{X}} = \{\mu_{t_1, \dots, t_n} : t_j \in T, n \in \mathbb{N}\}$ jest zgodna.

Dowód. 1.

$$\begin{aligned} & \mu_{t_1, \dots, t_n, t_{n+1}}(B \times \mathbb{R}) = \\ & = P((X_{t_1}, \dots, X_{t_n}, X_{t_{n+1}}) \in B \times \mathbb{R}) = \\ & = P((X_{t_1}, \dots, X_{t_n}) \in B) = \\ & = \mu_{t_1, \dots, t_n}(B) \end{aligned}$$

2. Podobnie

□

Twierdzenie 45

Niech \mathcal{M} będzie rodziną rozkładów skończenie wymiarowych. Wówczas istnieje proces stochastyczny $\mathfrak{X} = \{X_t\}_{t \in T}$ rzeczywisty (ewentualnie S - przestrzeń metryczna, ośrodkowa, zupełna), taka, że $\mathcal{M}^{\mathfrak{X}} = \mathcal{M}$ wtedy i tylko wtedy, gdy \mathcal{M} jest zgodna.

Dowód. \Rightarrow z poprzedniego twierdzenia

\Leftarrow (Znajdź (Ω, \mathcal{F}, P) oraz $\{X_t\}_{t \in T}$) □

Definicja 51 (Miara ciasna)

Niech (S, d) będzie przestrzenią metryczną oraz ν będzie miarą probabilistyczną σ -addytywną na (S, \mathfrak{B}_s) . Mówimy, że ν jest *ciasna* (*tight*), jeżeli

$$\forall \varepsilon > 0 \exists K_\varepsilon \subseteq S \nu(K_\varepsilon) > 1 - \varepsilon$$

Twierdzenie 46 (Ulama)

Jeżeli (S, d) jest przestrzenią metryczną, zupełną i ośrodkową (przestrzeń polska), to dowolna miara probabilistyczna (σ -addytywna) ν na S jest ciasna.