

Rozdział 1

28 września 2015

Procesy stochastyczne - teoria służąca do opisu analizy (wnioskowań) zjawisk losowych ewoluujących w czasie. Wywodzą się z rachunku prawdopodobieństwa. Modelowanie rzeczywistości obarczonej niepewnością (losowością). Przeciwnieństwo równań różniczkowych.

$$\begin{aligned}y' &= f(y, t) \\ y(t) &= g(t, y_0)\end{aligned}$$

Równania różniczkowe dostarczają modeli deterministycznych. Idealizuje, możliwe w warunkach laboratoryjnych. Bardzo dużo praktycznych zagadnień nie ma charakteru deterministycznego (a jak już ma to będzie to determinizm chaotyczny). Chaos to nie to samo, co losowość. Losowość tkwi w głębi natury. Dla przykładu mechanika kwantowa.

Podstawowe elementy (pojęcia) procesów stochastycznych:

Przestrzeń probabilistyczna (Ω, \mathcal{F}, P)

Ω - zbiór zdarzeń elementarnych
 $\omega \in \Omega$ - zdarzenie elementarne
 \mathcal{F} - σ -ciało podzbioru Ω

} pojęcia pierwotne

Definicja 1 (σ -ciało)

Mówimy, że rodzina \mathcal{F} podzbiorów Ω jest σ -ciałem, jeśli spełnia:

1.

$$\emptyset \in \mathcal{F}, \quad \Omega \in \mathcal{F},$$

2.

$$\forall A \in \Omega [A \in \mathcal{F} \Rightarrow A^c = \Omega \setminus A \in \mathcal{F}],$$

3.

$$\forall A_1, A_2, \dots \in \Omega \left[\forall_n A_n \in \mathcal{F} \Rightarrow \bigcup_{n=1}^{\infty} A_n \in \mathcal{F} \right],$$

Definicja 2

Mówimy, że funkcja zbioru P określona na (Ω, \mathcal{F}) jest σ -addytywnym prawdopodobieństwem (miarą probabilistyczną σ -addytywną), jeżeli spełnia:

1.

$$P : \mathcal{F} \rightarrow [0, 1],$$

2.

$$P(\emptyset) = 0,$$

3.

$$P(\Omega) = 1,$$

4. warunek σ -addytywności

$$\forall A_1, A_2, \dots \in \mathcal{F} \left[\forall_{i \neq j} A_i \cap A_j = \emptyset \Rightarrow P \left(\bigcup_{n=1}^{\infty} A_n \right) = \sum_{n=1}^{\infty} P(A_n) \right]$$

Definicja 3 (Proces stochastyczny)

Procesem stochastycznym na przestrzeni probabilistycznej (Ω, \mathcal{F}, P) nazywamy rodzinę zmiennych losowych $\{X_t\}_{t \in T}$ określonych na (Ω, \mathcal{F}, P) .

T - zbiór indeksów (czasowych, gdy T interpretujemy jako czas)

Definicja 4 (Zmienna losowa)

Zmienna losowa X_t .

$$\forall_{t \in T} \forall_{B \in \mathfrak{B}_{\mathbb{R}}} X_t^{-1}(B) \in \mathcal{F}$$

X_t jest \mathcal{F} mierzalne; X_t jest $\sigma(\mathcal{F}, \mathfrak{B}_{\mathbb{R}})$ mierzalna

- $\mathfrak{B}_{\mathbb{R}}$ - σ -ciało zbiorów borelowskich w \mathbb{R}
- $\mathfrak{B}_{\mathbb{R}} = \sigma(\{(\alpha, \beta) : \alpha < \beta\})$

Uwaga!

$$\text{card}(\mathfrak{B}_{\mathbb{R}}) = \mathfrak{c} < 2^{\mathfrak{c}} = \text{card}(\mathcal{L}_{\mathbb{R}})$$

Definicja 5

Niech Ω będzie ustalonym zbiorem. Mówimy, że rodzina \mathcal{C} podzbiorów Ω tworzy ciało, jeżeli spełnia:

1.

$$\emptyset, \Omega \in \mathcal{C}$$

2.

$$\forall_{A \subseteq \Omega} [A \in \mathcal{C} \Rightarrow A^c \in \mathcal{C}]$$

3.

$$\begin{aligned} & \forall_{A, B \in \Omega} [A < B \in \mathcal{C} \Rightarrow A \cup B \in \mathcal{C}] \equiv \\ & \equiv \left[A_1, A_2, \dots, A_n \in \mathcal{C}, \quad n \in \mathbb{N} \Rightarrow \bigcup_{j=1}^n A_j \in \mathcal{C} \right] \end{aligned}$$

Definicja 6

Mówimy, że funkcja zbioru μ określona na (Ω, \mathcal{C}) jest miarą probabilistyczną σ -addytywną, jeśli spełnia:

1.

$$\begin{aligned} \mu(\emptyset) &= 0 \\ \mu(\Omega) &= 1 \\ \forall_{A \in \mathcal{C}} \quad 0 &\leq \mu(A) \leq 1 \end{aligned}$$

2.

$$\forall_{A_1, A_2, \dots \in \mathcal{C}} \left[\forall_{i \neq j} A_i \cap A_j = \emptyset \wedge \bigcup_{n=1}^{\infty} A_n \in \mathcal{C} \Rightarrow \mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(A_n) \right]$$

Rozdział 2

5 Października 2015

Twierdzenie 1

Niech \mathcal{C} będzie ciałem podzbiorów Ω oraz $\mu : \mathcal{C} \rightarrow [0,1]$ będzie miarą skończenie addytywną na (Ω, \mathcal{C}) nieujemną i unormowaną, czyli

$$\mu(\Omega) = 1, \forall A \in \mathcal{C} \quad 0 \leq \mu(A) \leq 1.$$

Wówczas następujące warunki są równoważne:

(A) μ jest σ -addytywna na (Ω, \mathcal{C})

(B) Ciągłość od dołu

$$\forall B_j \in \mathcal{C} \forall B_1 \subseteq B_2 \subseteq \dots \bigcup_{j=1}^{\infty} B_j \in \mathcal{C} \Rightarrow \mu \left(\bigcup_{j=1}^{\infty} B_j \right) = \lim_{n \rightarrow \infty} \mu(B_n)$$

(C) Ciągłość od góry

$$\forall C_j \in \mathcal{C} \forall C_1 \supseteq C_2 \supseteq \dots \bigcap_{j=1}^{\infty} C_j = \emptyset \Rightarrow \lim_{n \rightarrow \infty} \mu(C_n) = 0$$

Dowód. (A) \Rightarrow (B)

$$A_1 = B_1$$

$$A_2 = B_2 \setminus B_1$$

\vdots

$$A_n = B_n \setminus B_{n-1}$$

\vdots

$$\bigcup_{j=1}^{\infty} B_j = \bigcup_{j=1}^{\infty} A_j$$

$$\begin{aligned}
\mu\left(\bigcup_{j=1}^{\infty} B_j\right) &= \mu\left(\bigcup_{j=1}^{\infty} A_j\right) = \\
&= \sum_{j=1}^{\infty} \mu(A_j) = \lim_{n \rightarrow \infty} \sum_{j=1}^n \mu(A_j) = \\
&= \lim_{n \rightarrow \infty} \mu\left(\bigcup_{j=1}^n A_j\right) = \\
&= \lim_{n \rightarrow \infty} \mu(B_n)
\end{aligned}$$

$$(B) \Rightarrow (C)$$

$$C_1 \supseteq C_2 \supseteq \dots$$

$$\bigcap_{n=1}^{\infty} C_n = \emptyset$$

$$B_n = C_n^c = \Omega \setminus C_n$$

$$\bigcup_{n=1}^{\infty} B_n = (\bigcap_{n=1}^{\infty} C_n)^c = \emptyset^c = \Omega$$

$$\begin{aligned}
1 &= \mu(\Omega) = \\
&= \mu\left(\bigcup_{n=1}^{\infty} B_n\right) = \\
&= \lim_{n \rightarrow \infty} \mu(B_n) = \\
&= \lim_{n \rightarrow \infty} (\mu(\Omega) - \mu(C_n)) = \\
&= \mu(\Omega) - \lim_{n \rightarrow \infty} \mu(C_n) \Rightarrow \lim_{n \rightarrow \infty} \mu(C_n) = 0
\end{aligned}$$

$$(C) \Rightarrow (A)$$

$$\bigcup_{j=1}^{\infty} A_j \in \mathcal{C}$$

$$\bigcup_{j=1}^{n-1} A_j \in \mathcal{C}$$

$$C_n = \bigcup_{j=n}^{\infty} A_j = \bigcup_{j=1}^{\infty} A_j \setminus \bigcup_{j=1}^{n-1} A_j \in \mathcal{C}$$

$$C_1 \supseteq C_2 \supseteq \dots$$

$$\bigcap_{j=1}^{\infty} C_n = \emptyset.$$

$$\text{Z (C)} \lim_{n \rightarrow \infty} \mu(C_n) = 0$$

$$\begin{aligned} \mu(C_n) &= \\ &= \mu\left(\bigcup_{j=n}^{\infty} A_j\right) = \\ &= \mu\left(\bigcup_{j=1}^{\infty} A_j \setminus \bigcup_{j=1}^{n-1} A_j\right) = \\ &= \mu\left(\bigcup_{j=1}^{\infty} A_j\right) - \mu\left(\bigcup_{j=1}^{n-1} A_j\right) = \\ &= \mu\left(\bigcup_{j=1}^{\infty} A_j\right) - \sum_{j=1}^{n-1} \mu(A_j) \rightarrow 0 \end{aligned}$$

$$\begin{aligned} \lim_{n \rightarrow \infty} \mu\left(\bigcup_{j=1}^{n-1} A_j\right) &= \mu\left(\bigcup_{j=1}^{\infty} A_j\right) \\ \lim_{n \rightarrow \infty} \sum_{j=1}^{n-1} \mu(A_j) &= \mu\left(\bigcup_{j=1}^{\infty} A_j\right) \end{aligned}$$

Ostatecznie

$$\mu\left(\bigcup_{j=1}^{\infty} A_j\right) = \sum_{j=1}^{\infty} \mu(A_j)$$

□

Uwaga!

Warunek (C) jest bardzo wygodny do sprawdzenia.

Twierdzenie 2

Jeżeli μ jest prawdopodobieństwem σ -addytywnym na ciele \mathcal{C} podzbiorów Ω , to istnieje dokładnie jedno rozszerzenie μ do miary probabilistycznej $\tilde{\mu}$ na $\sigma(\mathcal{C})$ $\{\tilde{\mu}|_{\mathcal{C}} = \mu\}$

$$(\Omega, \mathcal{C}, \mu) \rightsquigarrow (\Omega, \sigma(\mathcal{C}), \tilde{\mu})$$

Tradycyjnie $\tilde{\mu}$ piszemy μ .

Dygresja

$\Omega = \mathbb{N}, A \subseteq \mathbb{N}, \nu(A) = \lim_{n \rightarrow \infty} \frac{\mu(A \cap \{1, 2, \dots, n\})}{n}$ gęstość zbioru A . Dobra

miara "grubości" podzbiorów \mathbb{N} . Nie wszystkie podzbiory mają gęstość. Z całą pewnością ν nie jest σ -addytywna, bo $\nu(k) = 0, \text{card}(k) < \infty$

$$1 = \nu(\mathbb{N}) \neq \lim_{n \rightarrow \infty} \nu(\{1, 2, \dots, n\}) = 0$$

Przykład 1

$\Omega = (0, 1]$

$\mathcal{C}_{\text{przed.}} = \left\{ \bigcup_{j=1}^{\infty} (\alpha_j, \beta_j] : n = 0, 1, \dots; 0 < \alpha_1 < \beta_1 < \alpha_2 < \beta_2 < \dots < \alpha_n < \beta_n \right\}$

$F : [0, 1] \rightarrow \mathbb{R}, F$ niemalejąca, prawostronnie ciągła.

$$\mu_F \left(\bigcup_{j=1}^{\infty} (\alpha_j, \beta_j] \right) \stackrel{\text{df}}{=} \sum_{j=1}^n (F(\beta_j) - F(\alpha_j)) \geq 0$$

μ_F jest skończenie addytywna na $((0, 1], \text{przed.})$, co widać z konstrukcji. Nieco trudniej dowodzi się, że μ_F jest σ -addytywna na ciele $\mathcal{C}_{\text{przed.}}$. Zatem każda funkcja niemalejąca, prawostronnie ciągła $F : [0, 1]$ definiuje miarę σ -addytywną na $((0, 1], \sigma(\mathcal{C}_{\text{przed.}}))$

FUNKCJE TWORZĄCE

(p.g.f. probability geometry function)

Niech $X : (\Omega, \mathcal{F}, P) \rightarrow \mathbb{N}_0 = \{0, 1, 2, \dots\}$ będzie zmienną losową ($y \in X^{-1}(B) \in \mathcal{F}, B \subseteq \mathbb{N}$ - dowolny podzbiór). Nową charakterystyką takich zmiennych losowych jest funkcja charakterystyczna.

Definicja 7 (Funkcja tworząca)

Funkcją tworzącą zmiennej losowej X o wartościach w \mathbb{N}_0 nazywamy

$$\Upsilon_X(s) = \mathbb{E}s^X = \sum_{j=0}^{\infty} s^j P(X = j) = \sum_{j=0}^{\infty} s^j p_j$$

Pytanie: $\text{Dom}(r_X) = ?$

r_X określona szeregiem potęgowym; pewnie analityczna. $r_X(z), z \in K(0, R)$

Twierdzenie 3

Niech $X, \tau, X^{(1)}, X^{(2)}, \dots$ będą zmiennymi losowymi o wartościach w \mathbb{N}_0 i oznaczmy $P(X = k) = p_k$, $P(X^{(n)} = k) = p_k^{(n)}, k = 0, 1, 2, \dots$. Wówczas:

1. $\text{dom}(\Upsilon_X) \supseteq [-1, 1]$ (W przypadku dziedziny zespolonej $\overline{K}(0, 1)$)
 Υ_X jest niemalejąca i wypukła na $[0, 1]$ oraz klasy C^∞ na $(-1, 1)$

2. $\Upsilon_X(1) = 1$

3.

$$\begin{aligned}\Upsilon'_X(0) &= P(X = 1) = p_1 \\ \Upsilon''_X(0) &= 2 \cdot P(X = 2) = 2p_2 \\ &\vdots \\ \Upsilon_X^{(k)}(0) &= k! \cdot P(X = k) = k!p_k\end{aligned}$$

4. Dla X

$$\mathbb{E}X^n < \infty \Leftrightarrow \lim_{n \rightarrow 1^-} \Upsilon_X^{(n)}(s) = \Upsilon_X^{(n)}(1^-) < \infty$$

Co więcej

$$\Upsilon_X^{(n)}(1^-) = \mathbb{E}X(X-1) \cdots (X-n+1)$$

n-ty moment faktorialny

W szczególności

$$\begin{aligned}\mathbb{E}X &= \Upsilon'_X(1^-) \\ \mathbb{E}X^2 &= \mathbb{E}X(X-1) + \mathbb{E}X = \Upsilon''_X(1^-) + \Upsilon'_X(1^-)\end{aligned}$$

5. Jeżeli x i Y są niezależne o wartościach w \mathbb{N}_0 , to $\Upsilon_{X+Y}(s) = \Upsilon_X(s)\Upsilon_Y(s)$

6. Jeżeli $X^{(1)}, X^{(2)}, \dots$ są niezależnymi zmiennymi losowymi o tym samym rozkładzie i o wartościach w \mathbb{N}_0 i podobnie τ i dodatkowo ciąg $X^{(1)}, X^{(2)}, \dots$ i τ są niezależne, to dla

$$U = \sum_{j=1}^{\tau} X^{(j)}$$

mamy

$$\Upsilon_U(s) = \Upsilon_{\tau}(\Upsilon_{X^{(1)}}(s))$$

7. Dla dowolnego ciągu zmiennych losowych (niekoniecznie niezależnych) $X^{(1)}, X^{(2)}, \dots$ i zmiennej losowej X o wartościach w \mathbb{N}_0 następujące warunki są równoważne:

$$(a) \quad \forall_{k \in \mathbb{N}_0} \lim_{n \rightarrow \infty} P(X^{(n)} = k) = P(X = k)$$

(b) $X_n \xrightarrow{\mathcal{D}} X$ (zbieżność słaba)

(c) $\forall_{s \in [0,1]} \lim_{n \rightarrow \infty} \Upsilon_{X^{(n)}}(s) = \Upsilon_X(s)$

Dowód.

$$2. \Upsilon_X(1) = \mathbb{E}1^X = \mathbb{E}1 = 1$$

1.

$$\Upsilon_X(s) = \sum_{k=0}^{\infty} s^X p_k = \sum_{k=0}^{\infty} p_k s^k$$

ten szereg potęgowy jest zbieżny dla $s = 1$ nawet bezwzględnie.

$$\left(\sum_{k=0}^{\infty} |p_k| |s|^k \right)_{s=1} \\ \sum_{k=0}^{\infty} |a_k| |z^k| < \infty$$

$\Upsilon_X(z)$ jest dobrze określone na $|z| \leq 1$.

Υ_X jest funkcją analityczną (co najmniej) na $\{z : |z| < 1\}$, a stąd wynika, że Υ_X jest ciągła na $[-1,1]$ i ma ciągłe pochodne na $(-1,1)$.

$\Upsilon_X(s) = \sum_{k=0}^{\infty} p_k s^k \geq 0$ na $[0,1]$

$\Upsilon'_X(s) = \sum_{k=0}^{\infty} k \cdot p_k s^{k-1} \geq 0$ - niemalejąca na $[0,1]$

$\Upsilon''_X(s) = \sum_{k=0}^{\infty} k(k-1)p_k s^{k-2} \geq 0$ dla $s \in [0,1]$

Reasumując Υ_X jest nieujemna, niemalejąca, wypukła na $[0,1]$.

$$P(\{X = 0\} \cup \{X = 1\}) = 1$$

$$P(X \geq 2) > 0$$

$$\Upsilon_X(s) = p_0 + p_1 \cdot s$$

Υ_X ściśle wypukła

3.

$$\Upsilon_X^{(k)}(s) = \frac{d^k}{ds^k} \left(\sum_{j=0}^{\infty} p_j s^j \right) = \\ = \sum_{j=0}^{\infty} j(j-1) \cdots (j-k+1) p_j s^{j-k} = \sum_{j=k}^{\infty} j(j-1) \cdots (j-k+1) p_j s^{j-k}$$

$$\Upsilon_X^{(k)}(0) = k(k-1) \cdots (k-k+1) p_k = k! p_k \Rightarrow p_k = P(X = k) = \frac{\Upsilon_X}{k!}$$

4.

$$\begin{aligned}
 \mathbb{E}X &= \\
 &= \sum_{k=0}^{\infty} k \cdot P(X = k) = \\
 &= \sum_{k=0}^{\infty} k \cdot p_k \cdot 1^k = \\
 &= \left(\sum_{k=0}^{\infty} k \cdot p_k \cdot s^k \right)_{s=1} = \\
 &= \lim_{n \rightarrow 1^-} \left(\sum_{k=0}^{\infty} k \cdot p_k \cdot s^k \right) = \\
 &= \lim_{n \rightarrow 1^-} \Upsilon'_X(s)
 \end{aligned}$$

Analogicznie

$$\begin{aligned}
 \mathbb{E}X(X+1) \cdots (X-n+1) &= \\
 &= \sum_{k=n}^{\infty} k(k-1) \cdots (k-n+1) p_k \cdot 1^{k-n+1} = \\
 &= \lim_{n \rightarrow 1^-} \Upsilon_X^{(n)}(s)
 \end{aligned}$$

Uwaga!

$$\mathbb{E}X^n < \infty \Leftrightarrow \mathbb{E}(X(X-1) \cdots (X-n+1)) < \infty$$

5. X, Y niezależne zmienne losowe o wartościach w \mathbb{N}_0

$$\Upsilon_{X+Y}(s) = \mathbb{E}s^{X+Y} = \mathbb{E}s^X \cdot s^Y = \mathbb{E}s^X \cdot \mathbb{E}s^Y = \Upsilon_X^{(s)} \Upsilon_Y^{(s)}$$

6. $V = \sum_{j=1}^{\tau} X^{(j)}$, ustalmy $\sum_{j=1}^0 \dots = 0$

$$\begin{aligned}
\Upsilon_V(s) &= \mathbb{E} s^V = \int_{\Omega} s^V dP = \\
&= \sum_{n=0}^{\infty} \int_{\{\tau=n\}} s^{\sum_{j=1}^{\tau} x^{(j)}} dP = \\
&= \int_{\{\tau=0\}} s^{\sum_{j=1}^0 x^{(j)}} dP + \sum_{n=1}^{\infty} \int_{\{\tau=n\}} s^{\sum_{j=1}^{\tau} x^{(j)}} dP = \\
&= 1 \cdot P(\tau=0) + \sum_{n=1}^{\infty} \int_{\Omega} \mathbb{1}_{\{\tau=n\}} dP \int_{\Omega} s^{\sum_{j=1}^{\tau} x^{(j)}} dP = \\
&= 1^0 \cdot P(\tau=0) + \sum_{n=1}^{\infty} P(\tau=n) \Upsilon_{\sum_{j=1}^{\tau} x^{(j)}}(s) = \\
&= P(\tau=0) \cdot s^0 + \sum_{n=1}^{\infty} P(\tau=n) [\Upsilon_{X^{(1)}}(s)]^n = \\
&= P(\tau=0) \cdot \left(\Upsilon_X^{(1)}(s)\right)^0 + \sum_{n=1}^{\infty} P(\tau=n) [\Upsilon_{X^{(1)}}(s)]^n = \\
&= \Upsilon_{\tau}(\Upsilon_{X^{(1)}}(s)) = \Upsilon_{\tau} \circ \Upsilon_{X^{(1)}}(s)
\end{aligned}$$

□