

Rozdział 1

28 września 2015

Procesy stochastyczne - teoria służąca do opisu analizy (wnioskowań) zjawisk losowych ewoluujących w czasie. Wywodzą się z rachunku prawdopodobieństwa. Modelowanie rzeczywistości obarczonej niepewnością (losowością). Przeciwnieństwo równań różniczkowych.

$$\begin{aligned}y' &= f(y, t) \\ y(t) &= g(t, y_0)\end{aligned}$$

Równania różniczkowe dostarczają modeli deterministycznych. Idealizuje, możliwe w warunkach laboratoryjnych. Bardzo dużo praktycznych zagadnień nie ma charakteru deterministycznego (a jak już ma to będzie to determinizm chaotyczny). Chaos to nie to samo, co losowość. Losowość tkwi w głębi natury. Dla przykładu mechanika kwantowa.

Podstawowe elementy (pojęcia) procesów stochastycznych:

Przestrzeń probabilistyczna (Ω, \mathcal{F}, P)

Ω - zbiór zdarzeń elementarnych	} pojęcia pierwotne
$\omega \in \Omega$ - zdarzenie elementarne	
\mathcal{F} - σ -ciało podzbioru Ω	

Definicja 1 (σ -ciało)

Mówimy, że rodzina \mathcal{F} podzbiorów Ω jest σ -ciałem, jeśli spełnia:

1.

$$\emptyset \in \mathcal{F}, \quad \Omega \in \mathcal{F},$$

2.

$$\forall A \in \Omega [A \in \mathcal{F} \Rightarrow A^c = \Omega \setminus A \in \mathcal{F}],$$

3.

$$\forall A_1, A_2, \dots \in \Omega \left[\forall_n A_n \in \mathcal{F} \Rightarrow \bigcup_{n=1}^{\infty} A_n \in \mathcal{F} \right],$$

Definicja 2

Mówimy, że funkcja zbioru P określona na (Ω, \mathcal{F}) jest σ -addytywnym prawdopodobieństwem (miarą probabilistyczną σ -addytywną), jeżeli spełnia:

1.

$$P : \mathcal{F} \rightarrow [0, 1],$$

2.

$$P(\emptyset) = 0,$$

3.

$$P(\Omega) = 1,$$

4. warunek σ -addytywności

$$\forall A_1, A_2, \dots \in \mathcal{F} \left[\forall_{i \neq j} A_i \cap A_j = \emptyset \Rightarrow P \left(\bigcup_{n=1}^{\infty} A_n \right) = \sum_{n=1}^{\infty} P(A_n) \right]$$

Definicja 3 (Proces stochastyczny)

Procesem stochastycznym na przestrzeni probabilistycznej (Ω, \mathcal{F}, P) nazywamy rodzinę zmiennych losowych $\{X_t\}_{t \in T}$ określonych na (Ω, \mathcal{F}, P) .

T - zbiór indeksów (czasowych, gdy T interpretujemy jako czas)

Definicja 4 (Zmienna losowa)

Zmienna losowa X_t .

$$\forall t \in T \forall B \in \mathfrak{B}_{\mathbb{R}} X_t^{-1}(B) \in \mathcal{F}$$

X_t jest \mathcal{F} mierzalne; X_t jest $\sigma(\mathcal{F}, \mathfrak{B}_{\mathbb{R}})$ mierzalna

- $\mathfrak{B}_{\mathbb{R}}$ - σ -ciało zbiorów borelowskich w \mathbb{R}
- $\mathfrak{B}_{\mathbb{R}} = \sigma(\{(\alpha, \beta) : \alpha < \beta\})$

Uwaga!

$$\text{card}(\mathfrak{B}_{\mathbb{R}}) = \mathfrak{c} < 2^{\mathfrak{c}} = \text{card}(\mathcal{L}_{\mathbb{R}})$$

Definicja 5

Niech Ω będzie ustalonym zbiorem. Mówimy, że rodzina \mathcal{C} podzbiorów Ω tworzy ciało, jeżeli spełnia:

1.

$$\emptyset, \Omega \in \mathcal{C}$$

2.

$$\forall A \subseteq \Omega [A \in \mathcal{C} \Rightarrow A^c \in \mathcal{C}]$$

3.

$$\begin{aligned} & \forall A, B \in \Omega [A < B \in \mathcal{C} \Rightarrow A \cup B \in \mathcal{C}] \equiv \\ & \equiv \left[A_1, A_2, \dots, A_n \in \mathcal{C}, \quad n \in \mathbb{N} \Rightarrow \bigcup_{j=1}^n A_j \in \mathcal{C} \right] \end{aligned}$$

Definicja 6

Mówimy, że funkcja zbioru μ określona na (Ω, \mathcal{C}) jest miarą probabilistyczną σ -addytywną, jeśli spełnia:

1.

$$\begin{aligned} \mu(\emptyset) &= 0 \\ \mu(\Omega) &= 1 \\ \forall A \in \mathcal{C} \quad 0 &\leq \mu(A) \leq 1 \end{aligned}$$

2.

$$\forall A_1, A_2, \dots \in \mathcal{C} \left[\forall i \neq j A_i \cap A_j = \emptyset \wedge \bigcup_{n=1}^{\infty} A_n \in \mathcal{C} \Rightarrow \mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(A_n) \right]$$

Rozdział 2

5 Października 2015

Twierdzenie 1

Niech \mathcal{C} będzie ciałem podzbiorów Ω oraz $\mu : \mathcal{C} \rightarrow [0, 1]$ będzie miarą skończenie addytywną na (Ω, \mathcal{C}) nieujemną i unormowaną, czyli

$$\mu(\Omega) = 1, \forall a \in \mathcal{C} \quad 0 \leq \mu(A) \leq 1.$$

Wówczas następujące warunki są równoważne:

(A) μ jest σ -addytywna na (Ω, \mathcal{C})

(B) Ciągłość od dołu

$$\forall B_j \in \mathcal{C} \forall B_1 \subseteq B_2 \subseteq \dots \bigcup_{j=1}^{\infty} B_j \in \mathcal{C} \Rightarrow \mu \left(\bigcup_{j=1}^{\infty} B_j \right) = \lim_{n \rightarrow \infty} \mu(B_n)$$

(C) Ciągłość od góry

$$\forall C_j \in \mathcal{C} \forall C_1 \supseteq C_2 \supseteq \dots \bigcap_{j=1}^{\infty} C_j = \emptyset \Rightarrow \lim_{n \rightarrow \infty} \mu(C_n) = 0$$

Dowód. (A) \Rightarrow (B)

$$A_1 = B_1$$

$$A_2 = B_2 \setminus B_1$$

\vdots

$$A_n = B_n \setminus B_{n-1}$$

\vdots

$$\bigcup_{j=1}^{\infty} B_j = \bigcup_{j=1}^{\infty} A_j$$

$$\begin{aligned}
\mu\left(\bigcup_{j=1}^{\infty} B_j\right) &= \mu\left(\bigcup_{j=1}^{\infty} A_j\right) = \\
&= \sum_{j=1}^{\infty} \mu(A_j) = \lim_{n \rightarrow \infty} \sum_{j=1}^n \mu(A_j) = \\
&= \lim_{n \rightarrow \infty} \mu\left(\bigcup_{j=1}^n A_j\right) = \\
&= \lim_{n \rightarrow \infty} \mu(B_n)
\end{aligned}$$

(B) \Rightarrow (C)

$$C_1 \supseteq C_2 \supseteq \dots$$

$$\bigcap_{n=1}^{\infty} C_n = \emptyset$$

$$B_n = C_n^c = \Omega \setminus C_n$$

$$\bigcup_{n=1}^{\infty} B_n = (\bigcap_{n=1}^{\infty} C_n)^c = \emptyset^c = \Omega$$

$$\begin{aligned}
1 &= \mu(\Omega) = \\
&= \mu\left(\bigcup_{n=1}^{\infty} B_n\right) = \\
&= \lim_{n \rightarrow \infty} \mu(B_n) = \\
&= \lim_{n \rightarrow \infty} (\mu(\Omega) - \mu(C_n)) = \\
&= \lim_{n \rightarrow \infty} (\mu(\Omega) - \mu(C_n)) = \\
&= \mu(\Omega) - \lim_{n \rightarrow \infty} \mu(C_n) \Rightarrow \lim_{n \rightarrow \infty} \mu(C_n) = 0
\end{aligned}$$

(C) \Rightarrow (A)

$$\bigcup_{j=1}^{\infty} A_j \in \mathcal{C}$$

$$\bigcup_{j=1}^{n-1} A_j \in \mathcal{C}$$

$$C_n = \bigcup_{j=n}^{\infty} A_j = \bigcup_{j=1}^{\infty} A_j \setminus \bigcup_{j=1}^{n-1} A_j \in \mathcal{C}$$

$$C_1 \supseteq C_2 \supseteq \dots$$

$$\bigcap_{j=1}^{\infty} C_n = \emptyset.$$

$$\text{Z (C)} \lim_{n \rightarrow \infty} \mu(C_n) = 0$$

$$\begin{aligned} \mu(C_n) &= \\ &= \mu\left(\bigcup_{j=n}^{\infty} A_j\right) = \\ &= \mu\left(\bigcup_{j=1}^{\infty} A_j \setminus \bigcup_{j=1}^{n-1} A_j\right) = \\ &= \mu\left(\bigcup_{j=1}^{\infty} A_j\right) - \mu\left(\bigcup_{j=1}^{n-1} A_j\right) = \\ &= \mu\left(\bigcup_{j=1}^{\infty} A_j\right) - \sum_{j=1}^{n-1} \mu(A_j) \rightarrow 0 \end{aligned}$$

$$\begin{aligned} \lim_{n \rightarrow \infty} \mu\left(\bigcup_{j=1}^{n-1} A_j\right) &= \mu\left(\bigcup_{j=1}^{\infty} A_j\right) \\ \lim_{n \rightarrow \infty} \sum_{j=1}^{n-1} \mu(A_j) &= \mu\left(\bigcup_{j=1}^{\infty} A_j\right) \end{aligned}$$

Ostatecznie

$$\mu\left(\bigcup_{j=1}^{\infty} A_j\right) = \sum_{j=1}^{\infty} \mu(A_j)$$

□

Uwaga!

Warunek (C) jest bardzo wygodny do sprawdzenia.

Twierdzenie 2

Jeżeli μ jest prawdopodobieństwem σ -addytywnym na ciele \mathcal{C} podzbiorów Ω , to istnieje dokładnie jedno rozszerzenie μ do miary probabilistycznej $\tilde{\mu}$ na $\sigma(\mathcal{C})$ $\{\tilde{\mu}|_{\mathcal{C}} = \mu\}$

$$(\Omega, \mathcal{C}, \mu) \rightsquigarrow (\Omega, \sigma(\mathcal{C}), \tilde{\mu})$$

Tradycyjnie $\tilde{\mu}$ piszemy μ .

Dygresja

$\Omega = \mathbb{N}, A \subseteq \mathbb{N}, \nu(A) = \lim_{n \rightarrow \infty} \frac{\mu(A \cap \{1, 2, \dots, n\})}{n}$ gęstość zbioru A . Dobra miara

"grubości" podzbiorów \mathbb{N} . Nie wszystkie podzbiory mają gęstość. Z całą pewnością ν nie jest σ -addytywna, bo $\nu(k) = 0$, $\text{card}(k) < \infty$

$$1 = \nu(\mathbb{N}) \neq \lim_{n \rightarrow \infty} \nu(\{1, 2, \dots, n\}) = 0$$

Przykład 1

$$\Omega = (0, 1]$$

$$\mathcal{C}_{\text{przed.}} = \left\{ \bigcup_{j=1}^{\infty} (\alpha_j, \beta_j] : n = 0, 1, \dots; 0 < \alpha_1 < \beta_1 < \alpha_2 < \beta_2 < \dots < \alpha_n < \beta_n \right\}$$

$F : [0, 1] \rightarrow \mathbb{R}$, F niemalejąca, prawostronnie ciągła.

$$\mu_F \left(\bigcup_{j=1}^{\infty} (\alpha_j, \beta_j] \right) \stackrel{\text{df}}{=} \sum_{j=1}^n (F(\beta_j) - F(\alpha_j)) \geq 0$$

μ_F jest skończenie addytywna na $((0, 1], \text{przed.})$, co widać z konstrukcji. Nieco trudniej dowodzi się, że μ_F jest σ -addytywna na ciele $\mathcal{C}_{\text{przed.}}$. Zatem każda funkcja niemalejąca, prawostronnie ciągła $F : [0, 1]$ definiuje miarę σ -addytywną na $((0, 1], \sigma(\mathcal{C}_{\text{przed.}}))$

FUNKCJE TWORZĄCE

(p.g.f. probability geometry function)

Niech $X : (\Omega, \mathcal{F}, P) \rightarrow \mathbb{N}_0 = \{0, 1, 2, \dots\}$ będzie zmienną losową ($y \in X^{-1}(B) \in \mathcal{F}, \subseteq \mathbb{N}$ - dowolny podzbiór). Nową charakterystyką takich zmiennych losowych jest funkcja charakterystyczna.

Definicja 7 (Funkcja tworząca)

Funkcją tworzącą zmiennej losowej X o wartościach w \mathbb{N}_0 nazywamy

$$\Upsilon_X(s) = \mathbb{E}s^X \left(= \sum_{j=0}^{\infty} s^j P(X = j) = \sum_{j=0}^{\infty} s^j p_j \right)$$

Pytanie: $\text{Dom}(r_X) = ?$

r_X określona szeregiem potęgowym; pewnie analityczna. $r_X(z), z \in K(0, R)$

Twierdzenie 3

Niech $X, X^{(1)}, X^{(2)}, \dots$ będą zmiennymi losowymi o wartościach w \mathbb{N}_0 i oznaczmy $P(X = k) = p_k$, $P(X^{(n)} = k) = p_k^{(n)}$, $k = 0, 1, 2, \dots$. Wówczas:

1. $\text{dom}(\Upsilon_X) \supseteq [-1, 1]$ (W przypadku dziedziny zespolonej $\overline{K}(0, 1)$)
 Υ_X jest niemalejąca i wypukła na $[0, 1]$ oraz klasy C^∞ na $(-1, 1)$

2. $\Upsilon_X(1) = 1$

3.

$$\begin{aligned}\Upsilon'_X(0) &= P(X = 1) = p_1 \\ \Upsilon''_X(0) &= 2 \cdot P(X = 2) = 2p_2 \\ &\vdots \\ \Upsilon_X^{(k)}(0) &= k! \cdot P(X = k) = k!p_k\end{aligned}$$

4. Dla X

$$\mathbb{E}X^n < \infty \Leftrightarrow \lim_{n \rightarrow 1^-} \Upsilon_X^{(n)}(s) = \Upsilon_X^{(n)}(1^-) < \infty$$

Co więcej

$$\Upsilon_X^{(n)}(1^-) = \mathbb{E}X(X-1)\cdots(X-n+1)$$

n-ty moment faktorialny

W szczególności

$$\begin{aligned}\mathbb{E}X &= \Upsilon'_X(1^-) \\ \mathbb{E}X^2 &= \mathbb{E}X(X-1) + \mathbb{E}X = \Upsilon''_X(1^-) + \Upsilon'_X(1^-)\end{aligned}$$

5. Jeżeli x i Y są niezależne o wartościach w \mathbb{N}_0 , to $\Upsilon_{X+Y}(s) = \Upsilon_X(s)\Upsilon_Y(s)$

6. Jeżeli $X^{(1)}, X^{(2)}, \dots$ są niezależnymi zmiennymi losowymi o tym samym rozkładzie i o wartościach w \mathbb{N}_0 i podobnie τ i dodatkowo ciąg $X^{(1)}, X^{(2)}, \dots$ i τ są niezależne, to dla

$$U = \sum_{j=1}^{\tau} X^{(j)}$$

mamy

$$\Upsilon_U(s) = \Upsilon_{\tau}(\Upsilon_{X^{(1)}}(s))$$

7. Dla dowolnego ciągu zmiennych losowych (niekoniecznie niezależnych) $X^{(1)}, X^{(2)}, \dots$ i zmiennej losowej X o wartościach w \mathbb{N}_0 następujące warunki są równoważne:

$$(a) \quad \forall_{k \in \mathbb{N}_0} \lim_{n \rightarrow \infty} P(X^{(n)} = k) = P(X = k)$$

(b) $X_n \xrightarrow{\mathcal{D}} X$ (zbieżność słaba)

(c) $\forall_{s \in [0,1]} \lim_{n \rightarrow \infty} \Upsilon_{X^{(n)}}(s) = \Upsilon_X(s)$

Dowód.

$$2. \Upsilon_X(1) = \mathbb{E}1^X = \mathbb{E}1 = 1$$

1.

$$\Upsilon_X(s) = \sum_{k=0}^{\infty} s^X p_k = \sum_{k=0}^{\infty} p_k s^k$$

ten szereg potęgowy jest zbieżny dla $s = 1$ nawet bezwzględnie.

$$\left(\sum_{k=0}^{\infty} |p_k| |s|^k \right)_{s=1} \\ \sum_{k=0}^{\infty} |a_k| |z|^k < \infty$$

$\Upsilon_X(z)$ jest dobrze określone na $|z| \leq 1$.

Υ_X jest funkcją analityczną (co najmniej) na $\{z : |z| < 1\}$, a stąd wynika, że

Υ_X jest ciągła na $[-1, 1]$ i ma ciągłe pochodne na $(-1, 1)$.

$\Upsilon_X(s) = \sum_{k=0}^{\infty} p_k s^k \geq 0$ na $[0, 1]$

$\Upsilon'_X(s) = \sum_{k=0}^{\infty} k \cdot p_k s^{k-1} \geq 0$ - niemalejąca na $[0, 1]$

$\Upsilon''_X(s) = \sum_{k=0}^{\infty} k(k-1)p_k s^{k-2} \geq 0$ dla $s \in [0, 1]$

Reasumując Υ_X jest nieujemna, niemalejąca, wypukła na $[0, 1]$.

$$P(\{X+0\} \cup \{X=1\}) = 1$$

$$P(X \geq 2) > 0$$

$$\Upsilon_X(s) = p_0 + p_1 \cdot s$$

Υ_X ściśle wypukła

3.

$$\Upsilon_X^{(k)}(s) = \frac{d^k}{ds^k} \left(\sum_{j=0}^{\infty} p_j s^j \right) = \\ = \sum_{j=0}^{\infty} j(j-1) \cdots (j-k+1) p_j s^{j-k} = \sum_{j=k}^{\infty} j(j-1) \cdots (j-k+1) p_j s^{j-k}$$

$$\Upsilon_X^{(k)}(0) = k(k-1) \cdots (k-k+1) p_k = k! p_k \Rightarrow p_k = P(X=k) = \frac{\Upsilon_X}{k!}$$

4.

$$\begin{aligned}
\mathbb{E}X &= \\
&= \sum_{k=0}^{\infty} k \cdot P(X = k) = \\
&= \sum_{k=0}^{\infty} k \cdot p_k \cdot 1^k = \\
&= \left(\sum_{k=0}^{\infty} k \cdot p_k \cdot s^k \right)_{s=1} = \\
&= \lim_{n \rightarrow 1^-} \left(\sum_{k=0}^{\infty} k \cdot p_k \cdot s^k \right) = \\
&= \lim_{n \rightarrow 1^-} \Upsilon'_X(s)
\end{aligned}$$

Analogicznie

$$\begin{aligned}
&\mathbb{E}X(X+1) \cdots (X-n+1) = \\
&= \sum_{k=n}^{\infty} k(k-1) \cdots (k-n+1) p_k \cdot 1^{k-n+1} = \\
&= \lim_{n \rightarrow 1^-} \Upsilon_X^{(n)}(s)
\end{aligned}$$

Uwaga!

$$\mathbb{E}X^n < \infty \Leftrightarrow \mathbb{E}(X(X-1) \cdots (X-n+1)) < \infty$$

5. X, Y niezależne zmienne losowe o wartościach w \mathbb{N}_0

$$\Upsilon_{X+Y}(s) = \mathbb{E}s^{X+Y} = \mathbb{E}s^X \cdot s^Y = \mathbb{E}s^X \cdot \mathbb{E}s^Y = \Upsilon_X^{(s)} \Upsilon_Y^{(s)}$$

6. $V = \sum_{j=1}^{\tau} X^{(j)}$, ustalmy $\sum_{j=1}^0 \dots = 0$

$$\begin{aligned}
\Upsilon_V(s) &= \mathbb{E} s^V = \int_{\Omega} s^V dP = \\
&= \sum_{n=0}^{\infty} \int_{\{\tau=n\}} s^{\sum_{j=1}^{\tau} x^{(j)}} dP = \\
&= \int_{\{\tau=0\}} s^{\sum_{j=1}^0 x^{(j)}} dP + \sum_{n=1}^{\infty} \int_{\{\tau=n\}} s^{\sum_{j=1}^{\tau} x^{(j)}} dP = \\
&= 1 \cdot P(\tau=0) + \sum_{n=1}^{\infty} \int_{\Omega} \mathbb{1}_{\{\tau=n\}} dP \int_{\Omega} s^{\sum_{j=1}^{\tau} x^{(j)}} dP = \\
&= 1^0 \cdot P(\tau=0) + \sum_{n=1}^{\infty} P(\tau=n) \Upsilon_{\sum_{j=1}^{\tau} x^{(j)}}(s) = \\
&= P(\tau=0) \cdot s^0 + \sum_{n=1}^{\infty} P(\tau=n) [\Upsilon_{X^{(1)}}(s)]^n = \\
&= P(\tau=0) \cdot \left(\Upsilon_X^{(1)}(s)\right)^0 + \sum_{n=1}^{\infty} P(\tau=n) [\Upsilon_{X^{(1)}}(s)]^n = \\
&= \Upsilon_{\tau}(\Upsilon_{X^{(1)}}(s)) = \Upsilon_{\tau} \circ \Upsilon_{X^{(1)}}(s)
\end{aligned}$$

□

Rozdział 3

12 października 2015

Dowód. 7. (a) \Rightarrow (b)

$$P(X^{(n)} \leq t) \xrightarrow{n \rightarrow \infty} P(X \leq t)$$

w każdym punkcie t , w którym F_X jest ciągła; dla $t < 0$ jasne, bo $0 \xrightarrow{n \rightarrow \infty} 0$

$$\begin{aligned} P(X^{(n)} \leq t) &= \\ &= P(X^{(n)} \leq \lfloor t \rfloor) = \\ &= \sum_{k=0}^{\lfloor t \rfloor} P(X^{(n)} = k) \xrightarrow{n \rightarrow \infty} \sum_{k=0}^{\lfloor t \rfloor} P(X \leq \lfloor t \rfloor) = \\ &= P(X \leq t) \end{aligned}$$

(b) \Rightarrow (c)

$$\Upsilon_{X^{(n)}}(s) = \mathbb{E}s^{X^{(n)}}$$

$$g_s(t) = \begin{cases} 1 & \text{dla } t \leq 0 \\ s^t & \text{dla } t > 0 \end{cases} \quad \text{dla } 1 \geq s > 0$$
$$g_0(t) = 1 - 2t$$

$\forall_{s \in [0,1]} g_s$ jest funkcją ciągłą i ograniczoną

$$X \xrightarrow{\mathcal{D}} X \Leftrightarrow \forall_{g: \mathbb{R} \rightarrow \mathbb{R}} \mathbb{E}g(X^{(n)}) \xrightarrow{n \rightarrow \infty} \mathbb{E}g(X)$$

Dla każdego $s \in [0, 1]$ g jest funkcją ciągłą i ograniczoną.

$$\mathbb{E}g_s(X^{(n)}) = \mathbb{E}s^{X^{(n)}} = \Upsilon_{X^{(n)}}(s)$$

$$\mathbb{E}g_s(X) = \Upsilon_X(s)$$

$$\begin{aligned}\mathbb{E}g_0(X^{(n)}) &= 1 \cdot P(X^{(n)} = 0) + \sum_{k=1}^{\infty} 0 \cdot P(X^{(n)} = k) = \\ &= \Upsilon_{X^{(n)}}(0) \xrightarrow{n \rightarrow \infty} \mathbb{E}g_0(X) = \dots = \Upsilon_X(0)\end{aligned}$$

(c) \Rightarrow (a)

Mamy $\Upsilon_{X^{(n)}}(s) \rightarrow \Upsilon_X(s)$ dla $s \in [0, 1]$

Podstawmy $s = 0$

$$\begin{aligned}\sum_{k=0}^{\infty} s^k \cdot P(X^{(n)} = k) \Big|_{s=0} &= P(X^{(n)} = 0) \xrightarrow[n \rightarrow \infty]{c)} \Upsilon_X(0) \\ P_0^{(n)} &\rightarrow P_0\end{aligned}$$

Szkic

$$p_1^{(n)} = P(X^{(n)} = 1) \xrightarrow{n \rightarrow \infty} P(X = 0)?$$

$$\Upsilon_{X^{(n)}}(s) = P(X^{(n)} = 0) + P(X^{(n)} = 1)s + P(X^{(n)} = 2)s^2 + \dots$$

$$\Upsilon_X(s) = P(X = 0) + P(X = 1)s + P(X = 2)s^2 + \dots$$

$$\forall s \in [0, 1] \sum_{k=1}^{\infty} P(X^{(n)} = k) s^k \xrightarrow{n \rightarrow \infty} \sum_{k=1}^{\infty} P(X = k) s^k$$

$$\forall s \in [0, 1] s \sum_{k=1}^{\infty} P(X^{(n)} = k) s^{k-1} \xrightarrow{n \rightarrow \infty} s \sum_{k=1}^{\infty} P(X = k) s^{k-1}$$

o, ile $0 \leq s \leq 1$, to uprościmy

$$\begin{aligned}&\forall s \in [0, 1] \sum_{k=1}^{\infty} P(X^{(n)} = k) s^{k-1} = \\ &= P(X^{(n)} = 1) + P(X^{(n)} = 2)s + \dots + P(X^{(n)} = k) s^{k-1} + \dots \xrightarrow{n \rightarrow \infty} \\ &\xrightarrow{n \rightarrow \infty} P(X = 1) + P(X = 2)s + \dots + P(X = k) s^{k-1} + \dots\end{aligned}$$

mogą być dowolnie małe biorąc małe $s \in (0, 1]$. W takim razie, gdy $n \rightarrow \infty$ mamy

$$P(X^{(n)} = 0) \xrightarrow{n \rightarrow \infty} P(X = 0)$$

$$P(X^{(n)} = 1) \xrightarrow{n \rightarrow \infty} P(X = 1)$$

dalej indukcyjnie

$$\forall k \in \mathbb{N}_0 P(X^{(n)} = k) \xrightarrow{n \rightarrow \infty} P(X = k)$$

□

3.1 Funkcja generująca momenty (Moment generating function)

Definicja 8

Niech X będzie zmienną losową określoną na przestrzeni probabilistycznej (Ω, \mathcal{F}, P) . Funkcją generującą momenty nazywamy funkcję

$$M_X(s) = \mathbb{E}e^{sX} = \int_{-\infty}^{+\infty} e^{sx} dF_X(x)$$

Wtrącenie

$$\int_{-\infty}^{+\infty} e^{sx} f_X(x) dx, \text{ gdy } X \text{ ma gęstość } f_X$$

$$\sum_{k=1}^{\infty} e^{sx_k} P(X = x_k), \text{ gdy } X \text{ jest typu dyskretnego}$$

Wadą jest fakt, że $\text{Dom}(M_X)$ może być mała lub trudna do określenia. Np. może się zdarzyć, że $\text{Dom}(M_X) = \{0\}$, ale zawsze $0 \in \text{Dom}(M_X)$

Fakt

$$M_X(0) = \mathbb{E}e^{0 \cdot X} = \mathbb{E}e^0 = \mathbb{E}1 = 1$$

Chcielibyśmy, aby $(-\varepsilon, \varepsilon) \subseteq \text{Dom}(M_X)$

Twierdzenie 4

Niech zmienna losowa $X : (\Omega, \mathcal{F}, P) \rightarrow \mathbb{R}$ ma własność $\text{Dom}(M_X) \supseteq (-\varepsilon, \varepsilon)$ dla $\varepsilon > 0$. Wówczas

$$M'_X(0) = \mathbb{E}X$$

$$M''_X(0) = \mathbb{E}X^2 \text{ itd.}$$

Dowód.

$$\begin{aligned} M'_X(x) &= \\ &= \lim_{h \rightarrow 0} \frac{M_X(x+h) - M_X(x)}{h} = \\ &= \lim_{h \rightarrow 0} \frac{\mathbb{E}e^{(x+h)X} - \mathbb{E}e^{xX}}{h} = \\ &= \lim_{h \rightarrow 0} \mathbb{E} \frac{e^{(x+h)X} - e^{xX}}{h} = \\ &= \mathbb{E} \lim_{h \rightarrow 0} \frac{e^{(x+h)X} - e^{xX}}{h} = \\ &= \mathbb{E}X e^{xX} \end{aligned}$$

$$M'_X(0) = \left(M'_X(x) \right)_{x=0} = \mathbb{E} X e^{0X} = \mathbb{E} X$$

Indukcyjnie dla wyższych momentów. □

Twierdzenie 5

Jeżeli zmienne losowe X, Y są niezależne to

$$M_{X+Y}(x) = M_X(x) \cdot M_Y(x)$$

Dowód.

$$\begin{aligned} M_{X+Y}(x) &= \\ &= \mathbb{E} e^{x(X+Y)} = \\ &= \mathbb{E} e^{xX+xY} = \\ &= \mathbb{E} \underbrace{e^{xX} e^{xY}}_{\text{niezależne}} = \\ &= \mathbb{E} e^{xX} \cdot \mathbb{E} e^{xY} = \\ &= M_X(x) M_Y(x) \end{aligned}$$

□

Wniosek

Jeżeli X_1, \dots, X_k to niezależne zmienne losowe o tym samym rozkładzie, to

$$M_{\sum_{j=1}^k X_j}(x) = [M_{X_1}(x)]^k$$

Uwaga!

Jeżeli X i Y mają ten sam rozkład, to oczywiście

$$M_X = M_Y$$

Przykład 2

Wyznacz M_X , gdy $X \sim \text{Pois}(\lambda)$

$$\begin{aligned} M_X(x) &= \\ &= \mathbb{E} e^{xX} = \\ &= \sum_{k=0}^{\infty} e^{xk} \frac{\lambda^k}{k!} e^{-\lambda} = \\ &= \sum_{k=0}^{\infty} \frac{(e^x \lambda)^k}{k!} e^{-\lambda} = \\ &= e^{e^x \lambda} \cdot e^{-\lambda} = \\ &= e^{\lambda(e^x - 1)} \end{aligned}$$

$$\text{Dom}(M_{\text{Pois}}) = \mathbb{R}$$

$$\mathbb{E} = M'_X(0)$$

$$M'_X(x) = \left(e^{\lambda(e^x-1)} \right)' = e^{\lambda(e^x-1)} \cdot (\lambda \cdot e^x)$$

$$M''_X(x) = \left(e^{\lambda(e^x-1)} \cdot (\lambda \cdot e^x) \right)' = \lambda \left(e^{\lambda(e^x-1)} \cdot \lambda e^x \cdot e^x + e^{\lambda(e^x-1)} \cdot e^x \right)$$

$$M''_X(0) = \lambda(\lambda + 1) = \lambda^2 + \lambda = \mathbb{E}X^2$$

$$\text{Var}(X) = \mathbb{E}X^2 - (\mathbb{E}X)^2 = \lambda^2 + \lambda - \lambda^2 = \lambda$$

Przykład 3

$X \sim \text{Exp}(\alpha)$

$$M_X(x) = \mathbb{E}e^{xX} = \int_0^{+\infty} e^{xt} \alpha e^{-\alpha t} dt = \alpha \int_0^{\infty} e^{(x-\alpha)t} dt =$$

$$= \frac{\alpha}{x-\alpha} e^{(x-\alpha)t} \Big|_0^{\infty} = \frac{-\alpha}{x-\alpha} = \frac{\alpha}{\alpha-x}$$

$$\text{Dom}M_{\text{Exp}(\alpha)} = (-\infty, \alpha)$$

$$M'_X(x) = \frac{\alpha}{(x-\alpha)^2} \qquad M'_X(0) = \mathbb{E}X = \frac{\alpha}{\alpha^2} = \frac{1}{\alpha}$$

$$M''_X(x) = \frac{2\alpha}{(\alpha-x)^3} \qquad M''_X(0) = \mathbb{E}X^2 = \frac{2\alpha}{\alpha^3} = \frac{2}{\alpha^2}$$

itd.

3.2 Uwagi o teorii niezawodności

Niech czas pracy bezawaryjnej urządzenia opisany będzie zmienną losową X :
 $(\Omega, \mathcal{F}, P) \rightarrow [0, \infty)$

Definicja 9 (Funkcja niezawodności)

Funkcją niezawodności urządzenia nazywamy

$$R_X(t) = \bar{F}(t) = P(X > t) \quad \text{dla } t \in [0, \infty]$$

Uwaga!

$P(X = 0) = 0$ to nasze upraszczające założenie.

Definicja 10

Niech X będzie nieujemną zmienną losową. Mówimy, że X ma własność braku pamięci, jeżeli

$$\forall_{s,t \geq 0} P(X > s+t | X > t) = P(X > s)$$

Twierdzenie 6

Nieujemna zmienna losowa X ma własność braku pamięci wtedy i tylko wtedy, gdy ma rozkład wykładniczy.

Dowód. \Leftarrow

Zakładamy, że $X \sim \text{Exp}$, $P(X > t) = e^{-\alpha t}$

$$\begin{aligned} P(X > t + s | X > t) &= \frac{P(X > t + s \wedge X > t)}{P(X > t)} = \\ &= \frac{P(X > t + s)}{P(X > t)} = \\ &= \frac{e^{-\alpha(t+s)}}{e^{-\alpha t}} = \\ &= e^{-\alpha s} = \\ &= P(X > s) \end{aligned}$$

\Rightarrow

Zakładamy, że X ma własność braku pamięci

$$\begin{aligned} P(X > t + s | X > t) &= P(X > s) \\ \frac{P(X > t + s \wedge X > t)}{P(X > t)} &= P(X > s) \\ P(X > s + t) &= P(X > s) P(X > t) \\ \bar{F}_X(s + t) &= \bar{F}_X(s) \bar{F}_X(t) \text{ dla } s, t \geq 0 \end{aligned}$$

Mamy równanie funkcyjne dla $g : [0, \infty) \rightarrow \mathbb{R}$

$$\forall_{s, t \geq 0} g(t + s) = g(t)g(s)$$

$g(t) = \bar{F}(t)$ ograniczona, prawostronnie ciągła oraz $\bar{F}(0) = 1$ i

$$\lim_{x \rightarrow \infty} \bar{F}(x) = 0$$

Odrzucamy trywialne rozwiązania równania $g \equiv 0$, $g \equiv 1$

$$\begin{aligned} g(2s) &= g(s + s) = g(s) \cdot g(s) = g(s)^2 \geq 0 \\ g(1) &= \underbrace{\left(\frac{1}{m} + \frac{1}{m} + \dots + \frac{1}{m}\right)}_{m \text{ razy}} = g\left(\frac{1}{m}\right) g\left(\frac{1}{m}\right) \dots g\left(\frac{1}{m}\right) = \left[g\left(\frac{1}{m}\right)\right]^m \\ g\left(\frac{1}{m}\right) &= g(1)^{\frac{1}{m}} \\ g\left(\frac{k}{m}\right) &= \underbrace{\left(\frac{1}{m} + \frac{1}{m} + \dots + \frac{1}{m}\right)}_{k \text{ składników}} = g\left(\frac{1}{m}\right) g\left(\frac{1}{m}\right) \dots g\left(\frac{1}{m}\right) = \\ &= g\left(\frac{1}{m}\right)^k = [g(1)]^{\frac{k}{m}} = g(1)^{\frac{k}{m}} \end{aligned}$$

Gdyby $g(1) = 0 \Rightarrow g\left(\frac{1}{m}\right) = 0 \Rightarrow \lim_{m \rightarrow \infty} g\left(\frac{1}{m}\right) = 0$, ale $g(0) = 1$

Zatem $g(1) > 0$.

Gdyby $g(1) > 1 \Rightarrow g(k) = g(1)^k \xrightarrow{k \rightarrow \infty} 0$, ale $\lim_{x \rightarrow \infty} g(x) = 0$

Zatem $0 < g(1) < 1$. Przyjmijmy, że $g(1) = e^{-\alpha}$ dla pewnego $\alpha > 0$. Wtedy $g\left(\frac{k}{m}\right) = (e^{-\alpha})^{\frac{k}{m}} = e^{-\alpha \frac{k}{m}}$

Dla dowolnego $x \geq 0$, $\lim_{n \rightarrow \infty} \frac{k^{(n)}}{m^{(n)}} \left(\overline{\mathbb{Q}} = \mathbb{R} \right)$

$$g(x) = \lim_{n \rightarrow \infty} g\left(\frac{k^{(n)}}{m^{(n)}}\right) = \lim_{n \rightarrow \infty} e^{-\alpha \frac{k^{(n)}}{m^{(n)}}}$$

$$\forall_{x \geq 0} 1 - F(x) = \overline{F}(x) = e^{-\alpha x}; X \sim \text{Exp}$$

□

Uwaga!

W dziedzinie $\mathbb{N}_0 = \{0, 1, 2, \dots\}$ jedynym rozkładem o własności braku pamięci jest rozkład geometryczny.

Definicja 11

Niech X będzie zmienną losową opisującą czas pracy bezawaryjnej. Intensywnością awarii nazywamy funkcję $\lambda_X : [0, \infty) \rightarrow [0, \infty)$

$$\lambda_X(t) = \frac{f_X(t)}{\overline{F}_X(t)} = \frac{f_X(t)}{R_X(t)} = -\frac{R'_X(t)}{R_X(t)}$$

$$\begin{aligned} R'_X &= (1 - F_X)' = \\ &= -F'_X = -f_X \end{aligned}$$

Uwaga!

λ_X jest określona tylko dla zmiennych losowych absolutnie ciągłych.

W medycynie mówimy o intensywności śmierci albo ogólniej o funkcji hazardu. Rozkład (gęstość) wyznacza jednoznacznie funkcję intensywności awarii.

$$\lambda_X(t) = \frac{f_X(t)}{P(x > t)} = \frac{f_X(t)}{\int_t^{\infty} f_X(u) du}$$

Interpretacja funkcji intensywności awarii.

$$\begin{aligned}
& \lim_{\Delta \rightarrow 0^+} \frac{P(t < X \leq t + \Delta T | X > t)}{\Delta t} = \\
&= \lim_{\Delta \rightarrow 0^+} \frac{\frac{P(X_t \in (t, t + \Delta t] | X_t > t)}{R_X(t)}}{\Delta t} = \\
&= \lim_{\Delta \rightarrow 0^+} \frac{\frac{P(X_t \in (t, t + \Delta t])}{\Delta t}}{R_X(t)} = \\
&= \lim_{\Delta \rightarrow 0^+} \frac{\frac{1}{\Delta t} \int_t^{t+\Delta t} f_X(u) du}{R_X(t)} = \\
&= \frac{f_X(t)}{R_X(t)}
\end{aligned}$$

Rozdział 4

19 października 2015

Twierdzenie 7

Funkcja intensywności awarii wyznacza jednoznacznie F_X . ($F_X \longleftrightarrow \lambda_X$)

Dowód.

$$\lambda_X = -\frac{R'_x}{R_X} = -(\ln R_X)'$$

$$\Lambda_X(x) = \int_0^x \lambda_X(u) du = - \int_0^x (\ln R_X) du = -\ln R_X|_0^x = -\ln R_X(x) + \ln \overbrace{R_X(0)}^{=1}$$

$$R_X(x) = e^{-\int_0^x \lambda_X(u) du}$$

$$F_X(x) = 1 - e^{-\int_0^x \lambda_X(u) du}$$

□

Definicja 12

Jeżeli urządzenie opisane jest funkcją intensywności awarii λ_X , to

1. mówimy, że urządzenie starzeje się, gdy $\lambda_X \nearrow$ jest funkcją rosnącą
2. mówimy, że urządzenie dociera się, gdy $\lambda_X \searrow$ jest funkcją malejącą

Uwaga!

$$\lambda_X = \text{const} \Leftrightarrow X \sim \text{Exp}$$

4.1 Klasyczne rozkłady w teorii niezawodności

Definicja 13

Mówimy, że nieujemna zmienna losowa X ma rozkład Weibulla, gdy

$$\begin{aligned} F_X(t) &= 1 - e^{-(\lambda t)^\beta} & t \geq 0 & \lambda, \beta > 0 \\ R_X(t) &= e^{-(\lambda t)^\beta} & t \geq 0 & \lambda, \beta > 0 \end{aligned}$$

Dla rozkładu Weibulla

$$\lambda_X(t) = \frac{\lambda\beta(\lambda t)^{\beta-1}e^{-(\lambda t)^\beta}}{e^{-(\lambda t)^\beta}} = \lambda^\beta \beta t^{\beta-1}$$

Układ dociera się, gdy $\beta < 1$

Układ starzeje się, gdy $\beta > 1$

$$\text{Weib}_{\lambda,1} = \text{Exp}(\lambda)$$

W praktyce inżynierskiej

$$F_X(t) = \alpha_1 e^{-\lambda_1 t} + \alpha_2 e^{-\lambda_2 t} + \alpha_3 \frac{\text{const}}{\sqrt{2\pi}} \int_{\frac{t-m}{\sigma}}^{\infty} e^{-\frac{1}{2}u^2} du$$

Czyli mieszane rozkłady $\text{Exp} \approx \text{Exp} \approx \Gamma$

4.2 Formalne definicje z teorii procesów stochastycznych

Definicja 14

Niech $T(\neq \emptyset)$ będzie zbiorem indeksów. Procesem stochastycznym indeksowanym elementami zbioru T nazywamy rodzinę $\{X_t : t \in T\}$ zmiennych losowych (ogólniej elementów losowych) określonych na wspólnej przestrzeni probabilistycznej (Ω, \mathcal{F}, P) . Jeżeli $\text{card}(T) < \infty$ albo $\text{card}(T) = \aleph_0$, to mówimy o procesach z indeksem dyskretnym. Jeżeli $\text{card}(T) = \mathfrak{c}$, to mówimy, o procesach nad indeksami "ciągłymi".

T identyfikujemy z biegnącym czasem

$T = \{0, 1, \dots, N\}$ albo $T = \{1, 2, \dots, N\}$ albo $T = \{0, 1, 2, \dots\}$ albo $T = \{-3, -2, -1, 0, 1, 2, 3, \dots\}$ - procesy z czasem dyskretnym.

$T = [a, b], [a, \infty), (-\infty, 0], (-\infty, +\infty)$ - procesy z czasem ciągłym

$\mathfrak{X} = \{X_t : t \in T\}$ - matematyczny opis (model) ewolucji w czasie

Definicja 15

Dla ustalonego procesu stochastycznego $\mathfrak{X} = \{X_t : t \in T\}$ trajektorią (realizacją) odpowiadającą zdarzeniu elementarnemu $\omega \in \Omega$ nazywamy funkcję $T \ni t \rightarrow X_t(\omega) \in \mathbb{R}$

Przykład 4

W urnie mamy 1 kulę białą i 1 kulę niebieską. Po wylosowaniu jednej kuli zwracamy ją do urny dodając jedną kulę w wylosowanym kolorze (po n -tym losowaniu mamy w urnie $2 + n$ kul). Procesy stochastyczne na tym mechanizmie (losowym). (\equiv procesy urnowe).

1. X_n - liczba kul białych w urnie po n -tym losowaniu

$$X_0 = 1$$

$$X_1 = \left(P(X_1 = 1) = P(X_1 = 2) = \frac{1}{2} \right)$$

$$X_3 \in \{1, 2, 3\}, \dots$$

$\mathfrak{X} = \{X\}_{n=0}^\infty$ - proces stochastyczny z czasem dyskretnym,
 $T = \{0, 1, 2, \dots\} = \mathbb{N}_0$

- 2.

$$Y_n = \begin{cases} 1 & \text{gdy kula wylosowana w } n\text{-tym cięgnięciu jest niebieska} \\ 3 & \text{gdy kula wylosowana w } n\text{-tym cięgnięciu jest biała} \end{cases}$$

$$\{Y_n\}_{n=1}^\infty, \quad T = \{1, 2, \dots\}$$

3. Z_n = liczba wylosowanych kul białych w cięgnięciach $1, 2, \dots, n$

4. Zrób to sam(a)

4.3 Spacer losowy na grupie

$\xi_1, \xi_2, \xi_3, \dots$ ciąg Berboulliego niezależnych zmiennych losowych o tym samym rozkładzie

$$P(\xi_j = 1) = P(\xi_j = -1) = \frac{1}{2}$$

X_0 niezależna zmienna losowa od ciągu $(\xi_j)_{j=1}^\infty$ o wartościach w \mathbb{Z} .
Spacerem losowym nazywamy

$$S_{X_0, n} = X_0 + \xi_1 + \dots + \xi_n = X_0 + \sum_{j=1}^n \xi_j$$

Zauważmy, że

$$P(S_{X_{0,n+1}} - S_{X_{0,n}} = \pm 1) = P(\xi_{n+1} = \pm 1) = \frac{1}{2}$$

$$P(S_{X_{0,n+1}} = j | S_{X_{0,n}} = \pm 1) = \begin{cases} \frac{1}{2} & , \text{ gdy } |i - j| = 1 \\ 0 & , \text{ gdy } |i - j| \neq 1 \end{cases}$$

Uwaga!

Jeżeli $\mathfrak{X} = \{X_t\}_{t \in T}$ jest procesem stochastycznym, to $Y_t = g_t(X_t)$, $t \in T$ jest też procesem stochastycznym $g_t : \mathbb{R} \rightarrow \mathbb{R}$ (funkcja borelowska).

Definicja 16

Niech $\mathfrak{X} = \{X_t : t \in T\} = \{X_t\}_{t \in T}$ będzie procesem stochastycznym określonym na (Ω, \mathcal{F}, P) , przy czym $T = \mathbb{Z}$ albo $\mathbb{N}, \mathbb{R}, \mathbb{R}_+, \mathbb{Q}, \mathbb{Q}_+$. Mówimy, że \mathfrak{X} ma przyrosty:

- niezależne, gdy

$$\forall n \in \mathbb{N} \forall t_j \in T \forall t_0 < t_1 < \dots < t_n X_{t_1} - X_{t_0}, X_{t_2} - X_{t_1}, \dots, X_{t_n} - X_{t_{n-1}}$$

są zmiennymi losowymi niezależnymi

- jednorodne, gdy

$$\forall t_1, t_2 \in T; t_1 < t_2 \forall t_1+h, t_2+h \in T (X_{t_2} - X_{t_1}) \sim (X_{t_2+h} - X_{t_1+h})$$

- stacjonarne, gdy

$$\forall n \in \mathbb{N} \forall t_1, t_2 \in T; t_1 < t_2 \forall t_1+h, t_2+h \in T \\ (X_{t_1} - X_{t_0}, \dots, X_{t_n} - X_{t_{n-1}}) \sim (X_{t_1+h} - X_{t_0+h}, \dots, X_{t_n+h} - X_{t_{n-1}+h})$$

Uwaga!

Stacjonarność przyrostów implikuje jednorodność przyrostów.

Definicja 17

Niech $\mathfrak{X} = \{X_t : t \in T\}$ będzie procesem stochastycznym określonym na (Ω, \mathcal{F}, P) przy czym $T = \mathbb{Z}$ albo $\mathbb{N}, \mathbb{R}, \mathbb{R}_+, \mathbb{Q}, \mathbb{Q}_+$. Mówimy, że proces \mathfrak{X} jest stacjonarny, gdy

$$\forall n \in \mathbb{N} \forall t_j \in T \forall t_0 < t_1 < \dots < t_n \forall h : t_0+h, \dots, t_n+h \in T (X_{t_0}, X_{t_1}, \dots, X_{t_n}) \sim (X_{t_0+h}, X_{t_1+h}, \dots, X_{t_n+h})$$

Oznaczenia

$\mu_{t_0, t_1, \dots, t_n} \stackrel{\text{ozn.}}{=} \mu_{(X_{t_0}, X_{t_1}, \dots, X_{t_n})}$ - rozkład wektora losowego

$(X_{t_0}, X_{t_1}, \dots, X_{t_n}) \in \mathbb{R}^{n+1}$, $n = 0, 1, 2 \dots$

μ_t - rozkład X_t losowych o tym samym, czyli rozkład jednowymiarowy

$\mu_{r,t}$ rozkład (X_r, X_t) , czyli rozkład dwuwymiarowy itd.

$F_{t_0, t_1, \dots, t_n} \stackrel{\text{ozn.}}{=} F_{(X_{t_0}, X_{t_1}, \dots, X_{t_n})}$

Definicja 18

Jeżeli $\mathfrak{X} = \{X_t : t \in T\}$ jest procesem stochastycznym, to rozkładem skończenie wymiarowym odpowiadającym wyborowi indeksów $(t_1, t_2, \dots, t_n) \in T^n$ nazywamy rozkład wektora losowego $(X_{t_0}, X_{t_1}, \dots, X_{t_n})$. Oznaczam

$$\mu_{(t_1, t_2, \dots, t_n)} \stackrel{df}{=} \mathcal{L}((X_{t_0}, X_{t_1}, \dots, X_{t_n})) \in \mathcal{P}(\mathbb{R}^n)$$

Rodzina rozkładów skończenie wymiarowych procesów $\mathfrak{X} = \{X_t : t \in T\}$ nazywamy

$$\mathcal{M}^{\mathfrak{X}} = \left\{ \mu_{(t_1, t_2, \dots, t_n)} : t_1, t_2, \dots, t_n \in T, n = 1, 2, \dots \right\}$$

Uwaga!

Zmienną losową X charakteryzuje F_X

Wektor losowy $\vec{X} = (X_1, \dots, X_n)$ charakteryzuje $F_{\vec{X}}$ dystrybucja łączna n -wymiarowa.

Proces stochastyczny \mathfrak{X} charakteryzuje $\mathcal{M}^{\mathfrak{X}}$

Lemat 1

Proces $\mathfrak{X} = \{X_t : t \in T\}$ o przyrostach niezależnych ma przyrosty stacjonarne wtedy i tylko wtedy, gdy ma przyrosty jednorodne.

Dowód.

” \Rightarrow ” jasne

” \Leftarrow ”

Wybieramy $t_0 < t_1 < \dots < t_n \in T$ oraz h ”dowolne”, takie, że $t_0 + h, t_1 + h, \dots, t_n + h \in T$

$$\begin{aligned} & \mu_{(X_{t_1}-X_{t_0}, X_{t_2}-X_{t_1}, \dots, X_{t_n}-X_{t_{n-1}})} = \\ & = \mu_{(X_{t_1}-X_{t_0})} \otimes \mu_{(X_{t_2}-X_{t_1})} \otimes \dots \otimes \mu_{(X_{t_n}-X_{t_{n-1}})} \stackrel{jed.}{=} \\ & = \mu_{(X_{t_1+h}-X_{t_0+h})} \otimes \mu_{(X_{t_2+h}-X_{t_1+h})} \otimes \dots \otimes \mu_{(X_{t_n+h}-X_{t_{n-1}+h})} = \\ & = \mu_{(X_{t_1+h}-X_{t_0+h}, X_{t_2+h}-X_{t_1+h}, \dots, X_{t_n+h}-X_{t_{n-1}+h})} \end{aligned}$$

□

Rozdział 5

26 października 2015

Definicja 19 (Proces Poissona)

Mówimy, że proces $\{N_t\}_{t \in [0, \infty)}$ określony na przestrzeni probabilistycznej (Ω, \mathcal{F}, P) jest procesem liczącym, jeżeli

1. $N_0 = 0$

$$\forall \omega \in \Omega \forall t \in T N_T(\omega) \in \mathbb{N}_0 = \{0, 1, 2, \dots\}$$

- 2.

$$\forall 0 \leq s < t \forall \omega \in \Omega N_s(\omega) \leq N_t(\omega)$$

3. $\forall 0 \leq s < t N_t(\omega) - N_s(\omega)$ reprezentuje liczbę zdarzeń jakie zaszły na odcinku czasowym $(s, t]$.

Definicja 20 (Proces jednorodny)

Mówimy, że proces liczący $\{N_t\}_{t \in [0, \infty)}$ określony na przestrzeni probabilistycznej (Ω, \mathcal{F}, P) jest jednorodnym procesem Poissona z intensywnością $\lambda > 0$ - liczba, jeżeli spełnia

- i $N(0) = 0$ z prawdopodobieństwem 1
- ii $\{N_t\}_{t \in [0, \infty)}$ ma przyrosty niezależne
- iii $\forall 0 \leq s < t N_t(\omega) - N_s(\omega)$ ma rozkład Poissona z parametrem $\lambda(t - s)$

$$\left[\forall_{k \in \{0, 1, 2, \dots\}} P(N(t) - N(s) = k) = \frac{[\lambda(t - s)]^k}{k!} e^{-\lambda(t-s)} \right]$$

Uwaga!

(iii) implikuje, że przyrosty są jednorodne

$$N(t+h) - N(s+h) \sim \text{Poiiss}(\lambda(t+h - (s+h))) = \text{Poiiss}(\lambda(t-s)) \sim N(t) - N(s)$$

Zatem (iii) w połączeniu z (ii) mamy proces o przyrostach stacjonarnych (niezależnych).

Uwaga!

$$\mathbb{E}N(t) = \lambda t$$

$$\text{Var}N(t) = \lambda t$$

Twierdzenie 8

Niech $\{N_t\}_{t \in [0, \infty)}$ będzie procesem liczącym określonym na przestrzeni probabilistycznej (Ω, \mathcal{F}, P) . Wówczas $\{N_t\}_{t \in [0, \infty)}$ jest jednorodnym procesem Poissona z intensywnością $\lambda > 0$ wtedy i tylko wtedy, gdy spełnia

1. $N(0) = 0$ z pr. 1
2. $\{N_t\}_{t \in [0, \infty)}$ ma jednorodne i niezależne przyrosty
- 3.

$$P(N(h) = 1) = \lambda \cdot h + o(h)$$

$$\left[\frac{o(h)}{h} \xrightarrow{h \rightarrow 0} 0 \right]$$

4.

$$P(N(h) \geq 2) = P(N(h) = 2 \vee N(h) = 3 \vee \dots) = o(h)$$

Dowód. \Rightarrow

(i) \equiv (1)

(ii) + (iii) \Rightarrow (2)

$$P(N(h) = 1) \stackrel{(iii)}{=} \frac{(\lambda h)^1}{1!} e^{-\lambda h} = \lambda h e^{-\lambda h}$$

3)

$$P(N(h) = 1) - \lambda h \stackrel{?}{=} o(h)$$

$$\frac{\lambda h e^{-\lambda h} - \lambda h}{h} = \lambda (e^{-\lambda h} - 1) \xrightarrow{h \rightarrow 0} (e^{-\lambda 0} - 1) = 0$$

4)

$$\frac{P(N(h) \leq 2)}{h} \xrightarrow[h \rightarrow 0]{?} 0$$

$$\frac{1 - P(N(h) = 0) - P(N(h) = 1)}{h} \stackrel{(iii)}{=} \frac{1 - e^{-\lambda h} - \lambda h e^{-\lambda h}}{h}$$

Stosując regułę de l'Hospitala

$$\lim_{h \rightarrow 0} \frac{P(N(h) \leq 2)}{h} = \lim_{h \rightarrow 0} \frac{\lambda e^{-\lambda h} - \lambda(e^{-\lambda h} - \lambda h e^{-\lambda h})}{1} = \lim_{h \rightarrow 0} \lambda^2 h e^{-\lambda h} = 0$$

\Leftarrow

(i) \equiv (1)

(2) \Rightarrow (ii)

Jak pokazać (iii)? $P_n(t) = P(N(t) = n) \quad n = 0, 1, 2, \dots$

Etapami

$$P_0(t) = P(N(t) = 0) \stackrel{?}{=} e^{-\lambda t} = \frac{(\lambda t)^0}{0!} e^{-\lambda t}$$

$$\begin{aligned} P_0(t+h) &= P(N(t+h) = 0) = \\ &= P(N(t) = 0 \wedge N(t+h) - N(t) = 0) = \\ &= P(N(t) = 0) P(N(t+h) - N(t) = 0) \stackrel{(2)}{=} \\ &= P_0(t) \cdot P(N(h) = 0) \stackrel{(3)}{=} \\ &= P_0(t) \cdot \left(1 - P(N(h) = 1) - P(N(h) \geq 2)\right) = \\ &= P_0(t) (1 - \lambda h - o(h) - o(h)) = \\ &= P_0(t) - \lambda P_0(t) h - 2o(h) P_0(t) = \\ &= P_0(t) - \lambda P_0(t) h - o(h) \end{aligned}$$

$N(t) \perp\!\!\!\perp N(t+h)$

$$\frac{P_0(t+h) - P_0(t)}{h} = -\lambda P_0(t) - \frac{o(h)}{h}$$

$$P'_0(t) = -\lambda P_0(t)$$

z warunkiem $P_0(0) = P(N(0) = 0) = 1$

$$P_0(t) = e^{-\lambda t}$$

$$P_0(0) = P(N(0) = 0) = \frac{(\lambda h)^0}{0!} e^{-\lambda h}$$

Indukcyjnie pokazuje się, że

$$\forall_{n \geq 0} P(N(t) = n) = \frac{(\lambda h)^n}{n!} e^{-\lambda h}$$

Pokazaliśmy, już I krok indukcyjny i formuła zachodzi dla $n=0$.

$$\begin{aligned} P_n(t+h) &= P(N(t+h) = n) = \\ &= P(\{N(t) = n \wedge N(t+h) - N(t) = 0\} \cup \\ &\quad \cup \{N(t) = n-1 \wedge N(t+h) - N(t) = 1\} \cup \\ &\quad \cup \{N(t) < n-1 \wedge N(t+h) - N(t) \geq 2\}) = \\ &= P(N(t) = n \wedge N(t+h) - N(t) = 0) + \\ &\quad + P(N(t) = n-1 \wedge N(t+h) - N(t) = 1) + \\ &\quad + P(N(t) < n-1 \wedge N(t+h) - N(t) \geq 2) \stackrel{(2)}{=} \\ &= P(N(t) = n)P(N(h) = 0) + \\ &\quad + P(N(t) = n-1)P(N(h) = 1) + \\ &\quad + P(N(t) < n-1)P(N(h) \geq 2) = \\ &= P(N(t) = n)P(N(h) = 0) + P(N(t) = n-1)P(N(h) = 1) + o(h) = \\ &= P_n(t)e^{-\lambda h} + P_{n-1}(t)(\lambda h + o(h)) + o(h) = \\ &= P_n(t)(1 - \lambda h + o(h)) + \lambda h P_{n-1}(t) + o(h) = \\ &= P_n(t) - \lambda h P_n(t) + \lambda h P_{n-1}(t) + o(h) \end{aligned}$$

$$\begin{aligned} P_n(t+h) &= P_n(t) - \lambda h P_n(t) + \lambda h P_{n-1}(t) + o(h) \\ \frac{P_n(t+h) - P_n(t)}{h} &= \frac{-\lambda h P_n(t) + \lambda h P_{n-1}(t)}{h} + \frac{o(h)}{h} \end{aligned}$$

Przechodząc $h \rightarrow 0$

$$\begin{aligned} P'_n(t) &= -\lambda P_n(t) + \lambda P_{n-1}(t) \\ P'_n(t) + \lambda P_n(t) &= \lambda P_{n-1}(t) \\ P'_n(t)e^{\lambda t} + \lambda P_n(t)e^{\lambda t} &= \lambda P_{n-1}(t)e^{\lambda t} \\ (P_n(t)e^{\lambda t})' &= \lambda P_{n-1}(t)e^{\lambda t} \quad n = 1, 2, 3, \dots \end{aligned}$$

dla $n = 1$

$$\begin{aligned} (P_1(t)e^{\lambda t})' &= \lambda P_0(t)e^{\lambda t} = \lambda e^{-\lambda t} e^{\lambda t} = \lambda \\ P_1(t)e^{\lambda t} &= \lambda t + C \end{aligned}$$

Warunek początkowy

$$P_1(0) = P(N(0) = 1) = 0$$

daje

$$P_1(0)e^{\lambda 0} = \lambda \cdot 0 + C \Rightarrow C = 0$$

Ostatecznie

$$P_1(t)e^{\lambda t} = \lambda t$$

$$P_1(t) = \frac{(\lambda t)^1}{1!} e^{-\lambda t}$$

W II kroku indukcyjnym założymy, że

$$\left(P_n(t) e^{\lambda t} \right)' = \lambda \frac{(\lambda t)^{n-1}}{(n-1)!} e^{-\lambda t} \cdot e^{\lambda t} = \frac{\lambda^n \cdot t^{n-1}}{(n-1)!}$$

$$P_n(t) e^{\lambda t} = \int \frac{\lambda^n t^{n-1}}{(n-1)!} dt = \frac{\lambda^n t^n}{n!} + C$$

Warunek

$$P_n(0) = P(N(0) = n) = 0 \Rightarrow C = 0$$

Na mocy indukcji matematycznej

$$\forall_{n \geq 0} P(N(t) = n) = P_n(t) = \frac{(\lambda t)^n}{n!} e^{-\lambda t}$$

(iii)

$$P(N(t) - N(s) = n) =$$

$$= P(N(s + (t - s)) - N(s) = n) \stackrel{(2)}{=} \\ = P(N(t - s) = n) = \frac{(\lambda(t - s))^n}{n!} e^{-\lambda(t-s)}$$

□

5.1 Własności trajektorii Procesu Poissona

Fakt 1

Z prawdopodobieństwem 1 trajektoria ma tylko skończenie wiele skoków na każdym skończonym odcinku czasowym $[0, t]$.

A_n - zdarzenie polegające na tym, że na odcinku $[0, n]$ było nieskończenie wiele skoków

A_n - zdarzenie polegające na tym, że na odcinku skończonym było skończenie wiele skoków

$$B^c = \Omega \setminus B = \bigcup_{n=1}^{\infty} A_n$$

$$\begin{aligned} P(A_n) &= \\ &= P(\text{na odcinku } [0, n] \text{ było nieskończenie wiele skoków}) = \\ &= P(\forall_{k \in \mathbb{N}} N(n) \geq k) = \\ &= P\left(\bigcap_{k=1}^{\infty} \{N(n) \geq k\}\right) = \\ &= \lim_{k \rightarrow \infty} P(N(n) \geq k) = \\ &= \lim_{k \rightarrow \infty} P\left(\bigcup_{j=k}^{\infty} N(n) = j\right) = \\ &= \lim_{k \rightarrow \infty} \underbrace{\sum_{j=k}^{\infty} \frac{(\lambda n)^j}{j!} e^{-\lambda n}}_{\text{ogon szeregu zbieżnego}} = 0 \end{aligned}$$

$$\forall_n P(A_n) = 0$$

$$\begin{aligned} 0 &\leq P\left(\bigcup_{n=1}^{\infty} A_n\right) \leq \sum_{n=1}^{\infty} P(A_n) = 0 \\ P(B^c) &= 0 \Rightarrow P(B) = 1 - P(B^c) = 1 - 0 = 1 \end{aligned}$$

Uwaga!

Jednorodny proces Poissona nie eksploduje (na skończonym odcinku czasu).

Fakt 2

Z prawdopodobieństwem 1 skoki trajektorii są równe 1.

$$P(\{\omega \in \Omega : [0, \infty) \ni t \rightarrow N_t(\omega) \text{ ma skoki równe } 1\}) = 1$$

Zdarzenie przeciwne

$$\begin{aligned} &\{\omega \in \Omega : [0, \infty) \ni t \rightarrow N_t(\omega) \text{ ma skoki } \geq 2\} = \\ &= \bigcup_{n=1}^{\infty} \{\omega \in \Omega : [0, \infty) \ni t \rightarrow N_t(\omega) \text{ ma skoki } \geq 2 \text{ na odcinku } [0, n]\} = \bigcup_{n=1}^{\infty} A_n \end{aligned}$$

$$A_n = \bigcup_{j=0}^{n \cdot m - 1} \left\{ \text{skok} \geq 2 \text{ zdarzył się na } \left(\frac{j}{m}, \frac{j+1}{m} \right] \right\} \leq \bigcup_{j=0}^{n \cdot m - 1} \left\{ N\left(\frac{j+1}{m}\right) - N\left(\frac{j}{m}\right) \geq 2 \right\}$$

$$\begin{aligned} 0 &\leq P(A_n) \leq \sum_{j=0}^{n \cdot m - 1} P\left(N\left(\frac{j}{m} + \frac{1}{m}\right) - N\left(\frac{j}{m}\right) \geq 2\right) \stackrel[\text{jednorodność}]{\text{przyrostu}} \\ &= \sum_{j=0}^{n \cdot m - 1} P\left(N\left(\frac{1}{m}\right) \geq 2\right) = n \cdot m \left(1 - P\left(N\left(\frac{1}{m}\right) = 0\right) - P\left(N\left(\frac{1}{m}\right) = 1\right)\right) = \\ &= n \left(1 - e^{-\frac{1}{m} \cdot \lambda} - \frac{1}{m} e^{-\frac{1}{m} \cdot \lambda}\right) \cdot \frac{1}{\frac{1}{m}} \leq n \cdot \varepsilon \end{aligned}$$

$$\lim_{x \rightarrow 0^+} \frac{1 - e^{-\lambda x} - \lambda x e^{-\lambda x}}{x} \stackrel{\text{"H"}}{=} \lim_{x \rightarrow 0^+} \frac{\lambda e^{-\lambda x} - \lambda e^{-\lambda x} + \lambda^2 x e^{-\lambda x}}{1} = 0$$

Jeśli

$$X < \delta_\varepsilon$$

wtedy

$$\left| \frac{1 - e^{-\lambda x} - \lambda x e^{-\lambda x}}{x} \right| < \varepsilon \text{ dla } \frac{1}{m} < \delta_\varepsilon \left(\equiv \left(m > \frac{1}{\delta_\varepsilon} \right) \right)$$

$$0 \leq P(A_n) \leq \varepsilon \cdot n$$

Zatem $\forall_n P(A_n) = 0$

Stąd

$$P\left(\bigcup_{n=1}^{\infty} A_n\right) = 0$$

$$P(\{\omega \in \Omega : [0, \infty) \ni t \rightarrow N_t(\omega) \text{ ma skok} \geq 2\}) = 0$$

$$P(\{\omega \in \Omega : [0, \infty) \ni t \rightarrow N_t(\omega) \text{ ma skok} = 1\}) = 1$$

Fakt 3

Z prawdopodobieństwem 1 trajektorie dążą do ∞ , gdy $t \rightarrow \infty$

$$P\left(\left\{\omega \in \Omega : \lim_{t \rightarrow \infty} N_t(\omega) = \infty\right\}\right) = 1$$

Zdanie przeciwne

$$\left\{ \omega \in \Omega : \lim_{t \rightarrow \infty} N_t(\omega) < \infty \right\} = \bigcup_{n=1}^{\infty} \left\{ \omega \in \Omega : \lim_{t \rightarrow \infty} N_t(\omega) < n \right\} = \bigcup_{n=1}^{\infty} A_n$$

$$\begin{aligned} A_n &= \left\{ \omega \in \Omega : \forall_{t \in [0, \infty)} N_t(\omega) \leq n \right\} = \\ &= \left\{ \omega \in \Omega : \forall_{k \in \mathbb{N}} N_k(\omega) \leq n \right\} = \\ &= \bigcap_{k=1}^{\infty} \left\{ \omega \in \Omega : N_k(\omega) \leq n \right\} \end{aligned}$$

$$\begin{aligned} P(A_n) &= P\left(\bigcap_{k=1}^{\infty} \{N_k \leq n\}\right) = \\ &= \lim_{k \rightarrow \infty} P(N_k \leq n) = \\ &= \lim_{k \rightarrow \infty} P(N_k = 0 \vee N_k = 1 \vee \dots \vee N_k = n) = \\ &= \lim_{k \rightarrow \infty} \sum_{j=0}^n P(N_k = j) = \\ &= \lim_{k \rightarrow \infty} \sum_{j=0}^n \frac{(\lambda k)^j}{j!} \cdot e^{-\lambda k} = 0 \end{aligned}$$

$$P\left(\bigcup_{n=1}^{\infty} A_n\right) = 0$$

Stąd z prawdopodobieństwem 1

$$\lim_{t \rightarrow \infty} N_t = \infty$$

Twierdzenie 9

Jeżeli $\{N_t\}_{t \in [0, \infty)}$ jest jednorodnym procesem Poissona z intensywnością $\lambda > 0$, to z prawdopodobieństwem 1 trajektorie $[0, \infty) \ni t \rightarrow N_t(\omega)$ są funkcjami schodkowymi, startującymi z 0, o skokach równych 1, o skończenie wielu skokach na każdym odcinku skończonym i dążących do nieskończoności (gdy $t \rightarrow \infty$) i prawostronnie ciągłymi.

Moment skoku \equiv chwila skoku (T_1, T_2, \dots)

Czas oczekiwania na kolejny skok X_1, X_2, \dots "międzyczasy"; "czasypomiędzy"

Twierdzenie 10

Ciąg zmiennych losowych X_1, X_2, \dots dla jednorodnego procesu Poissona z intensywnością $\lambda > 0$ jest ciągiem niezależnym o tym samym rozkładzie $\text{Exp}(\lambda)$.

Dowód.

$$P(X_1 \leq t) = P(N_t \geq 1) = 1 - P(N_t = 0) = 1 - e^{-\lambda t} \quad \text{dla } t \geq 0$$

$F_{X_1}(t) = 1 - e^{-\lambda t}$. Z definicji $X_n \geq 0$.

$$X_1 \sim \text{Exp}(\lambda)$$

□

Rozdział 6

9 listopada 2015

$\{N(t)\}_{t \geq 0}$ jednorodny proces Poissona z intensywnością $\lambda = \text{const} > 0$
 $X_n(\omega)$ zmienna losowa czas pomiędzy $n - 1$ i n -tym zdarzeniem ("międzyczas")
 X_1, X_2, \dots i.i.d. $\sim \text{Exp}(\lambda)$

Dowód. pokazaliśmy, że $X_1 \sim \text{Exp}(\lambda)$
 (X_1, X_2, \dots, X_n) czy składowe są niezależne o rozkładzie $\text{Exp}(\lambda)$?

$$f_{X_1, \dots, X_n}(x_1, \dots, x_n) = (\lambda e^{-\lambda x_1}) \cdot (\lambda e^{-\lambda x_2}) \cdot \dots \cdot (\lambda e^{-\lambda x_n})$$

Wystarczy. Żeby czasy skończyły się na tablicy policzymy dla $n = 2$

$$\begin{aligned} f_{X_1, X_2}(x_1, x_2) & \lim_{\substack{\Delta t_1 \rightarrow 0 \\ \Delta t_2 \rightarrow 0}} \frac{P(X_1 \in (x_1, x_1 + \Delta t_1] \wedge X_2 \in (x_2, x_2 + \Delta t_2])}{\Delta t_1 \cdot \Delta t_2} = \\ & = \lim_{\substack{\Delta t_1 \rightarrow 0 \\ \Delta t_2 \rightarrow 0}} \frac{1}{\Delta t_1 \cdot \Delta t_2} \cdot P(N(x_1) = 0, N(x_1 + \Delta t_1) - N(x_1) = 1, \\ & \quad N(x_1 + x_2) - N(x_1 + \Delta t_1) = 0, N(x_1 + x_2 + \Delta t_2) - N(x_1 + x_2) = 1) = \\ & = \lim_{\substack{\Delta t_1 \rightarrow 0 \\ \Delta t_2 \rightarrow 0}} \frac{1}{\Delta t_1 \cdot \Delta t_2} \cdot P(N(x_1) = 0) P(N(x_1 + \Delta t_1) - N(x_1) = 1) \\ & \quad P(N(x_1 + x_2) - N(x_1 + \Delta t_1) = 0) P(N(x_1 + x_2 + \Delta t_2) - N(x_1 + x_2) = 1)) = \\ & = \lim_{\substack{\Delta t_1 \rightarrow 0 \\ \Delta t_2 \rightarrow 0}} \frac{1}{\Delta t_1 \cdot \Delta t_2} \cdot e^{-\lambda x_1} (\lambda \cdot \Delta t_1)^1 e^{-\lambda \Delta t_1} P(x_2 - \Delta t_1 = 0) \cdot \lambda \Delta t_2 e^{-\lambda \Delta t_2} = \\ & = \lim_{\substack{\Delta t_1 \rightarrow 0 \\ \Delta t_2 \rightarrow 0}} \lambda e^{-\lambda x_1} \cdot e^{-\lambda \Delta t_1} \cdot e^{-\lambda(x_2 - \Delta t_1)} \cdot \lambda e^{-\lambda \Delta t_2} = \\ & = \lambda e^{-\lambda x_1} \cdot \lambda e^{-\lambda x_2} = f_{\text{Exp}(\lambda)}(x_1) f_{\text{Exp}(\lambda)}(x_2) \end{aligned}$$

X_1, X_2 są niezależne i $X_1, X_2 \sim \text{Exp}(\lambda)$

Dla dowolnych $n \in \mathbb{N}$ rozumowanie jest takie samo, jedynie rachunki dłuższe. \square

Wnioski

Niech $T_n = X_1 + \dots + X_n$ czas oczekiwania na n -te zdarzenie. Wówczas T ma rozkład Erlanga z parametrami $\Gamma_{n,\lambda}$

$$f_{T_n}(t) = \frac{\lambda^n \Gamma(n)}{t^{n-1} e^{-\lambda t}}$$

Dowód. Wiemy, że

$$X_j \sim \text{Exp}(\lambda) \Rightarrow X_1 + \dots + X_n \sim \Gamma_{n,\lambda}$$

$t > 0$

$$T_n \leq t \Leftrightarrow N(t) \geq n$$

$$F_{T_n}(t) = P(N(t) \geq n) = \sum_{j=n}^{\infty} \frac{(\lambda t)^j}{j!} e^{-\lambda t}$$

$$\begin{aligned} f_{T_n}(t) &= F'_{T_n}(t) = \\ &= \sum_{j=n}^{\infty} \left(\frac{(\lambda t)^j}{j!} e^{-\lambda t} \right)' = \\ &= \sum_{j=n}^{\infty} \frac{\lambda^{j+1}}{j!} j t^{j+1} e^{-\lambda t} + \sum_{j=n}^{\infty} \frac{\lambda^j t^j}{j!} e^{-\lambda t} = \\ &= \frac{\lambda^{(n-1)+1}}{(n-1)!} t^{n-1} e^{-\lambda t} = \\ &= \frac{\lambda^n}{\Gamma(n)} t^{n-1} e^{-\lambda t} \end{aligned}$$

To rozkład Erlanga z parametrami n, λ

\square

6.1 Statystyki pozycyjne

Y_1, Y_2, \dots, Y_n - zmienne losowe

Permutujemy, aby uzyskać ciąg niemalejący

$$\begin{aligned} \tilde{Y}_1(\omega) &\leq \tilde{Y}_2(\omega) \leq \dots \leq \tilde{Y}_n(\omega) \\ Y_{\alpha(1)}(\omega) &\leq Y_{\alpha(2)}(\omega) \leq \dots \leq Y_{\alpha(n)}(\omega) \end{aligned}$$

Permutacja α zależy od ω

Zakładamy, że zmienne losowe Y_1, \dots, Y_n są typu ciągłego (a nawet absolutnie ciągłego) i niezależne. Z prawdopodobieństwem 1 mamy

$$\tilde{Y}_1(\omega) < \tilde{Y}_2(\omega) < \dots < \tilde{Y}_n(\omega)$$

bo $P(Y_i = Y_j) = 0$ dla $i \neq j$

My założymy dodatkowo, że Y_1, \dots, Y_n mają ten sam rozkład.

Reasumując Y_1, \dots, Y_n i.i.d. z gęstością f_Y

$$\begin{aligned} & f_{(\tilde{Y}_1, \dots, \tilde{Y}_n)}(t_1, \dots, t_n) = \\ &= \lim_{\substack{\Delta t_1 \rightarrow 0 \\ \vdots \\ \Delta t_n \rightarrow 0}} \frac{n! P(Y_1 \in [t_1, t_1 + \Delta t_1), \dots, Y_n \in [t_n, t_n + \Delta t_n))}{\Delta t_1 \cdot \dots \cdot \Delta t_n} = \\ &= n! \lim_{\substack{\Delta t_1 \rightarrow 0 \\ \vdots \\ \Delta t_n \rightarrow 0}} \frac{P(Y_1 \in [t_1, t_1 + \Delta t_1))}{\Delta t_1} \cdot \frac{P(Y_2 \in [t_2, t_2 + \Delta t_2))}{\Delta t_2} \cdot \dots \cdot \frac{P(Y_n \in [t_n, t_n + \Delta t_n))}{\Delta t_n} = \\ &= n! f_{Y_1}(t_1) \cdot f_{Y_2}(t_2) \cdot \dots \cdot f_{Y_n}(t_n) = \\ &= n! \prod_{j=1}^n f_Y(t_j) \end{aligned}$$

$$f_{(\tilde{Y}_1, \dots, \tilde{Y}_n)}(t_1, t_2, \dots, t_n) = \frac{n!}{t^n} \mathbb{1}_{\{0 < t_1 < \dots < t_n < t\}}$$

Twierdzenie 11

Niech $\{N(t)\}_{t \geq 0}$ jednorodny proces Poissona. Wówczas warunkowy rozkład momentu skoku pod warunkiem $N(t) = 1$ jest rozkładem jednostajnym na $[0, t]$.

Dowód.

$$\begin{aligned} & P(X_1 \leq t_1 | N(t) = 1) = \\ &= \frac{P(X_1 \leq t_1 \wedge N(t) = 1)}{P(N(t) = 1)} = \\ &= \frac{P(N(t_1) = 1 \wedge N(t) = 1)}{P(N(t) = 0)} = \\ &= \frac{P(N(t_1) = 1) P(N(t) = 1)}{P(N(t) = 0)} = \\ &= \frac{P(N(t_1) = 1) P(N(t - t_1) = 1)}{P(N(t) = 0)} = \\ &= \frac{\lambda t_1 e^{-\lambda t_1} e^{-\lambda(t-t_1)}}{\lambda t e^{-\lambda t}} = \frac{t_1}{t} \end{aligned}$$

$$F_{X_1|N(t)=1}(x) = \begin{cases} 0 & x \leq 0 \\ \frac{x}{t} & 0 < x < t \\ 1 & x \geq t \end{cases}$$

□

Twierdzenie 12

Rozkład warunkowy wektora momentu skoków (zawarto... T_1, T_2, \dots, T_n) pod warunkiem zdarzenia $N(t) = n$ ma gęstość $f_{(T_1, \dots, T_n)}(t_1, \dots, t_n) = \frac{n!}{t^n} \mathbb{1}_{\{0 < t_1 < \dots < t_n < t\}}$. Czyli jest taki sam jak rozkład statystyk pozycyjnych dla Y_1, \dots, Y_n i.i.d. na przedziale $[0, t]$.

Dowód. Zobaczmy jak "idzie" dla $n = 2$ $f_{(T_1, T_2)}(t_1, t_2) = ?$
Oczywiście $0 < t_1 < t_2 < t$

$$\begin{aligned} & f_{(T_1, T_2)}(t_1, t_2) = \\ &= \lim_{\substack{\Delta t_1 \rightarrow 0 \\ \Delta t_2 \rightarrow 0}} \frac{P(T_1 \in [t_1, t_1 + \Delta t_1), T_2 \in [t_2, t_2 + \Delta t_2))}{\Delta t_1 \cdot \Delta t_2} = \\ &= \lim_{\substack{\Delta t_1 \rightarrow 0 \\ \Delta t_2 \rightarrow 0}} \frac{P(T_1 \in [t_1, t_1 + \Delta t_1), T_2 \in [t_2, t_2 + \Delta t_2), N(t) = 2)}{\Delta t_1 \cdot \Delta t_2 P(N(t) = 2)} = \\ &= \lim_{\substack{\Delta t_1 \rightarrow 0 \\ \Delta t_2 \rightarrow 0}} \frac{P(N(t_1)=0, N(t_1+\Delta t_1)-N(t_1)=1, N(t_2)-N(t_1+\Delta t_1)=0, N(t_2+\Delta t_2)-N(t_2)=1, N(t)-N(t_2+\Delta t_2)=0)}{\Delta t_1 \cdot \Delta t_2 \frac{(\lambda t)^2}{2!} e^{-\lambda t}} = \\ &= \lim_{\substack{\Delta t_1 \rightarrow 0 \\ \Delta t_2 \rightarrow 0}} \frac{P(N(t_1) = 0) P(N(t_1 + \Delta t_1) - N(t_1) = 1) P(N(t_2) - N(t_1 + \Delta t_1) = 0)}{\Delta t_1 \cdot \Delta t_2 \frac{(\lambda t)^2}{2!} e^{-\lambda t}} \cdot \\ &\quad \cdot P(N(t_2 + \Delta t_2) - N(t_2) = 1) P(N(t) - N(t_2 + \Delta t_2) = 0) = \\ &= \lim_{\substack{\Delta t_1 \rightarrow 0 \\ \Delta t_2 \rightarrow 0}} \frac{e^{-\lambda t_1} \cdot \lambda \Delta t_1 e^{-\lambda \Delta t_1} \cdot e^{\lambda t} \cdot e^{\lambda \Delta t} \cdot e^{-\lambda \Delta t_2} \cdot e^{-\lambda t} \cdot e^{\lambda t_2} \cdot e^{\lambda \Delta t_2}}{\frac{t^2}{2} \cdot e^{-\lambda t}} = \\ &= \frac{2!}{t^2} \mathbb{1}_{\{0 < t_1 < t_2 < t\}} \end{aligned}$$

□

6.2 Niejednorodny proces Poissona

$\lambda(t) \geq 0$ - intensywność pojawiania się zdarzeń zależny od czasu.

Definicja 21 (Niejednorodny proces Poissona)

Mówimy, że proces $\{N(t)\}_{t \geq 0}$ jest niejednorodnym procesem Poissona z funkcją intensywności (deterministyczną) $\lambda : [0, \infty) \rightarrow \mathbb{R}_+$. (ciągła)

- $N(0) = 0$ z pr. 1
- $\{N(t)\}_{t \geq 0}$ ma przyrosty niezależne
- $P(N(t + \Delta t) - N(t) = 1) = \lambda(t) \cdot \Delta t + o(\Delta t)$
- $P(N(t + \Delta t) - N(t) \geq 2) = o(\Delta t)$

Twierdzenie 13

Jeżeli $\{N(t)\}_{t \geq 0}$ jest niejednorodnym procesem Poissona z ciągłą funkcją intensywności $\lambda : [0, \infty) \rightarrow \mathbb{R}_+$, to

$$P(N(s+t) - N(t) = k) = \frac{(\mu(s+t) - \mu(t))^k}{k!} e^{-(\mu(s+t) - \mu(t))}$$

To znaczy

$$\forall_{s,t > 0} N(s+t) - N(t) \sim \text{Poisson}(\mu(s+t) - \mu(t))$$

gdzie

$$\mu(t) = \int_0^t \lambda(u) du$$

Dowód. Ustalmy t

$$P_k(s) = P(N(t+s) - N(t) = k)$$

$$\text{Czy } P(N(t+s) - N(t) = k) = \frac{(\mu(s+t) - \mu(t))^k}{k!} e^{-(\mu(s+t) - \mu(t))}?$$

Dowód indukcyjnie po k . Rozpoczynamy od $k = 0$

$$\begin{aligned} & P(N(t+s+\Delta s) - N(t+s) = 0 \wedge N(t+s) - N(t) = 0) = \\ & = P(N(t+s+\Delta s) - N(t+s) = 0) P(N(t+s) - N(t) = 0) = \\ & = \left(1 - P(N(t+s+\Delta s) - N(t+s) = 1) + o(\Delta s)\right) \cdot P_0(s) = \\ & = \left(1 - \lambda(t+s)\Delta s + o(\Delta s)\right) \cdot P_0(s) = \\ & = P_0(s) - \lambda(t+s)P_0(s)\Delta s + o(\Delta s) \end{aligned}$$

$$\begin{aligned}
\frac{P_0(s + \Delta t) - P_0(s)}{\Delta s} &= -\lambda(t + s)P_0(s) - \frac{o(\Delta s)}{\Delta s} \\
P'_0(s) &= -\lambda(t + s)P_0(s) \\
\frac{P'_0(s)}{P_0(s)} &= -\lambda(t + s) \\
(\ln P_0(s))' &= -\lambda(t + s) \\
\ln P_0(s) &= -\int_0^s \lambda(t + n) dn \\
\ln P_0(s) &= -\int_t^{t+s} \lambda(n) dn \\
P_0(s) &= \exp\left(-\int_t^{t+s} \lambda(n) dn\right) \\
P_0(s) &= \exp\left(-\int_0^{t+s} \lambda(n) dn + \int_0^t \lambda(n) dn\right) \\
P_0(s) &= e^{-(\mu(t+s)-\mu(t))}
\end{aligned}$$

Dla $k = 1$ formuła zachodzi. Krok indukcyjny robi się tak samo jak w przypadku jednorodnym. \square

Ogólnie
 $\{\tilde{N}(t)\}_{t \geq 0}$ niejednorodny proces Poissona $\supseteq \{N(t)\}_{t \geq 0}$ standardowy proces Poissona (jednorodny z $\lambda = 1$ szczególny przypadek)
 Załóżmy, że $\lambda(u) > 0$, ciągle (ewentualnie $\lambda(0) = 0$)

$$\mu(t) = \int_0^t \lambda(u) du \xrightarrow{t \rightarrow \infty} \int_0^\infty \lambda(u) du = \infty$$

$\mu(t)$ jest funkcją $\mu(0) = 0$, μ ściśle rosnące i klasy $C([0, \infty])$

Twierdzenie 14

Jeśli $\{N(t)\}_{t \geq 0}$ jest niejednorodnym procesem Poissona z funkcją intensywności $\lambda : [0, \infty) \rightarrow \mathbb{R}_+$ ciągłą, $\lambda(u) > 0$ dla $u > 0$ i $\int_0^\infty \lambda(u) du = \infty$, to proces $N(t) \stackrel{df}{=} \tilde{N}(\mu^{-1}(t))$ jest niejednorodnym procesem Poissona z funkcją intensywności

$$\lambda(t) = \mu'(t)$$

Twierdzenie 15

Niech $\{N(t)\}_{t \geq 0}$ będzie standardowym procesem Poissona oraz $\mu : [0, \infty) \rightarrow [0, \infty)$ będzie funkcją klasy C^1 , ściśle rosnącą, $\mu(0) = 0$, $\lim_{t \rightarrow \infty} \mu(t) = \infty$. Wówczas proces $\tilde{N}(t) \stackrel{\text{df}}{=} N(\mu(t))$ jest niejednorodnym procesem Poissona z funkcją intensywności

$$\lambda(t) = \mu'(t)$$

Wniosek

Niejednorodne procesy Poissona powstają przez deterministyczne przeskalowanie czasu w standardowym procesie Poissona.

Naturalnym uogólnieniem są procesy Coxa.

$$N(t + \Delta t) - N(t) = 1 \quad \text{z intensywnością } \lambda_t$$

Dowód.

$$\begin{aligned} \tilde{N}(\mu^{-1}(t)) &= N(t) \\ \tilde{N}(\mu^{-1}(0)) &= N(0) \end{aligned}$$

$N(t)$ jest rosnące, gdyż \tilde{N} jest liczący.

$N(t)$ ma przyrosty niezależne, gdyż \tilde{N} ma przyrosty niezależne

$$\begin{aligned} &P(N(t+s) - N(t) = k) = \\ &= P(\tilde{N}(\mu^{-1}(t+s)) - \tilde{N}(\mu^{-1}(t)) = k) = \\ &= \frac{(\mu(\mu^{-1}(t+s)) - \mu(\mu^{-1}(t)))^k}{k!} = \\ &= e^{-\mu(\mu^{-1}(t+s)) - \mu(\mu^{-1}(t))} = \\ &= \frac{(t+s-t)^k}{k!} e^{-s} \sim \text{Poisson}(1) \end{aligned}$$

Niezależność przyrostów $\tilde{N}(\mu^{-1}(t))$ wynika z niezależności przyrostów $\tilde{N}T = (t)$ i faktu, że μ^{-1} jest rosnąca. \square