

Rozdział 1

28 września 2015

Procesy stochastyczne - teoria służąca do opisu analizy (wnioskowań) zjawisk losowych ewoluujących w czasie. Wywodzą się z rachunku prawdopodobieństwa. Modelowanie rzeczywistości obarczonej niepewnością (losowością). Przeciwnieństwo równań różniczkowych.

$$\begin{aligned}y' &= f(y, t) \\ y(t) &= g(t, y_0)\end{aligned}$$

Równania różniczkowe dostarczają modeli deterministycznych. Idealizuje, możliwe w warunkach laboratoryjnych. Bardzo dużo praktycznych zagadnień nie ma charakteru deterministycznego (a jak już ma to będzie to determinizm chaotyczny). Chaos to nie to samo, co losowość. Losowość tkwi w głębi natury. Dla przykładu mechanika kwantowa.

Podstawowe elementy (pojęcia) procesów stochastycznych:

Przestrzeń probabilistyczna (Ω, \mathcal{F}, P)

Ω - zbiór zdarzeń elementarnych	} pojęcia pierwotne
$\omega \in \Omega$ - zdarzenie elementarne	
\mathcal{F} - σ -ciało podzbioru Ω	

Definicja 1 (σ -ciało)

Mówimy, że rodzina \mathcal{F} podzbiorów Ω jest σ -ciałem, jeśli spełnia:

1.

$$\emptyset \in \mathcal{F}, \quad \Omega \in \mathcal{F},$$

2.

$$\forall A \in \Omega [A \in \mathcal{F} \Rightarrow A^c = \Omega \setminus A \in \mathcal{F}],$$

3.

$$\forall A_1, A_2, \dots \in \Omega \left[\forall_n A_n \in \mathcal{F} \Rightarrow \bigcup_{n=1}^{\infty} A_n \in \mathcal{F} \right],$$

Definicja 2

Mówimy, że funkcja zbioru P określona na (Ω, \mathcal{F}) jest σ -addytywnym prawdopodobieństwem (miarą probabilistyczną σ -addytywną), jeżeli spełnia:

1.

$$P : \mathcal{F} \rightarrow [0, 1],$$

2.

$$P(\emptyset) = 0,$$

3.

$$P(\Omega) = 1,$$

4. warunek σ -addytywności

$$\forall A_1, A_2, \dots \in \mathcal{F} \left[\forall_{i \neq j} A_i \cap A_j = \emptyset \Rightarrow P \left(\bigcup_{n=1}^{\infty} A_n \right) = \sum_{n=1}^{\infty} P(A_n) \right]$$

Definicja 3 (Proces stochastyczny)

Procesem stochastycznym na przestrzeni probabilistycznej (Ω, \mathcal{F}, P) nazywamy rodzinę zmiennych losowych $\{X_t\}_{t \in T}$ określonych na (Ω, \mathcal{F}, P) .

T - zbiór indeksów (czasowych, gdy T interpretujemy jako czas)

Definicja 4 (Zmienna losowa)

Zmienna losowa X_t .

$$\forall t \in T \forall B \in \mathfrak{B}_{\mathbb{R}} X_t^{-1}(B) \in \mathcal{F}$$

X_t jest \mathcal{F} mierzalne; X_t jest $\sigma(\mathcal{F}, \mathfrak{B}_{\mathbb{R}})$ mierzalna

- $\mathfrak{B}_{\mathbb{R}}$ - σ -ciało zbiorów borelowskich w \mathbb{R}
- $\mathfrak{B}_{\mathbb{R}} = \sigma(\{(\alpha, \beta) : \alpha < \beta\})$

Uwaga!

$$\text{card}(\mathfrak{B}_{\mathbb{R}}) = \mathfrak{c} < 2^{\mathfrak{c}} = \text{card}(\mathcal{L}_{\mathbb{R}})$$

Definicja 5

Niech Ω będzie ustalonym zbiorem. Mówimy, że rodzina \mathcal{C} podzbiorów Ω tworzy ciało, jeżeli spełnia:

1.

$$\emptyset, \Omega \in \mathcal{C}$$

2.

$$\forall A \subseteq \Omega [A \in \mathcal{C} \Rightarrow A^c \in \mathcal{C}]$$

3.

$$\begin{aligned} & \forall A, B \in \mathcal{C} [A < B \Rightarrow A \cup B \in \mathcal{C}] \equiv \\ & \equiv \left[A_1, A_2, \dots, A_n \in \mathcal{C}, \quad n \in \mathbb{N} \Rightarrow \bigcup_{j=1}^n A_j \in \mathcal{C} \right] \end{aligned}$$

Definicja 6

Mówimy, że funkcja zbioru μ określona na (Ω, \mathcal{C}) jest miarą probabilistyczną σ -addytywną, jeśli spełnia:

1.

$$\begin{aligned} \mu(\emptyset) &= 0 \\ \mu(\Omega) &= 1 \\ \forall A \in \mathcal{C} \quad 0 &\leq \mu(A) \leq 1 \end{aligned}$$

2.

$$\forall A_1, A_2, \dots \in \mathcal{C} \left[\forall i \neq j A_i \cap A_j = \emptyset \wedge \bigcup_{n=1}^{\infty} A_n \in \mathcal{C} \Rightarrow \mu\left(\bigcup_{n=1}^{\infty} A_n\right) = \sum_{n=1}^{\infty} \mu(A_n) \right]$$

Rozdział 2

5 Października 2015

Twierdzenie 1

Niech \mathcal{C} będzie ciałem podzbiorów Ω oraz $\mu : \mathcal{C} \rightarrow [0, 1]$ będzie miarą skończone addytywną na (Ω, \mathcal{C}) nieujemną i unormowaną, czyli

$$\mu(\Omega) = 1, \forall a \in \mathcal{C} \quad 0 \leq \mu(A) \leq 1.$$

Wówczas następujące warunki są równoważne:

(A) μ jest σ -addytywna na (Ω, \mathcal{C})

(B) Ciągłość od dołu

$$\forall B_j \in \mathcal{C} \forall B_1 \subseteq B_2 \subseteq \dots \bigcup_{j=1}^{\infty} B_j \in \mathcal{C} \Rightarrow \mu \left(\bigcup_{j=1}^{\infty} B_j \right) = \lim_{n \rightarrow \infty} \mu(B_n)$$

(C) Ciągłość od góry

$$\forall C_j \in \mathcal{C} \forall C_1 \supseteq C_2 \supseteq \dots \bigcap_{j=1}^{\infty} C_j = \emptyset \Rightarrow \lim_{n \rightarrow \infty} \mu(C_n) = 0$$

Dowód. (A) \Rightarrow (B)

$$A_1 = B_1$$

$$A_2 = B_2 \setminus B_1$$

\vdots

$$A_n = B_n \setminus B_{n-1}$$

\vdots

$$\bigcup_{j=1}^{\infty} B_j = \bigcup_{j=1}^{\infty} A_j$$

$$\begin{aligned}
\mu\left(\bigcup_{j=1}^{\infty} B_j\right) &= \mu\left(\bigcup_{j=1}^{\infty} A_j\right) = \\
&= \sum_{j=1}^{\infty} \mu(A_j) = \lim_{n \rightarrow \infty} \sum_{j=1}^n \mu(A_j) = \\
&= \lim_{n \rightarrow \infty} \mu\left(\bigcup_{j=1}^n A_j\right) = \\
&= \lim_{n \rightarrow \infty} \mu(B_n)
\end{aligned}$$

(B) \Rightarrow (C)

$$C_1 \supseteq C_2 \supseteq \dots$$

$$\bigcap_{n=1}^{\infty} C_n = \emptyset$$

$$B_n = C_n^c = \Omega \setminus C_n$$

$$\bigcup_{n=1}^{\infty} B_n = (\bigcap_{n=1}^{\infty} C_n)^c = \emptyset^c = \Omega$$

$$\begin{aligned}
1 &= \mu(\Omega) = \\
&= \mu\left(\bigcup_{n=1}^{\infty} B_n\right) = \\
&= \lim_{n \rightarrow \infty} \mu(B_n) = \\
&= \lim_{n \rightarrow \infty} (\mu(\Omega) - \mu(C_n)) = \\
&= \lim_{n \rightarrow \infty} (\mu(\Omega) - \mu(C_n)) = \\
&= \mu(\Omega) - \lim_{n \rightarrow \infty} \mu(C_n) \Rightarrow \lim_{n \rightarrow \infty} \mu(C_n) = 0
\end{aligned}$$

(C) \Rightarrow (A)

$$\bigcup_{j=1}^{\infty} A_j \in \mathcal{C}$$

$$\bigcup_{j=1}^{n-1} A_j \in \mathcal{C}$$

$$C_n = \bigcup_{j=n}^{\infty} A_j = \bigcup_{j=1}^{\infty} A_j \setminus \bigcup_{j=1}^{n-1} A_j \in \mathcal{C}$$

$$C_1 \supseteq C_2 \supseteq \dots$$

$$\bigcap_{j=1}^{\infty} C_n = \emptyset.$$

$$\text{Z (C)} \lim_{n \rightarrow \infty} \mu(C_n) = 0$$

$$\begin{aligned} \mu(C_n) &= \\ &= \mu \left(\bigcup_{j=n}^{\infty} A_j \right) = \\ &= \mu \left(\bigcup_{j=1}^{\infty} A_j \setminus \bigcup_{j=1}^{n-1} A_j \right) = \\ &= \mu \left(\bigcup_{j=1}^{\infty} A_j \right) - \mu \left(\bigcup_{j=1}^{n-1} A_j \right) = \\ &= \mu \left(\bigcup_{j=1}^{\infty} A_j \right) - \sum_{j=1}^{n-1} \mu(A_j) \rightarrow 0 \end{aligned}$$

$$\begin{aligned} \lim_{n \rightarrow \infty} \mu \left(\bigcup_{j=1}^{n-1} A_j \right) &= \mu \left(\bigcup_{j=1}^{\infty} A_j \right) \\ \lim_{n \rightarrow \infty} \sum_{j=1}^{n-1} \mu(A_j) &= \mu \left(\bigcup_{j=1}^{\infty} A_j \right) \end{aligned}$$

Ostatecznie

$$\mu \left(\bigcup_{j=1}^{\infty} A_j \right) = \sum_{j=1}^{\infty} \mu(A_j)$$

□

Uwaga!

Warunek (C) jest bardzo wygodny do sprawdzenia.

Twierdzenie 2

Jeżeli μ jest prawdopodobieństwem σ -addytywnym na ciele \mathcal{C} podzbiorów Ω , to istnieje dokładnie jedno rozszerzenie μ do miary probabilistycznej $\tilde{\mu}$ na $\sigma(\mathcal{C})$ $\{\tilde{\mu}|_{\mathcal{C}} = \mu\}$

$$(\Omega, \mathcal{C}, \mu) \rightsquigarrow (\Omega, \sigma(\mathcal{C}), \tilde{\mu})$$

Tradycyjnie $\tilde{\mu}$ piszemy μ .

Dygresja

$\Omega = \mathbb{N}, A \subseteq \mathbb{N}, \nu(A) = \lim_{n \rightarrow \infty} \frac{\mu(A \cap \{1, 2, \dots, n\})}{n}$ gęstość zbioru A . Dobra miara

"grubości" podzbiorów \mathbb{N} . Nie wszystkie podzbiory mają gęstość. Z całą pewnością ν nie jest σ -addytywna, bo $\nu(k) = 0$, $\text{card}(k) < \infty$

$$1 = \nu(\mathbb{N}) \neq \lim_{n \rightarrow \infty} \nu(\{1, 2, \dots, n\}) = 0$$

Przykład 1

$$\Omega = (0, 1]$$

$$\mathcal{C}_{\text{przed.}} = \left\{ \bigcup_{j=1}^{\infty} (\alpha_j, \beta_j] : n = 0, 1, \dots; 0 < \alpha_1 < \beta_1 < \alpha_2 < \beta_2 < \dots < \alpha_n < \beta_n \right\}$$

$F : [0, 1] \rightarrow \mathbb{R}$, F niemalejąca, prawostronnie ciągła.

$$\mu_F \left(\bigcup_{j=1}^{\infty} (\alpha_j, \beta_j] \right) \stackrel{\text{df}}{=} \sum_{j=1}^n (F(\beta_j) - F(\alpha_j)) \geq 0$$

μ_F jest skończenie addytywna na $((0, 1], \text{przed.})$, co widać z konstrukcji. Nieco trudniej dowodzi się, że μ_F jest σ -addytywna na ciele $\mathcal{C}_{\text{przed.}}$. Zatem każda funkcja niemalejąca, prawostronnie ciągła $F : [0, 1]$ definiuje miarę σ -addytywną na $((0, 1], \sigma(\mathcal{C}_{\text{przed.}}))$

FUNKCJE TWORZĄCE

(p.g.f. probability geometry function)

Niech $X : (\Omega, \mathcal{F}, P) \rightarrow \mathbb{N}_0 = \{0, 1, 2, \dots\}$ będzie zmienną losową ($\chi_X(B) \in \mathcal{F}, \subseteq \mathbb{N}$ - dowolny podzbiór). Nową charakterystyką takich zmiennych losowych jest funkcja charakterystyczna.

Definicja 7 (Funkcja tworząca)

Funkcją tworzącą zmiennej losowej X o wartościach w \mathbb{N}_0 nazywamy

$$\Upsilon_X(s) = \mathbb{E}s^X \left(= \sum_{j=0}^{\infty} s^j P(X = j) = \sum_{j=0}^{\infty} s^j p_j \right)$$

Pytanie: $\text{Dom}(r_X) = ?$

r_X określona szeregiem potęgowym; pewnie analityczna. $r_X(z), z \in K(0, R)$

Twierdzenie 3

Niech $X, X^{(1)}, X^{(2)}, \dots$ będą zmiennymi losowymi o wartościach w \mathbb{N}_0 i oznaczmy $P(X = k) = p_k$, $P(X^{(n)} = k) = p_k^{(n)}$, $k = 0, 1, 2, \dots$. Wówczas:

1. $\text{dom}(\Upsilon_X) \supseteq [-1, 1]$ (W przypadku dziedziny zespolonej $\overline{K}(0, 1)$)
 Υ_X jest niemalejąca i wypukła na $[0, 1]$ oraz klasy C^∞ na $(-1, 1)$

2. $\Upsilon_X(1) = 1$

3.

$$\begin{aligned}\Upsilon'_X(0) &= P(X = 1) = p_1 \\ \Upsilon''_X(0) &= 2 \cdot P(X = 2) = 2p_2 \\ &\vdots \\ \Upsilon_X^{(k)}(0) &= k! \cdot P(X = k) = k!p_k\end{aligned}$$

4. Dla X

$$\mathbb{E}X^n < \infty \Leftrightarrow \lim_{n \rightarrow 1^-} \Upsilon_X^{(n)}(s) = \Upsilon_X^{(n)}(1^-) < \infty$$

Co więcej

$$\Upsilon_X^{(n)}(1^-) = \mathbb{E}X(X-1)\cdots(X-n+1)$$

n-ty moment faktorialny

W szczególności

$$\begin{aligned}\mathbb{E}X &= \Upsilon'_X(1^-) \\ \mathbb{E}X^2 &= \mathbb{E}X(X-1) + \mathbb{E}X = \Upsilon''_X(1^-) + \Upsilon'_X(1^-)\end{aligned}$$

5. Jeżeli x i Y są niezależne o wartościach w \mathbb{N}_0 , to $\Upsilon_{X+Y}(s) = \Upsilon_X(s)\Upsilon_Y(s)$

6. Jeżeli $X^{(1)}, X^{(2)}, \dots$ są niezależnymi zmiennymi losowymi o tym samym rozkładzie i o wartościach w \mathbb{N}_0 i podobnie τ i dodatkowo ciąg $X^{(1)}, X^{(2)}, \dots$ i τ są niezależne, to dla

$$U = \sum_{j=1}^{\tau} X^{(j)}$$

mamy

$$\Upsilon_U(s) = \Upsilon_{\tau}(\Upsilon_{X^{(1)}}(s))$$

7. Dla dowolnego ciągu zmiennych losowych (niekoniecznie niezależnych) $X^{(1)}, X^{(2)}, \dots$ i zmiennej losowej X o wartościach w \mathbb{N}_0 następujące warunki są równoważne:

$$(a) \quad \forall_{k \in \mathbb{N}_0} \lim_{n \rightarrow \infty} P(X^{(n)} = k) = P(X = k)$$

(b) $X_n \xrightarrow{\mathcal{D}} X$ (zbieżność słaba)

(c) $\forall_{s \in [0,1]} \lim_{n \rightarrow \infty} \Upsilon_{X^{(n)}}(s) = \Upsilon_X(s)$

Dowód.

$$2. \Upsilon_X(1) = \mathbb{E}1^X = \mathbb{E}1 = 1$$

1.

$$\Upsilon_X(s) = \sum_{k=0}^{\infty} s^X p_k = \sum_{k=0}^{\infty} p_k s^k$$

ten szereg potęgowy jest zbieżny dla $s = 1$ nawet bezwzględnie.

$$\left(\sum_{k=0}^{\infty} |p_k| |s|^k \right)_{s=1} \\ \sum_{k=0}^{\infty} |a_k| |z|^k < \infty$$

$\Upsilon_X(z)$ jest dobrze określone na $|z| \leq 1$.

Υ_X jest funkcją analityczną (co najmniej) na $\{z : |z| < 1\}$, a stąd wynika, że

Υ_X jest ciągła na $[-1, 1]$ i ma ciągłe pochodne na $(-1, 1)$.

$\Upsilon_X(s) = \sum_{k=0}^{\infty} p_k s^k \geq 0$ na $[0, 1]$

$\Upsilon'_X(s) = \sum_{k=0}^{\infty} k \cdot p_k s^{k-1} \geq 0$ - niemalejąca na $[0, 1]$

$\Upsilon''_X(s) = \sum_{k=0}^{\infty} k(k-1)p_k s^{k-2} \geq 0$ dla $s \in [0, 1]$

Reasumując Υ_X jest nieujemna, niemalejąca, wypukła na $[0, 1]$.

$$P(\{X > 0\} \cup \{X = 1\}) = 1$$

$$P(X \geq 2) > 0$$

$$\Upsilon_X(s) = p_0 + p_1 \cdot s$$

Υ_X ściśle wypukła

3.

$$\Upsilon_X^{(k)}(s) = \frac{d^k}{ds^k} \left(\sum_{j=0}^{\infty} p_j s^j \right) = \\ = \sum_{j=0}^{\infty} j(j-1) \cdots (j-k+1) p_j s^{j-k} = \sum_{j=k}^{\infty} j(j-1) \cdots (j-k+1) p_j s^{j-k}$$

$$\Upsilon_X^{(k)}(0) = k(k-1) \cdots (k-k+1) p_k = k! p_k \Rightarrow p_k = P(X = k) = \frac{\Upsilon_X}{k!}$$

4.

$$\begin{aligned}
 \mathbb{E}X &= \\
 &= \sum_{k=0}^{\infty} k \cdot P(X = k) = \\
 &= \sum_{k=0}^{\infty} k \cdot p_k \cdot 1^k = \\
 &= \left(\sum_{k=0}^{\infty} k \cdot p_k \cdot s^k \right)_{s=1} = \\
 &= \lim_{n \rightarrow 1^-} \left(\sum_{k=0}^{\infty} k \cdot p_k \cdot s^k \right) = \\
 &= \lim_{n \rightarrow 1^-} \Upsilon'_X(s)
 \end{aligned}$$

Analogicznie

$$\begin{aligned}
 \mathbb{E}X(X+1) \cdots (X-n+1) &= \\
 &= \sum_{k=n}^{\infty} k(k-1) \cdots (k-n+1) p_k \cdot 1^{k-n+1} = \\
 &= \lim_{n \rightarrow 1^-} \Upsilon_X^{(n)}(s)
 \end{aligned}$$

Uwaga!

$$\mathbb{E}X^n < \infty \Leftrightarrow \mathbb{E}(X(X-1) \cdots (X-n+1)) < \infty$$

5. X, Y niezależne zmienne losowe o wartościach w \mathbb{N}_0

$$\Upsilon_{X+Y}(s) = \mathbb{E}s^{X+Y} = \mathbb{E}s^X \cdot s^Y = \mathbb{E}s^X \cdot \mathbb{E}s^Y = \Upsilon_X^{(s)} \Upsilon_Y^{(s)}$$

6. $V = \sum_{j=1}^{\tau} X^{(j)}$, ustalmy $\sum_{j=1}^0 \dots = 0$

$$\begin{aligned}
\Upsilon_V(s) &= \mathbb{E} s^V = \int_{\Omega} s^V dP = \\
&= \sum_{n=0}^{\infty} \int_{\{\tau=n\}} s^{\sum_{j=1}^{\tau} x^{(j)}} dP = \\
&= \int_{\{\tau=0\}} s^{\sum_{j=1}^0 x^{(j)}} dP + \sum_{n=1}^{\infty} \int_{\{\tau=n\}} s^{\sum_{j=1}^{\tau} x^{(j)}} dP = \\
&= 1 \cdot P(\tau=0) + \sum_{n=1}^{\infty} \int_{\Omega} \mathbb{1}_{\{\tau=n\}} dP \int_{\Omega} s^{\sum_{j=1}^{\tau} x^{(j)}} dP = \\
&= 1^0 \cdot P(\tau=0) + \sum_{n=1}^{\infty} P(\tau=n) \Upsilon_{\sum_{j=1}^{\tau} x^{(j)}}(s) = \\
&= P(\tau=0) \cdot s^0 + \sum_{n=1}^{\infty} P(\tau=n) [\Upsilon_{X^{(1)}}(s)]^n = \\
&= P(\tau=0) \cdot \left(\Upsilon_X^{(1)}(s)\right)^0 + \sum_{n=1}^{\infty} P(\tau=n) [\Upsilon_{X^{(1)}}(s)]^n = \\
&= \Upsilon_{\tau}(\Upsilon_{X^{(1)}}(s)) = \Upsilon_{\tau} \circ \Upsilon_{X^{(1)}}(s)
\end{aligned}$$

□

Rozdział 3

12 października 2015

Dowód. 7. (a) \Rightarrow (b)

$$P(X^{(n)} \leq t) \xrightarrow{n \rightarrow \infty} P(X \leq t)$$

w każdym punkcie t , w którym F_X jest ciągła; dla $t < 0$ jasne, bo $0 \xrightarrow{n \rightarrow \infty} 0$

$$\begin{aligned} P(X^{(n)} \leq t) &= \\ &= P(X^{(n)} \leq \lfloor t \rfloor) = \\ &= \sum_{k=0}^{\lfloor t \rfloor} P(X^{(n)} = k) \xrightarrow{n \rightarrow \infty} \sum_{k=0}^{\lfloor t \rfloor} P(X \leq \lfloor t \rfloor) = \\ &= P(X \leq t) \end{aligned}$$

(b) \Rightarrow (c)

$$\Upsilon_{X^{(n)}}(s) = \mathbb{E}s^{X^{(n)}}$$

$$g_s(t) = \begin{cases} 1 & \text{dla } t \leq 0 \\ s^t & \text{dla } t > 0 \end{cases} \quad \text{dla } 1 \geq s > 0$$
$$g_0(t) = 1 - 2t$$

$\forall s \in [0,1] g_s$ jest funkcją ciągłą i ograniczoną

$$X \xrightarrow{\mathcal{D}} X \Leftrightarrow \forall g: \mathbb{R} \rightarrow \mathbb{R} \mathbb{E}g(X^{(n)}) \xrightarrow{n \rightarrow \infty} \mathbb{E}g(X)$$

Dla każdego $s \in [0, 1]$ g jest funkcją ciągłą i ograniczoną.

$$\begin{aligned}\mathbb{E}g_s(X^{(n)}) &= \mathbb{E}s^{X^{(n)}} = \Upsilon_{X^{(n)}}(s) \\ \mathbb{E}g_s(X) &= \Upsilon_X(s) \\ \mathbb{E}g_0(X^{(n)}) &= 1 \cdot P(X^{(n)} = 0) + \sum_{k=1}^{\infty} 0 \cdot P(X^{(n)} = k) = \\ &= \Upsilon_{X^{(n)}}(0) \xrightarrow{n \rightarrow \infty} \mathbb{E}g_0(X) = \dots = \Upsilon_X(0)\end{aligned}$$

(c) \Rightarrow (a)

Mamy $\Upsilon_{X^{(n)}}(s) \rightarrow \Upsilon_X(s)$ dla $s \in [0, 1]$

Podstawmy $s = 0$

$$\begin{aligned}\sum_{k=0}^{\infty} s^k \cdot P(X^{(n)} = k) \Big|_{s=0} &= P(X^{(n)} = 0) \xrightarrow[n \rightarrow \infty]{c)} \Upsilon_X(0) \\ P_0^{(n)} &\rightarrow P_0\end{aligned}$$

Szkic

$$\begin{aligned}p_1^{(n)} &= P(X^{(n)} = 1) \xrightarrow{n \rightarrow \infty} P(X = 0)? \\ \Upsilon_{X^{(n)}}(s) &= P(X^{(n)} = 0) + P(X^{(n)} = 1)s + P(X^{(n)} = 2)s^2 + \dots \\ \Upsilon_X(s) &= P(X = 0) + P(X = 1)s + P(X = 2)s^2 + \dots \\ \forall_{s \in [0,1]} \sum_{k=1}^{\infty} P(X^{(n)} = k) s^k &\xrightarrow{n \rightarrow \infty} \sum_{k=1}^{\infty} P(X = k) s^k \\ \forall_{s \in [0,1]} s \sum_{k=1}^{\infty} P(X^{(n)} = k) s^{k-1} &\xrightarrow{n \rightarrow \infty} s \sum_{k=1}^{\infty} P(X = k) s^{k-1}\end{aligned}$$

o, ile $0 \leq s \leq 1$, to uprościmy

$$\begin{aligned}\forall_{s \in [0,1]} \sum_{k=1}^{\infty} P(X^{(n)} = k) s^{k-1} &= \\ = P(X^{(n)} = 1) + P(X^{(n)} = 2)s + \dots + P(X^{(n)} = k)s^{k-1} + \dots &\xrightarrow{n \rightarrow \infty} \\ \xrightarrow{n \rightarrow \infty} P(X = 1) + P(X = 2)s + \dots + P(X = k)s^{k-1} + \dots\end{aligned}$$

mogą być dowolnie małe biorąc małe $s \in (0, 1]$. W takim razie, gdy $n \rightarrow \infty$ mamy

$$\begin{aligned}P(X^{(n)} = 0) &\xrightarrow{n \rightarrow \infty} P(X = 0) \\ P(X^{(n)} = 1) &\xrightarrow{n \rightarrow \infty} P(X = 1)\end{aligned}$$

dalej indukcyjnie

$$\forall_{k \in \mathbb{N}_0} P(X^{(n)} = k) \xrightarrow{n \rightarrow \infty} P(X = k)$$

□

FUNKCJA GENERUJĄCA MOMENTY (Moment generating function)

Definicja 8

Niech X będzie zmienną losową określoną na przestrzeni probabilistycznej (Ω, \mathcal{F}, P) . Funkcją generującą momenty nazywamy funkcję

$$M_X(s) = \mathbb{E}e^{sX} = \int_{-\infty}^{+\infty} e^{sx} dF_X(x)$$

Wtrącenie

$$\int_{-\infty}^{+\infty} e^{sx} f_X(x) dx, \text{ gdy } X \text{ ma gęstość } f_X$$

$$\sum_{k=1}^{\infty} e^{sx_k} P(X = x_k), \text{ gdy } X \text{ jest typu dyskretnego}$$

Wadą jest fakt, że $\text{Dom}(M_x)$ może być mała lub trudna do określenia. Np. może się zdarzyć, że $\text{Dom}(M_X) = \{0\}$, ale zawsze $0 \in \text{Dom}(M_X)$

Fakt

$$M_X(0) = \mathbb{E}e^{0 \cdot X} = \mathbb{E}e^0 = \mathbb{E}1 = 1$$

Chcielibyśmy, aby $(-\varepsilon, \varepsilon) \subseteq \text{Dom}(M_X)$

Twierdzenie 4

Niech zmienna losowa $X : (\Omega, \mathcal{F}, P) \rightarrow \mathbb{R}$ ma własność $\text{Dom}(M_X) \supseteq (-\varepsilon, \varepsilon)$ dla $\varepsilon > 0$. Wówczas

$$M'_X(0) = \mathbb{E}X$$

$$M''_X(0) = \mathbb{E}X^2 \text{ itd.}$$

Dowód.

$$\begin{aligned}
 M'_X(x) &= \\
 &= \lim_{h \rightarrow 0} \frac{M_X(x+h) - M_X(x)}{h} = \\
 &= \lim_{h \rightarrow 0} \frac{\mathbb{E}e^{(x+h)X} - \mathbb{E}e^{xX}}{h} = \\
 &= \lim_{h \rightarrow 0} \mathbb{E} \frac{e^{(x+h)X} - e^{xX}}{h} = \\
 &= \mathbb{E} \lim_{h \rightarrow 0} \frac{e^{(x+h)X} - e^{xX}}{h} = \\
 &= \mathbb{E} X e^{xX}
 \end{aligned}$$

$$M'_X(0) = \left(M'_X(x) \right)_{x=0} = \mathbb{E} X e^{0X} = \mathbb{E} X$$

Indukcyjnie dla wyższych momentów. □

Twierdzenie 5

Jeżeli zmienne losowe X, Y są niezależne to

$$M_{X+Y}(x) = M_X(x) \cdot M_Y(x)$$

Dowód.

$$\begin{aligned}
 M_{X+Y}(x) &= \\
 &= \mathbb{E} e^{x(X+Y)} = \\
 &= \mathbb{E} e^{xX+xY} = \\
 &= \mathbb{E} \underbrace{e^{xX} e^{xY}}_{\text{niezależne}} = \\
 &= \mathbb{E} e^{xX} \cdot \mathbb{E} e^{xY} = \\
 &= M_X(x) M_Y(x)
 \end{aligned}$$

□

Wniosek

Jeżeli X_1, \dots, X_k to niezależne zmienne losowe o tym samym rozkładzie, to

$$M_{\sum_{j=1}^k X_j}(x) = [M_{X_1}(x)]^k$$

Uwaga!

Jeżeli X i Y mają ten sam rozkład, to oczywiście

$$M_X = M_Y$$

Przykład 2

Wyznacz M_X , gdy $X \sim \text{Pois}(\lambda)$

$$\begin{aligned}
 M_X(x) &= \\
 &= \mathbb{E}e^{xX} = \\
 &= \sum_{k=0}^{\infty} e^{xk} \frac{\lambda^k}{k!} e^{-\lambda} = \\
 &= \sum_{k=0}^{\infty} \frac{(e^x \lambda)^k}{k!} e^{-\lambda} = \\
 &= e^{e^x \lambda} \cdot e^{-\lambda} = \\
 &= e^{\lambda(e^x - 1)}
 \end{aligned}$$

$$\text{Dom}(M_{\text{Pois}}) = \mathbb{R}$$

$$\mathbb{E} = M'_X(0)$$

$$M'_X(x) = \left(e^{\lambda(e^x - 1)} \right)' = e^{\lambda(e^x - 1)} \cdot (\lambda \cdot e^x)$$

$$M''_X(x) = \left(e^{\lambda(e^x - 1)} \cdot (\lambda \cdot e^x) \right)' = \lambda \left(e^{\lambda(e^x - 1)} \cdot \lambda e^x \cdot e^x + e^{\lambda(e^x - 1)} \cdot e^x \right)$$

$$M''_X(0) = \lambda(\lambda + 1) = \lambda^2 + \lambda = \mathbb{E}X^2$$

$$\text{Var}(X) = \mathbb{E}X^2 - (\mathbb{E}X)^2 = \lambda^2 + \lambda - \lambda^2 = \lambda$$

Przykład 3

$X \sim \text{Exp}(\alpha)$

$$\begin{aligned}
 M_X(x) &= \mathbb{E}e^{xX} = \int_0^{+\infty} e^{xt} \alpha e^{-\alpha t} dt = \alpha \int_0^{\infty} e^{(x-\alpha)t} dt = \\
 &= \frac{\alpha}{x-\alpha} e^{(x-\alpha)t} \Big|_0^{\infty} = \frac{-\alpha}{x-\alpha} = \frac{\alpha}{\alpha-x}
 \end{aligned}$$

$$\text{Dom}M_{\text{Exp}(\alpha)} = (-\infty, \alpha)$$

$$M'_X(x) = \frac{\alpha}{(x-\alpha)^2}$$

$$M'_X(0) = \mathbb{E}X = \frac{\alpha}{\alpha^2} = \frac{1}{\alpha}$$

$$M''_X(x) = \frac{2\alpha}{(\alpha-x)^3}$$

$$M''_X(0) = \mathbb{E}X^2 = \frac{2\alpha}{\alpha^3} = \frac{2}{\alpha^2}$$

itd.

UWAGI O TEORII NIEZAWODNOŚCI.

Niech czas pracy bezawaryjnej urządzenia opisany będzie zmienną losową X :
 $(\Omega, \mathcal{F}, P) \rightarrow [0, \infty)$

Definicja 9 (Funkcja niezawodności)

Funkcją niezawodności urządzenia nazywamy

$$R_X(t) = \overline{F}(t) = P(X > t) \text{ dla } t \in [0, \infty]$$

Uwaga!

$P(X = 0) = 0$ to nasze upraszczające założenie.

Definicja 10

Niech X będzie nieujemną zmienną losową. Mówimy, że X ma własność braku pamięci, jeżeli

$$\forall_{s,t \geq 0} P(X > s+t | X > t) = P(X > s)$$

Twierdzenie 6

Nieujemna zmienna losowa X ma własność braku pamięci wtedy i tylko wtedy, gdy ma rozkład wykładniczy.

Dowód. \Leftarrow

Zakładamy, że $X \sim \text{Exp}$, $P(X > t) = e^{-\alpha t}$

$$\begin{aligned} P(X > t+s | X > t) &= \frac{P(X > t+s \wedge X > t)}{P(X > t)} = \\ &= \frac{P(X > t+s)}{P(X > t)} = \\ &= \frac{e^{-\alpha(t+s)}}{e^{-\alpha t}} = \\ &= e^{-\alpha s} = \\ &= P(X > s) \end{aligned}$$

\Rightarrow

Zakładamy, że X ma własność braku pamięci

$$\begin{aligned} P(X > t+s | X > t) &= P(X > s) \\ \frac{P(X > t+s \wedge X > t)}{P(X > t)} &= P(X > s) \\ P(X > s+t) &= P(X > s) P(X > t) \\ \overline{F}_X(s+t) &= \overline{F}_X(s) \overline{F}_X(t) \text{ dla } s, t \geq 0 \end{aligned}$$

Mamy równanie funkcyjne dla $g : [0, \infty) \rightarrow \mathbb{R}$

$$\forall_{s,t \geq 0} g(t+s) = g(t)g(s)$$

$g(t) = \overline{F}(t)$ ograniczona, prawostronnie ciągła oraz $\overline{F}(0) = 1$ i
 $\lim_{x \rightarrow \infty} \overline{F}(x) = 0$

Odrzucamy trywialne rozwiązania równania $g \equiv 0$, $g \equiv 1$

$$\begin{aligned} g(2s) &= g(s+s) = g(s) \cdot g(s) = g(s)^2 \geq 0 \\ g(1) &= \underbrace{\left(\frac{1}{m} + \frac{1}{m} + \dots + \frac{1}{m}\right)}_{m \text{ razy}} = g\left(\frac{1}{m}\right) g\left(\frac{1}{m}\right) \dots g\left(\frac{1}{m}\right) = \left[g\left(\frac{1}{m}\right)\right]^m \\ g\left(\frac{1}{m}\right) &= g(1)^{\frac{1}{m}} \\ g\left(\frac{k}{m}\right) &= \underbrace{\left(\frac{1}{m} + \frac{1}{m} + \dots + \frac{1}{m}\right)}_{k \text{ składników}} = g\left(\frac{1}{m}\right) g\left(\frac{1}{m}\right) \dots g\left(\frac{1}{m}\right) = \\ &= g\left(\frac{1}{m}\right)^k = [g(1)]^{\frac{k}{m}} = g(1)^{\frac{k}{m}} \end{aligned}$$

Gdyby $g(1) = 0 \Rightarrow g\left(\frac{1}{m}\right) = 0 \Rightarrow \lim_{m \rightarrow \infty} g\left(\frac{1}{m}\right) = 0$, ale $g(0) = 1$

Zatem $g(1) > 0$.

Gdyby $g(1) > 1 \Rightarrow g(k) = g(1)^k \xrightarrow{k \rightarrow \infty} 0$, ale $\lim_{x \rightarrow \infty} g(x) = 0$

Zatem $0 < g(1) < 1$. Przyjmijmy, że $g(1) = e^{-\alpha}$ dla pewnego $\alpha > 0$. Wtedy

$$g\left(\frac{k}{m}\right) = (e^{-\alpha})^{\frac{k}{m}} = e^{-\alpha \frac{k}{m}}$$

Dla dowolnego $x \geq 0$, $\lim_{n \rightarrow \infty} \frac{k^{(n)}}{m^{(n)}} \left(\overline{\mathbb{Q}} = \mathbb{R} \right)$

$$g(x) = \lim_{n \rightarrow \infty} g\left(\frac{k^{(n)}}{m^{(n)}}\right) = \lim_{n \rightarrow \infty} e^{-\alpha \frac{k^{(n)}}{m^{(n)}}}$$

$$\forall_{x \geq 0} 1 - F(x) = \overline{F}(x) = e^{-\alpha x}; X \sim \text{Exp}$$

□

Uwaga!

W dziedzinie $\mathbb{N}_0 = \{0, 1, 2, \dots\}$ jedynym rozkładem o własności braku pamięci jest rozkład geometryczny.

Definicja 11

Niech X będzie zmienną losową opisującą czas pracy bezawaryjnej. Intensywnością awarii nazywamy funkcję $\lambda_X : [0, \infty) \rightarrow [0, \infty)$

$$\lambda_X(t) = \frac{f_X(t)}{\overline{F}_X(t)} = \frac{f_X(t)}{R_X(t)} = -\frac{R'_X(t)}{R_X(t)}$$

$$\begin{aligned} R'_X &= (1 - F_X)' = \\ &= -F'_X = -f_X \end{aligned}$$

Uwaga!

λ_X jest określona tylko dla zmiennych losowych absolutnie ciągłych.

W medycynie mówimy o intensywności śmierci albo ogólniej o funkcji hazardu. Rozkład (gęstość) wyznacza jednoznacznie funkcję intensywności awarii.

$$\lambda_X(t) = \frac{f_X(t)}{P(x > t)} = \frac{f_X(t)}{\int_t^{\infty} f_X(u) du}$$

Interpretacja funkcji intensywności awarii.

$$\begin{aligned} & \lim_{\Delta \rightarrow 0^+} \frac{P(t < X \leq t + \Delta t | X > t)}{\Delta t} = \\ &= \lim_{\Delta \rightarrow 0^+} \frac{\frac{P(X_t \in (t, t + \Delta t] | X_t > t)}{R_X(t)}}{\Delta t} = \\ &= \lim_{\Delta \rightarrow 0^+} \frac{\frac{P(X_t \in (t, t + \Delta t])}{\Delta t}}{R_X(t)} = \\ &= \lim_{\Delta \rightarrow 0^+} \frac{\frac{1}{\Delta t} \int_t^{t+\Delta t} f_X(u) du}{R_X(t)} = \\ &= \frac{f_X(t)}{R_X(t)} \end{aligned}$$